

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-16768-116143

Peter Bartoš

Avatar medicínskeho vyšetrenia CT/MR

Priebežná správa o riešení projektu

Vedúci práce: Ing. Miroslav Hlinka

December 2023

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-16768-116143

Peter Bartoš

Avatar medicínskeho vyšetrenia CT/MR

Priebežná správa o riešení projektu

Študijný program: Informatika

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky,
FIIT STU, Bratislava

Vedúci práce: Ing. Miroslav Hlinka

December 2023

ZADANIE BAKALÁRSKEJ PRÁCE



Autor práce: Peter Bartoš
Študijný program: informatika
Študijný odbor: informatika
Evidenčné číslo: FIIT-16768-116143
ID študenta: 116143
Vedúci práce: Ing. Miroslav Hlinka
Vedúci pracoviska: Ing. Katarína Jelemenská, PhD.

Názov práce: **Avatar medicínskeho vyšetrenia CT/MR**

Jazyk, v ktorom sa práca
vypracuje: slovenský jazyk

Špecifikácia zadania: V súčasnosti sa poskytuje prehľad o klinických nálezoch vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní podľa častí tela a orgánov. Táto forma neposkytuje dostatočný celkový prehľad. Cieľom práce je vypracovať systém grafického prehľadu všetkých klinických nálezov formou avatara. Preskúmajte možnosti automatického umiestnenia grafických značiek určitých nálezov (napr. nádory, zranení atď.) na zobrazení avatara. Navrhnite systém automatickej transformácie pozície nálezu na čiastočnej CT/MR snímke konkrétneho pacienta (napríklad malé dieťa, muži a ženy rôznych postáv v rôznych polohách) do normalizovaného grafického zobrazenia avatara. Navrhnite vlastné riešenie pre modelovanie transformácie zobrazenia. Toto navrhnuté riešenie implementuje tak, aby vznikol funkčný prototyp. Vyhodnotte presnosť generovanej pozície grafickej značky na avatare porovnaním s pozíciou vyhodnocovaného bodu na CT/MR snímkach rôznych pacientov (dieťa, muž, žena, rôzne polohy pacienta.)

Rozsah práce: 40

Termín odovzdania práce: 21. 05. 2024

Dátum schválenia zadania
práce: 03.05.2023

Zadanie práce schválil: doc. Ing. Valentino Vranič, PhD. – garant študijného programu

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Modrom Kameni, December 2023

Peter Bartoš

Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree Course: Informatika

Author: Peter Bartoš

Bachelor's Thesis: Avatar medicínskeho vyšetrenia CT/MR

Supervisor: Ing. Miroslav Hlinka

December 2023

Development of medical examinations, with the primary goal of enhancing the interpretation of medical images by radiologists has presented itself as a complex task for the last few years. This paper is focused on the exploration of this development, that enhances the interpretation of medical images by radiologists using a 3D Avatar Widget. The proposed system integrates advanced rendering techniques with interactive tools to facilitate a more comprehensive analysis of CT/MR scans. The Avatar Widget serves as a dynamic platform, allowing radiologists to visualize and interact with the CT/MR scans in three dimensions. By combining organ segmentation, radiological annotations, and 3D modeling, the proposed system aims to enhance the radiological diagnostic process. The integration of findings onto the 3D model provides a holistic perspective, facilitating a more comprehensive understanding of the relationships between radiological abnormalities and anatomical structures. For achieving our goal, we use CT/MR scans from Siemens Healthineers internal database, MONAI framework for preprocessing of medical images, TotalSegmentator's U-Net convolutional neural network for segmentation of organs, PyQt framework for interaction of radiologists to mark findings in CT/MR scans and OpenGL framework for 3D human anatomy model rendering.

Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Informatika

Autor: Peter Bartoš

Bakalárska práca: Avatar medicínskeho vyšetrenia CT/MR

Vedúci bakalárskeho projektu: Ing. Miroslav Hlinka

December 2023

Rozvoj lekárskeho vyšetrenia s primárnym cieľom zlepšiť interpretáciu lekárskeho snímok rádiológmi sa v posledných rokoch predstavuje ako zložitá úloha. Tento článok je zameraný na skúmanie tohto vývoja, ktorý zlepšuje interpretáciu lekárskeho snímok rádiológmi pomocou 3D avatara. Navrhovaný systém integruje pokročilé techniky vykresľovania s interaktívnymi nástrojmi na uľahčenie komplexnejšej analýzy CT/MR skenov. Avatar Widget slúži ako dynamická platforma, ktorá umožňuje rádiológom vizualizovať a interagovať s CT/MR skenmi v troch rozmeroch. Kombináciou segmentácie orgánov, rádiologických anotácií a 3D modelovania sa navrhovaný systém zameriava na zlepšenie rádiologického diagnostického procesu. Integrácia zistení do 3D modelu poskytuje holistickú perspektívu, ktorá uľahčuje komplexnejšie pochopenie vzťahov medzi rádiologickými abnormalitami a anatomickými štruktúrami. Na dosiahnutie nášho cieľa používame skeny CT/MR z internej databázy Siemens Healthineers, rámec MONAI na predspracovanie medicínskych zobrazení, U-Net konvolučnú neurónovú sieť TotalSegmentator na segmentáciu orgánov, rámec PyQt na interakciu rádiológov na označenie nálezov v CT/MR skenoch a rámec OpenGL pre 3D vykresľovanie modelu ľudskej anatómie.

Pod'akovanie

Moje poďakovanie patrí vedúcemu mojej práce Ing. Miroslavovi Hlinkovi za jeho ochotu a užitočné rady ktoré mi poskytol pri písaní bakalárskej práce.

Obsah

1	Úvod	1
1.1	Úvod do problémovej oblasti	1
1.2	Zámer projektu	2
2	Analýza problému	3
2.1	Úvod do medicínskych zobrazení	3
2.1.1	Počítačová tomografia	4
2.1.2	Magnetická rezonancia	6
2.2	Predspracovanie medicínskych zobrazení	7
2.2.1	MONAI	8
2.3	Umelá inteligencia	9
2.3.1	Hlboké učenie	11
2.3.2	Konvolučné neurónové siete	15
2.3.2.1	Konvolučná vrstva	16
2.3.2.2	Aktivačná vrstva	17
2.3.2.3	Združovacia vrstva	18
2.3.2.4	Plne prepojená vrstva	19
2.3.3	Porozumenie medicínskym zobraziam	20
2.3.3.1	Klasifikácia medicínskych zobrazení	20

2.3.3.2	Segmentácia medicínskych zobrazení	21
2.3.3.3	Lokalizácia medicínskych zobrazení	21
2.3.3.4	Detekcia v medicínskych zobrazeniach	21
2.3.4	Aplikácie konvolučných neurónových sietí v segmentácii medicínskych obrazov	22
2.3.4.1	Viaccestná a viacškálová konvolučná neurónová sieť	22
2.3.4.2	Konvolučná neurónová sieť založená na záplatách .	22
2.3.4.3	Odvodzovanie viacerých značiek v konvolučnej neurónovej sieti	23
2.3.4.4	U-Net	23
2.3.4.5	TotalSegmentator	24
2.3.5	Zhodnotenie aplikácií konvolučných neurónových sietí v segmentácii medicínskych obrazov	24
2.4	Počítačová grafika	26
2.4.1	Úvod do počítačovej grafiky	26
2.4.2	Rastrová grafika	26
2.4.3	Vektorová grafika	27
2.4.4	Rozdiely medzi vektorovou a rastrovou grafikou	27
2.4.5	Dvojrozmerná grafika	27
2.4.5.1	Pixelová mriežka	28
2.4.5.2	Farebné modely	29
2.4.6	Trojrozmerná grafika	30
2.4.7	Kreslenie čiar	30
2.4.7.1	Vyfarbovanie a zvýrazňovanie tvarov	31
2.4.7.2	Definícia polygónov	32
2.4.7.3	Translácia obrazu	33
2.4.7.4	Rotácia obrazu	34

2.4.7.5	Škálovanie obrazu	35
2.4.7.6	Import a export modelov	36
2.4.8	Grafické rámce	37
2.4.8.1	OpenGL	37
2.4.8.2	DirectX	37
2.4.8.3	Vulkan	38
2.4.9	Zhodnotenie grafických rámcov	38
2.5	Prenášanie označení z medicínskeho zobrazenia do 3D avatara . . .	39
2.5.1	Používateľské grafické rozhranie	39
2.5.1.1	Tkinter	39
2.5.1.2	PyQt	40
2.5.1.3	wxPython	40
2.5.2	Zhodnotenie rámcov grafických používateľských rozhraní . .	40
2.5.3	Algoritmus na prenášanie označení z medicínskeho zobraze- nia do 3D avatara	41
3	Návrh	43
3.1	3D avatar	43
3.2	Predspracovanie, zobrazenie a interakcia s medicínskymi zobrazeniami	44
3.3	Spracovanie medicínskeho zobrazenia	44
3.4	Prenášanie značiek z medicínskeho zobrazenia do 3D avatara	45

Kapitola 1

Úvod

1.1 Úvod do problémovej oblasti

Medicínske zobrazovanie zohráva kľúčovú úlohu v modernej zdravotnej starostlivosti a poskytuje lekárom neoceniteľný pohľad na vnútorné štruktúry ľudského tela. Skenovanie počítačovou tomografiou a magnetickou rezonanciou ponúka najmä podrobné prierezové snímky, ktoré pomáhajú pri diagnostike a plánovaní liečby rôznych zdravotných stavov. Keďže objem a zložitosť lekárskeho zobrazovacích údajov neustále narastá [14], potreba pokročilých nástrojov, ktoré uľahčujú presnú interpretáciu a analýzu, je čoraz zreteľnejšia.

Jednou dôležitou výzvou, ktorej čelia rádiológovia počas vyšetrenia CT skenov, je efektívna integrácia rádiologických nálezov do zmysluplného 3D kontextu. Ako bolo spomenuté už v samotnom zadaní: „V súčasnosti sa poskytuje prehľad o klinických nálezochoch vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní podľa častí tela a orgánov. Táto forma neposkytuje dostatočný celkový prehľad“, hoci sú informatívne, často chýba priestorové porozumenie nevyhnutné na pochopenie anatomických vzťahov medzi abnormalitami a okolitými štruktú-

rami. Vyriešenie tohto nedostatku si vyžaduje vývoj inovatívnych riešení, ktoré využívajú možnosti najmodernejších techník segmentácie obrazu, 3D modelovania a grafického vykresľovania.

1.2 Zámer projektu

V tejto práci sa budeme zaoberať touto výzvou prostredníctvom vytvorenia 3D avatara pre CT/MR lekárske vyšetrenia. Cieľom je poskytnúť rádiológom nástroj, ktorý bezproblémovo kombinuje pokročilé vykresľovanie CT snímok, užívateľsky prívetivé možnosti anotácie a interaktívne 3D zobrazenie ľudskej anatómie.

Tým, že navrhovaný systém umožňuje rádiológom anotovať nálezy priamo na CT snímky, chce poskytnúť prirodzený a intuitívny prostriedok na zachytenie diagnostických poznatkov. Ďalší krok zahŕňa implementovanie algoritmu na overenie priestorovej zhody medzi rádiologickými anotáciami a segmentovanými oblasťami CT snímok. Tento algoritmus je kľúčový pri zabezpečovaní presného zobrazenia nálezov na 3D reprezentáciu ľudskej anatómie.

Riešením tohto problému táto práca prispieva k pokroku v oblasti medicínskych zobrazovacích nástrojov a podporuje komplexnejší a efektívnejší prístup k rádiologickej analýze. Úspešná implementácia avatara má potenciál zlepšiť celkový pracovný postup rádiológov, čo v konečnom dôsledku povedie k efektívnejšej starostlivosti o pacientov.

Kapitola 2

Analýza problému

2.1 Úvod do medicínskych zobrazení


Lekárske zobrazovanie je kľúčovou oblasťou zdravotnej starostlivosti, ktorá využíva rôzne technológie na vytváranie vizuálnych zobrazení vnútra ľudského tela. Tieto snímky sú dôležité pri diagnostike, plánovaní liečby a monitorovaní zdravotných stavov. Zohráva tiež úlohu pri včasnej diagnostike pacienta, plánovaní individuálnej liečby, populačnom skríningu, hodnotení a predpovedaní výsledkov liečby, medicíne založenej na dôkazoch a predklinickom a klinickom výskume. Vďaka tomu, že lekárske zobrazovanie poskytuje lekárom neinvazívny a podrobný pohľad na anatomicke štruktúry a fyziologické procesy, zohráva rozhodujúcu úlohu v modernej medicíne. [27, 26]

V medicínskom zobrazovaní sa používa niekoľko metód, z ktorých každá ponúka jedinečné výhody a uspokojuje špecifické diagnostické potreby. Medzi najčastejšie používané lekárske zobrazovacie metódy patria: X-ray (röntgenové zobrazovanie), počítačová tomografia, magnetická rezonancia, ultrazvukové zobrazovanie. [13, 26] Táto práca sa zameria iba na počítačovú tomografiu a magnetickú rezonanciu.

2.1.1 Počítačová tomografia

Počítačová tomografia, bežne známa ako CT, je lekárska zobrazovacia technika, ktorá využíva röntgenovú technológiu na vytvorenie podrobných prierezových snímok vnútorných štruktúr tela. [19, 8]

Proces CT zobrazovania zahŕňa použitie röntgenového žiarenia, ktoré je nasmerované cez telo z viacerých uhlov. Detektory na opačnej strane pacienta zachytia röntgenové lúče po ich prechode telom a tieto údaje sa potom spracujú v počítači na vytvorenie podrobných dvojrozmerných rezov (alebo tomografických snímok) skenovanej oblasti. Tieto rezy možno ďalej rekonštruovať a vytvoriť trojrozmerné obrazy, ktoré umožňujú komplexné vyšetrenie anatómie. [19, 8]



Obr. 2.1: CT usporiadanie: Osový rez cez pacienta je vyžarovaný úzkym röntgenovým lúčom (šírky ceruzky), keď prepojený röntgenový trubicový detektor skenuje pacienta v lineárnej translácii. Translácie sa opakujú v mnohých uhloch. Hrúbka lúča je ekvivalentná hrúbke rezu. [8]

Charakteristickou črtou CT zobrazovania je jeho schopnosť odhaliť mäkké tkanivá, kosti a cievy s pozoruhodnou presnosťou, vďaka čomu je obzvlášť cenné pri zisťovaní a diagnostike širokého spektra zdravotných stavov. CT sa bežne používa v rôznych lekárskech špecializáciách, okrem iného v rádiológii, onkológii, neurológii a ortopédii. [19, 8]


Pokrok v technológii CT viedol k vývoju multidetektorových CT skenerov, ktoré dokážu získať viacero rezov súčasne, čím sa výrazne skracuje čas skenovania a zlepšuje kvalita obrazu. Okrem toho inovácie, ako napríklad CT skenovanie s kontrastom, zahŕňajú použitie kontrastných látok na zlepšenie viditeľnosti určitých štruktúr alebo abnormalít. [19, 8]



Obr. 2.2: Príklad CT skenu [19]

2.1.2 Magnetická rezonancia

Magnetická rezonancia (ďalej ako MR) je neinvazívna medicínska zobrazovacia technika, ktorá využíva silné magnety a rádiové frekvenčné impulzy na generovanie detailných snímok vnútorných štruktúr tela. Na rozdiel od röntgenových lúčov alebo počítačovej tomografie, MRI nepoužíva ionizujúce žiarenie, čo z neho robí bezpečnú a všestrannú zobrazovaciu modalitu. [22, 11]




Obr. 2.3: Príklad MR skenu [19]

MRI sa presadilo ako diagnostický a výskumný nástroj v mnohých oblastiach medicíny vďaka svojej schopnosti poskytnúť vynikajúce ohraničenie mäkkých tkanív v rôznych oblastiach záujmu. Okrem T1- a T2-vážených zobrazení bolo navrhnutých mnoho špecializovaných MRI techník na získavanie metabolických alebo biofyzikálnych informácií. Difúzne vážené zobrazovanie umožňuje nahliadnuť do pohybu molekúl vody v tkanive a zobrazovanie pomocou difúzneho tenzora môže odhaliť orientáciu vlákien v dráhach bielej hmoty. Metabolické informácie o objekte záujmu možno získať pomocou spektroskopie protónov, okrem zobrazovania iných jadier, napríklad sodíka. Dynamické zobrazovanie s použitím kontrastných látok a v poslednom čase aj protónová spektroskopia zohrávajú dôležitú úlohu v onkologickom zobrazovaní. Keď sa tieto techniky skombinujú, môžu lekárovi pomôcť pri stanovení diagnózy alebo monitorovaní liečebného režimu. Jednou z hlavných výhod rôznych typov MR zobrazovania je možnosť operátora manipulovať s kontrastom obrazu pomocou rôznych voliteľných parametrov, ktoré ovplyvňujú druh a kvalitu poskytovaných informácií. Medzi prvky používané na získanie MR obrazu a faktory, ktoré ovplyvňujú tvorbu MR obrazu, patrí MR prístrojové vybavenie, lokalizácia MR signálu, gradienty, k-priestor a pulzné sekvencie. [22, 11]

2.2 Predspracovanie medicínskych zobrazení

Predspracovanie zohráva priamo kľúčovú úlohu pri analýze medicínskych snímok a zahŕňa rad techník zameraných na zvýšenie kvality a užitočnosti nespracovaných medicínskych snímok. [2, 20, 12, 28] Hlavným cieľom predbežného spracovania je zmierniť šum, opraviť artefakty, normalizovať intenzitu a pripraviť údaje na následnú analýzu. Nasledujúci zoznam poskytuje prehľad o rôznych krokoch predspracovania, ktoré sa bežne používajú na medicínske snímky: redukcia šumu,

normalizácia intenzity, zvýšenie kontrastu, korekcia artefaktov, registrácia obrazu, priestorové filtrovanie, prevzorkovanie, orezanie obrazu, korekcia nerovnomernosti a kontrola kvality. [2, 20, 12, 28]



Obr. 2.4: Príklad predspracovania skenu [28]

Systematickým uplatňovaním týchto techník predspracovania sa analytici medicínskych snímok snažia zvýšiť spoľahlivosť a interpretovateľnosť dát. Ďalej sa usilujú o zabezpečenie toho, aby následné analýzy a diagnostické procesy boli založené na kvalitných reprezentáciách údajov. Výber konkrétnych krokov predspracovania závisí od vlastností zobrazovacej modality, povahy údajov a požiadaviek zamýšľanej analýzy. [2, 20, 12, 28]

2.2.1 MONAI

Rámec určený na analýzu zdravotníckych a lekárskeho snímok. Poskytuje nástroje na urýchlenie vývoja a nasadenia modelov hlbokého učenia v oblasti medicínskeho zobrazovania. Obsahuje načítavače údajov a rôzne techniky rozšírenia údajov prispôbené pre súbory lekárskeho zobrazovacích údajov. Taktiež ponúka celý rad stratových funkcií a hodnotiacich metrík vhodných pre úlohy lekárskeho zobrazovania. Poskytuje rozsiahlu dokumentáciu, ktorá pomáha pri pochopení a používaní rámca. [4] Tento rámec bude využitý v riešení projektu.

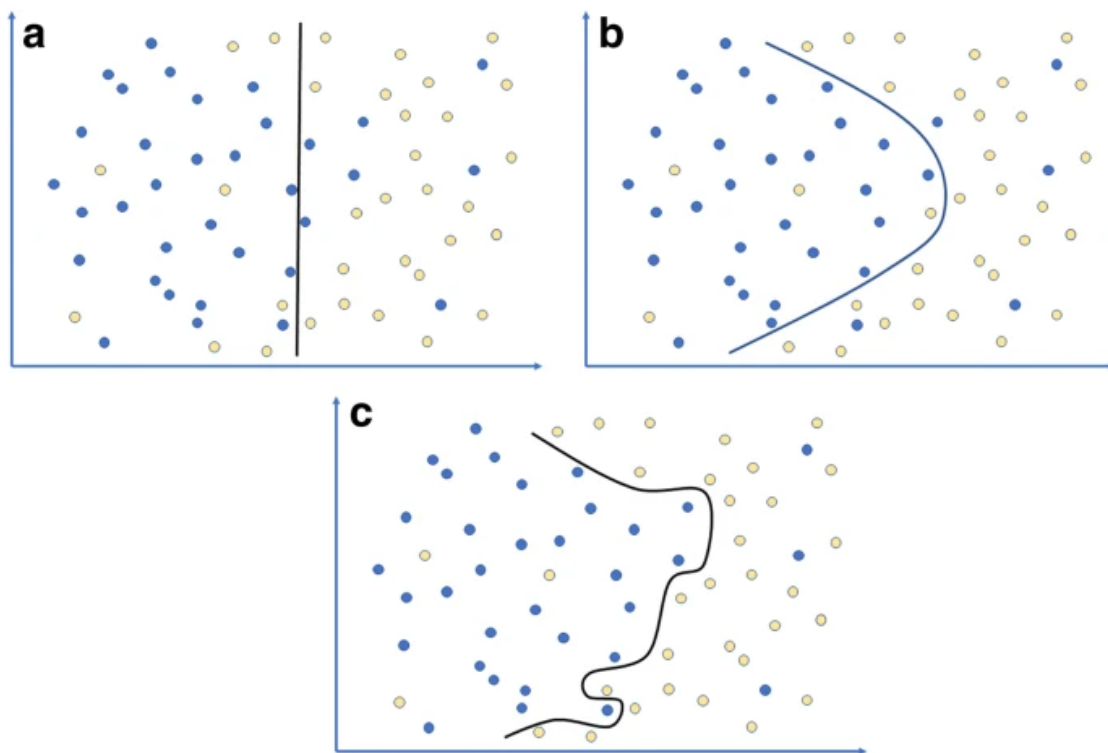
2.3 Umelá inteligencia

Umelá inteligencia sa stala veľmi dôležitým aspektom v oblasti medicínskeho zobrazovania a spôsobila revolúciu v spôsobe, akým zdravotnícki pracovníci analyzujú, interpretujú a využívajú zobrazovacie údaje. Integrácia technológií umelej inteligencie prináša významný pokrok v efektívnosti, presnosti a celkovej starostlivosti o pacientov. Umelá inteligencia pomáha pri rekonštrukcii obrazu, redukcii a vylepšovaní šumu, segmentácii a anotácii obrazu, počítačom podporovanej diagnostike, personalizovanom plánovaní liečby a optimalizácii pracovných postupov. [18, 10, 24]

Samozrejme, v tomto odvetví čelí umelá inteligencia veľa problémom. Tradičné metódy, ktoré sa spoliehajú na explicitné odborné znalosti, môžu čeliť prekážkam pri transformácii ľudských odborných znalostí do počítačových modelov, najmä ak je znalostná báza neúplná. Na riešenie tohto problému rastie záujem o iný prístup známy ako "objaviteľská veda" (inak aj ako "veda o objavovaní", angl. discovery science). Tento prístup sa zameriava na dolovanie veľkých súborov údajov s cieľom odhaliť nové vzory a formulovať hypotézy. Na rozdiel od tradičných metód prístupy discovery science neobsahujú modely a sú založené výlučne na údajoch. [24]

Jednou z rozšírených aplikácií tohto prístupu v rádiológii je analýza textúry alebo "rádiomika". V tomto kontexte sa algoritmy učia charakteristické reprezentácie vzhľadu orgánov a tkanív zo súboru trénovaných obrázkov. Ak sú trénované obrázky manuálne označené, nazýva sa to učenie pod dohľadom. Ak nie je žiadne označovanie, metódy učenia bez dohľadu automaticky zisťujú vzory v údajoch. [24, 1]

Bez ohľadu na dohľad sa tieto metódy spoliehajú na extrakciu rôznych znakov z obrazov, napríklad charakteristík textúry. Cieľom je použiť tieto vlastnosti na rozlišovanie medzi rôznymi triedami vo vysokorozmerných priestoroch vlastností. Na tento účel sa používajú rôzne štatistické techniky a techniky strojového učenia, ako napríklad logistická regresia, stroje podporných vektorov a rozhodovacie stromy. Takto vyzerá zjednodušený príklad v dvojrozmernom poli bodov: [24]

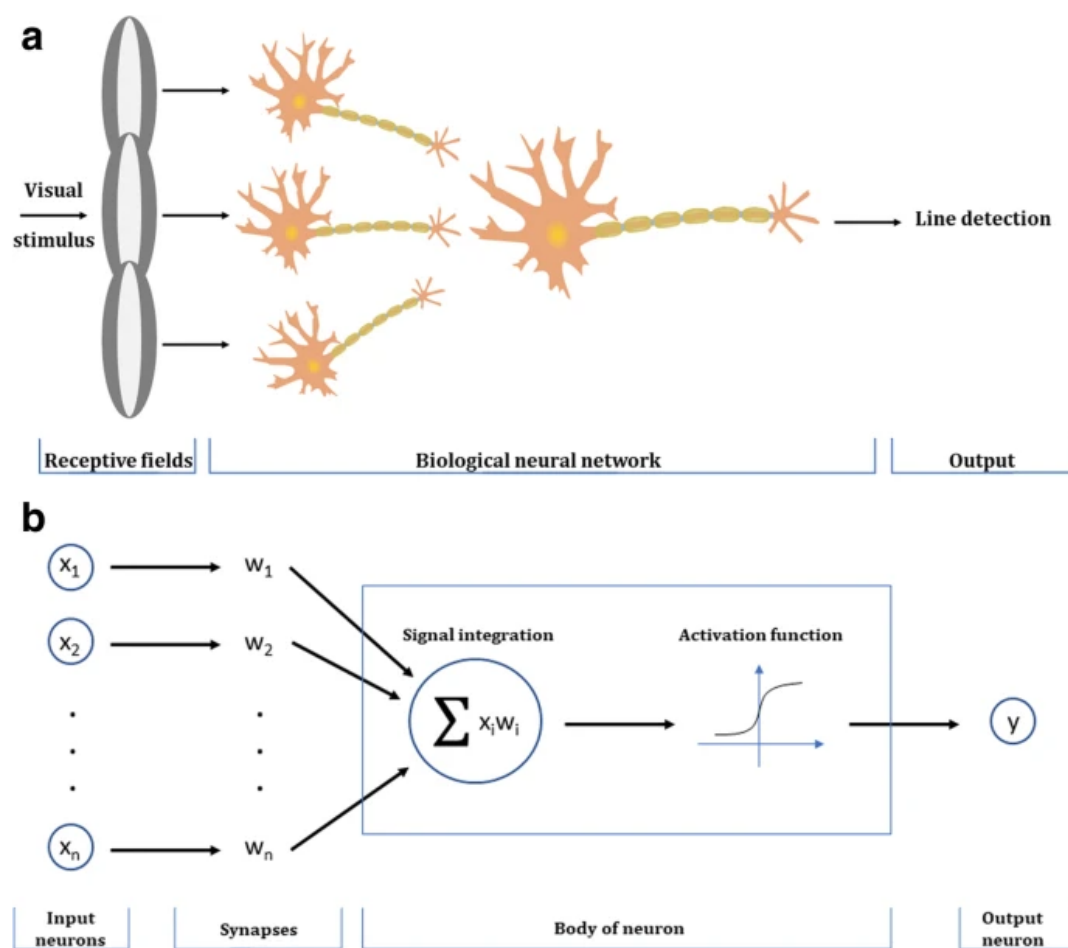


Obr. 2.5: Príklad rozhodovacích hraníc medzi dvoma skupinami dátových bodov v dvojrozmernom priestore s rastúcou zložitou od a, b až po c; a je príliš jednoduchá, zatiaľ čo c je nadmerne prispôbená [24]

2.3.1 Hlboké učenie

V rádiológii sa mnohé prístupy založené na údajoch zameriavajú na vlastnosti, ktoré odrážajú dôležité vlastnosti pozorované ľudskými rádiológmi, ako je hustota, heterogenita a tvar nádoru. Súbor metód strojového učenia, ktoré získavajú na popularite, však dokáže automaticky identifikovať najdôležitejšie vlastnosti pre konkrétnu úlohu bez ľudského zásahu do návrhu vlastností. Táto kategória metód sa nazýva hlboké učenie a preukázala schopnosť prekonať kvalitu výstupu ľudí v určitých úlohách. [24]

Systémy hlbokého učenia sú konštruované pomocou umelých neurónových sietí. Každá umelá neurónová sieť pozostáva z umelých "neurónov alebo uzlov usporiadaných do poľa. Tieto uzly prijímajú ako vstup súbor hodnôt funkcií, z ktorých každá je vynásobená príslušnou váhou. Uzol potom sčíta vážené vstupy a výsledok prechádza nelineárnou aktivačnou funkciou, ktorá určuje výstup neurónu. V podstate každý umelý neurón prijíma rozhodnutie na základe vážených dôkazov. Cieľom tohto návrhu je zjednodušiť simulovať správanie biologického neurónu, ktorý integruje vstupy zo synapsií a vysiela výstupný signál inému neurónu. [24, 17]



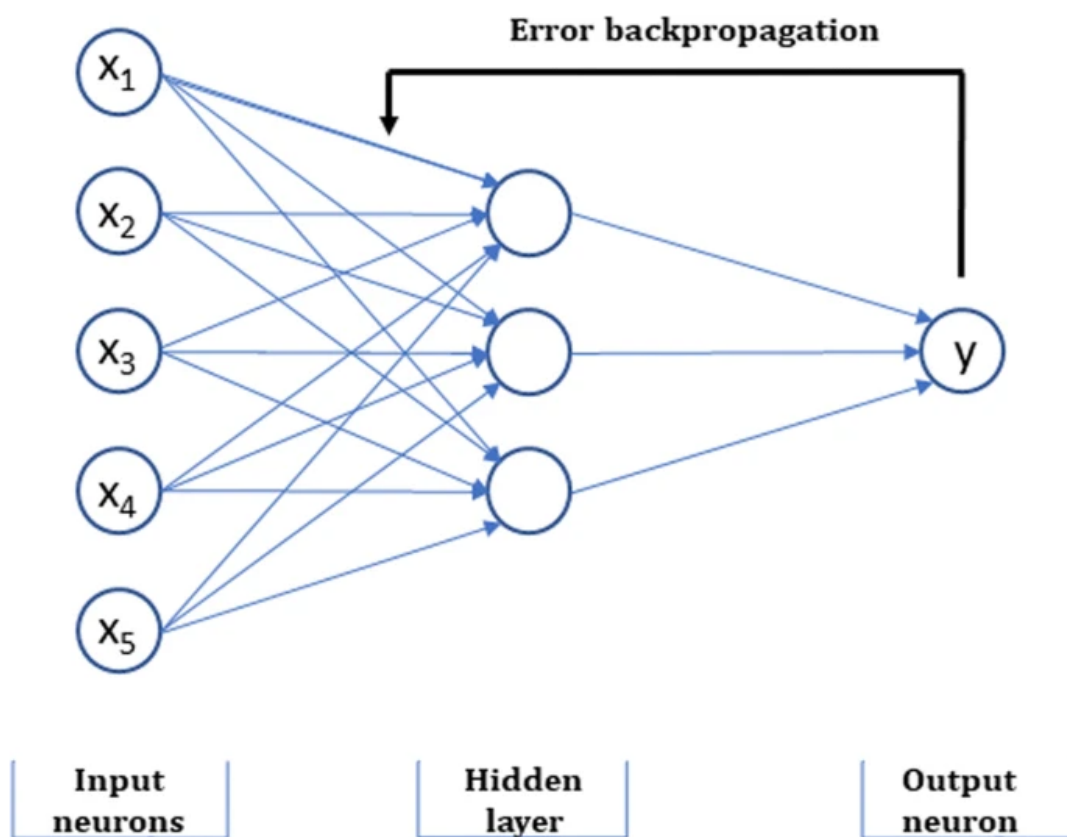
Obr. 2.6: Schematická reprezentácia jednoduchkej biologickej neurónovej siete a analógickej umelej neurónovej siete [24]

Váhy a odchýlky siete zohrávajú kľúčovú úlohu pri určovaní jej správania. Aby však bola sieť efektívna, je potrebné tieto parametre jemne doladiť prostredníctvom procesu trénovania. [24, 17]

Počas trénovania je sieť vystavená súboru vstupných údajov (napríklad obrázkov, v našom prípade jednotlivé rezy skenu) a jej aktuálna konfigurácia spracúva tieto vstupy a vytvára výstup. Tento výstup sa potom kvantitatívne porovnáva so skutočným požadovaným výstupom pomocou metriky nazývanej "stratová funkcia". Stratová funkcia v podstate meria, ako ďaleko je predikcia siete od skutočného požadovaného výsledku. [24, 17]

Teraz prichádza zaujímavá časť nazývaná spätné šírenie. Je to technika, pri ktorej sieť vyhodnocuje svoj výkon a upravuje svoje parametre tak, aby minimalizovala stratu. Predstavte si to ako proces pokusov a omylov - sieť dostáva spätnú väzbu o svojich predpovediach a upravuje svoje vnútorné nastavenia, aby sa priblížila k správnym odpovediam. Táto úprava sa vykonáva miernou úpravou každého parametra smerom, ktorý znižuje celkovú stratu. [24, 17]


Celý tento proces je iteračný. Sieť prechádza trénovanými údajmi viackrát, pričom v každej iterácii zdokonaľuje svoje parametre. Cieľom je nájsť stav, v ktorom je stratová funkcia siete minimalizovaná, čo znamená, že robí čo najpresnejšie predpovede. Je to ako učiť sieť tým, že sa jej ukazujú príklady a vedie ju to k tomu, aby krok za krokom zlepšovala svoje predpovede, až kým nebude naozaj dobrá v úlohe, ktorú je od nej vyžadovaná na vykonávanie. [24, 17]



Obr. 2.7: Schematické znázornenie umelej neurónovej siete so spätným šírením chybových signálov počas tréningového procesu [24]

2.3.2 Konvolučné neurónové siete


Chápanie obrazu zvieratami je veľmi fascinujúci proces, ktorý je pre ne veľmi jednoduchý. Ale pre stroj, ktorému chceme umožniť porozumieť obrazu, je v tomto procese veľa skrytých zložitostí. U zvierat to funguje tak, že oči zachytávajú obraz, ktorý je spracovaný neurónmi a odoslaný do mozgu na interpretáciu. Konvolučná neurónová sieť je algoritmus hlbokého učenia inšpirovaný zrkovú kôrou zvieracieho mozgu a jeho cieľom je napodobniť zrkovo-vizuálny mechanizmus zvierat. Konvolučná neurónová sieť predstavuje obrovský skok v oblasti porozumenia obrazu, ktorý zahŕňa klasifikáciu obrazu, segmentáciu, lokalizáciu, detekciu atď. Účinnosť konvulčnej neurónovej siete v oblasti porozumenia obrazu je hlavným dôvodom jej hojného využívania. Konvulčné neurónové siete sa skladajú z konvulcií, ktoré majú naučiteľné váhy a skreslenia podobné neurónom (nervovým bunkám) zvierat. Konvulčné vrstvy, aktivačné funkcie, združovanie a plne prepojené vrstvy sú základnými stavebnými prvkami konvulčnej neurónovej siete. [23]



Obr. 2.8: Stavebné bloky konvulčnej neurónovej siete [23]

2.3.2.1 Konvolučná vrstva

Zraková kôra mozgu zvierat sa skladá z neurónových buniek, ktoré extrahujú vlastnosti obrazov. Každá neurónová bunka extrahuje rôzne vlastnosti, ktoré pomáhajú pri porozumení obrazu. Konvolučná vrstva je modelovaná nad neurónovými bunkami a jej cieľom je extrahovať vlastnosti, ako sú hrany, farby, textúra a orientácia gradientu. Konvolučné vrstvy sa skladajú z učiteľných filtrov nazývaných konvolučné filtre alebo jadrá s veľkosťou $n \times m \times d$, kde premenné n a m sú dimenzie konvolučného filtra a d je hĺbka obrazu. Počas priameho prechodu sú jadrá konvolvované cez šírku a výšku vstupného objemu a vypočíta sa bodový súčin medzi vstupmi filtra a vstupom. Intuitívne sa konvolučná neurónová sieť učí filtre, ktoré sa aktivujú, keď narazia na hrany, farby, textúry atď. Výstup konvolučnej vrstvy sa privádza do vrstvy aktivačnej funkcie. [23, 15]



Obr. 2.9: Rozpoznávanie abstraktných prvkov v konvolučných neurónových sieťach [15]


2.3.2.2 Aktivačná vrstva

Aktivačná funkcia pre konvolučnú neurónovú sieť je nealineaárna, keďže údaje v reálnom svete sú väčšinou nelineárne. Aktivačné funkcie zohrávajú kľúčovú úlohu tým, že do údajov zavádzajú nelineárne transformácie. Ich účelom je zabezpečiť, aby sa reprezentácia vstupného priestoru mapovala na odlišný výstupný priestor, ktorý vyhovuje špecifickým požiadavkám modelu alebo danej úlohy. Tu sa väčšinou používa sigmoid, hyperbolický tangens a usmernená lineárna jednotka (angl. rectified linear unit, v skrate ReLU). [23, 15]

Sigmoid vezme reálne číslo x a rozdrobí ho do rozsahu medzi 0 a 1. Najmä veľké záporné a kladné vstupy sú umiestnené veľmi blízko nuly, resp. jednotke. Vyjadruje sa ako $f(x) = \frac{1}{1+e^{-x}}$. [23, 15]

Hyperbolický tangens vezme reálne číslo x a rozdrobí ho medzi -1 a 1. Vyjadruje sa ako $f(x) = \frac{1-e^{-2x}}{1+e^{-2x}}$. [23, 15]


Usmernená lineárna jednotka berie reálne číslo x a prevádza x na 0, ak je x záporné. Táto funkcia je najčastejšie používanou nelineárnou funkciou pre konvolučné neurónové siete, v porovnaní s ostatnými dvoma zaberá menej výpočtového času, a tým pádom je rýchlejšia a je vyjadrená ako $f(x) = \max(0, x)$. [23, 15]



Obr. 2.10: Bežné typy nelineárnych funkcií v konvolučných neurónových sieťach [15]

2.3.2.3 Združovacia vrstva


V konvolučnej neurónovej sieti nasleduje ďalej združovacia vrstva. Táto vrstva vykonáva nelineárne znížovanie vzorkovania konvolvovanej funkcie. Znižuje výpočtový výkon potrebný na spracovanie údajov prostredníctvom redukcie dimenzionality. Zmenšuje priestorovú veľkosť agregovaním údajov v priestore alebo typu funkcie, kontroluje nadmerné prispôbenie a prekonáva translačné a rotačné odchýlky obrazov. Výsledkom operácie združovania je rozdelenie jeho vstupu na súbor obdĺžnikových políček. Každá škvŕna sa nahradí jednou hodnotou v závislosti od zvoleného typu združovania. Existujú rôzne typy združovania a tými sú: maximálne a priemerné. [23, 15]




Obr. 2.11: Predvedenie maximálneho združovania s filtrom 2×2 a krokom 2, ktoré vedie k zníženiu vzorkovania každého bloku 2×2 na 1 blok (pixel). [15]

2.3.2.4 Plne prepojená vrstva

Táto vrstva je podobná umelej neurónovej sieti, kde každý uzol má prichádzajúce spojenia zo všetkých vstupov a všetky spojenia majú priradené váhy. Výstupom je súčet všetkých vstupov vynásobený príslušnými váhami. Hlavnou nevýhodou plne prepojených vrstiev je však značný počet parametrov, čo vedie k výpočtovo zložitému trénovaniu. Na vyriešenie tohto problému sa používajú techniky, ako je vysadzovanie, ktoré znižujú počet uzlov a spojení. Napríklad architektúry ako LeNet a AlexNet dokázali navrhnuť hlboké a široké siete a zároveň udržať výpočtovú zložitosť na zvládnuteľnej úrovni. [23, 15]



Obr. 2.12: Ukážka Lenet architektúry konvolučnej neurónovej siete [15]



Obr. 2.13: Ukážka Alexnet architektúry konvolučnej neurónovej siete [15]

2.3.3 Porozumenie medicínskym zobrazeniám

Ako už bolo spomenuté, lekárske zobrazovanie je potrebné na vizualizáciu vnútorných orgánov s cieľom odhaliť abnormality v ich anatómii alebo fungovaní. Lekárske zobrazovacie zariadenia, ako sú röntgeny, počítačová tomografia, magnetická rezonancia a ultrazvukové skenery, zachytávajú anatómiu alebo fungovanie vnútorných orgánov a prezentujú ich ako obrázky. Ako sme spomenuli v predspracovaní medicínskych zobrazeniach, obrázky musia byť zrozumiteľné na presné zistenie anomálií alebo diagnostiku funkčných abnormalít. Ak sa zistí abnormalita, musí sa určiť jej presné umiestnenie, veľkosť a tvar. Tieto úlohy tradične vykonávajú vyškolení lekári na základe svojho úsudku a skúseností. Cieľom inteligentných systémov zdravotnej starostlivosti je vykonávať tieto úlohy pomocou inteligentného porozumenia lekárskeho obrazom. Klasifikácia, segmentácia, detekcia a lokalizácia lekárskeho obrazu sú dôležité úlohy v rámci porozumenia lekárskeho obrazu. [23]

2.3.3.1 Klasifikácia medicínskych zobrazení

Klasifikácia lekárskeho snímku zahŕňa určenie a priradenie značiek lekárskeho snímku z pevne stanoveného súboru. Táto úloha zahŕňa extrakciu príznakov z obrazu a priradenie štítkov pomocou extrahovaných príznakov. Nech I označuje obrázok zložený z pixelov a c_1, c_2, \dots, c_r označujú štítky. Pre každý pixel x sa vytvorí vektor príznakov ζ pozostávajúci z hodnôt $f(x_i)$ sa extrahuje z okolia $N(x)$ pomocou $\zeta = (f(x_0), f(x_1), \dots, f(x_k))$, kde $x_i \in N(x)$ pre $i = 0, 1, \dots, k$. [23]

Značka zo zoznamu značiek c_1, c_2, \dots, c_r sa priradí k obrázku na základe ζ . [23]

2.3.3.2 Segmentácia medicínskych zobrazení

Segmentácia lekárskeho snímku pomáha pri porozumení obrazu, extrakcii a rozpoznávaní príznakov a pri kvantitatívnom hodnotení lézií alebo iných abnormalít. Poskytuje cenné informácie na analýzu patologických stavov a následne pomáha pri diagnostike a plánovaní liečby. Cieľom segmentácie je rozdeliť obraz na oblasti, ktoré majú silné korelácie. Segmentácia zahŕňa rozdelenie obrazu I na konečnú množinu oblastí R_1, R_2, \dots, R_S ako je vyjadrené v $I = \bigcup_{i=1}^S R_i$, $R_i \cap R_j = \emptyset$ and $i \neq j$. [23]

2.3.3.3 Lokalizácia medicínskych zobrazení

Automatická lokalizácia patológie na snímkach je dôležitým krokom k automatickému plánovaniu akvizície a úlohám následnej analýzy snímok, ako je segmentácia a funkčná analýza. Lokalizácia zahŕňa predpovedanie objektu na snímke, nakreslenie ohraničujúceho poľa okolo objektu a označenie objektu.

Lokalizačná funkcia $f(I)$ na obraze I vypočíta c, l_x, l_y, l_w, l_h , ktoré predstavujú označenie triedy, súradnice centroidu x a y a podiel ohraničujúceho boxu vzhľadom na šírku a výšku obrazu, ako je vyjadrené v $f(I) = (c, l_x, l_y, l_w, l_h)$. [23]

2.3.3.4 Detekcia v medicínskych zobrazeniach

Detekcia obrazu je zameraná na klasifikáciu a lokalizáciu oblastí záujmu nakreslením ohraničujúcich boxov okolo viacerých oblastí záujmu a ich označením. To pomáha určiť presné umiestnenie rôznych orgánov a ich orientáciu. Nech I je obrázok s n objektmi alebo oblasťami záujmu. Potom detekčná funkcia $D(I)$ vypočíta c_i, x_i, y_i, w_i, h_i a to sú v uvedenom poradí označenie triedy, súradnice centroidu x a y , podiel ohraničujúceho boxu vzhľadom na šírku a výšku obrazu I , ako je uvedené v $\bigcup_{i=1}^n c_i, x_i, y_i, w_i, h_i = D(I)$. [23]

2.3.4 Aplikácie konvolučných neurónových sietí v segmentácii medicínskych obrazov

Konvolučné neurónové siete by boli použité na implementáciu účinnej segmentácie obrazov mozgu, srdca, prsníkov, sietnice, pľúc, pečene, tenkého čreva, hrubého čreva, stromálnych a epitelových tkanív, a podobne. Práca prejde pár riešení a optimálne riešenie je nájsť čo najširšie, najrobustnejšie riešenie, keďže je potrebné segmentovať všetky orgány v medicínskom zobrazení.

2.3.4.1 Viaccestná a viacškálová konvolučná neurónová sieť

V prípade segmentácie mozgových nádorov bola v práci [34] navrhnutá viacškálová architektúra konvulčnej neurónovej siete na extrakciu lokálnych aj globálnych znakov v rôznych mierkach. Model dosahoval lepšie výsledky vďaka rôznym príznakom extrahovaným v rôznom rozlíšení. Výpočtový čas sa znížil využitím dvojrozmernej konvulčnej neurónovej siete namiesto trojrozmernej konvulčnej neurónovej siete. Tri veľkosti políčok $48 * 48$, $28 * 28$ a $12 * 12$ boli vstupom pre tri konvulčné neurónové siete na extrakciu príznakov. Všetky extrahované príznaky boli vložené do vrstvy FC. Hodnotenie modelu sa uskutočnilo pomocou DSC a presnosti. Výkon modelu bol takmer rovnako stabilný ako najlepšia metóda s presnosťou takmer 90%. [23]

2.3.4.2 Konvulčná neurónová sieť založená na záplatách

Rakovina prsníka sa dá predpovedať automatickou segmentáciou hustoty prsníka a charakterizovaním mamografických texturálnych vzorov. Výhody konvulčnej neurónovej siete založenej na záplatách boli využité v [33]. Metóda využívala aj metódu superpixelov na nadmerné segmentovanie H&E obrazov rakoviny prsníka na atómové obrazy. Výsledkom boli prirodzené hranice, pričom chyby boli jemné

a menej výrazné, zatiaľ čo metódy posuvných okien mali za následok kľukaté hranice. Na segmentáciu a klasifikáciu stromálnych a epitelových oblastí v histopatologických obrazoch na detekciu rakoviny prsníka a hrubého čreva sa kombinovali techniky konvolučnej neurónovej siete založené na záplatách aj superpixelové techniky. Navrhnutý model prekonal CNN s podporným vektorovým strojom (angl. support vector machine, ďalej ako SVM). Porovnanie sa uskutočnilo s metódami využívajúcimi ručne vytvorené príznaky. Dosiahol presnosť 100% a CNN-Ncut-SVM s hlbokým učením mal lepšiu plochu pod krivkou ako ostatné konvolučné neurónové siete. [23]

2.3.4.3 Odvodzovanie viacerých značiek v konvolučnej neurónovej sieti

Segmentácia sietnicových ciev bola v práci [3] riešená ako viacznačkový inferenčný problém a riešená pomocou konvolučnej neurónovej siete. Model extrahoval zelený kanál z obrazu RGB fundu, keďže cievy vykazujú vysoký kontrast v zelenom kanáli. Model bol v šiestej vrstve prevzorkovaný, aby sa zvýšila priestorová dimenzia pre štruktúrovaný výstup. Výstup modelu konvolučnej neurónovej siete bol modelovaný ako vektor namiesto skaláru kvôli viacnásobným značkám. Dosiahol presnosť 84.98%, citlivosť 76.91%, špecifickosť 98.01%, presnosť 95.33%, a plochu pod krivkou 97.44%. [23]

2.3.4.4 U-Net

Segmentácia pľúc a techniky vylúčenia kostných tieňov na analýzu rakoviny pľúc pomocou architektúry U-net sú navrhnuté v [9]. Snímky boli predspracované na odstránenie kostného tieňa a na segmentáciu pľúcneho ROI sa použila jednoduchá architektúra U-net. Získané výsledky boli veľmi sľubné a ukázali dobrú rýchlosť a presnú segmentáciu. [23]

2.3.4.5 TotalSegmentator

Predstavuje model segmentácie pomocou hlbokého učenia, ktorý dokáže automaticky a robustne segmentovať všetky hlavné anatomické štruktúry na medicínskych snímkach počítačovej tomografie. V tejto retrospektívnej štúdii bolo 1204 vyšetrení počítačovej tomografie (z rokov 2012, 2016 a 2020) použitých na segmentáciu 104 anatomických štruktúr (27 orgánov, 59 kostí, 10 svalov a 8 ciev), ktoré sú relevantné pre prípady použitia, ako je volumetria orgánov, charakterizácia ochorenia a plánovanie chirurgickej terapie alebo rádioterapie. Snímky z počítačovej tomografie boli náhodne vybrané z rutinných klinických štúdií, a preto predstavujú súbor údajov z reálneho sveta (rôzne vekové kategórie, abnormality, skenery, časti tela, sekvencie a miesta). Autori na tomto súbore údajov natrénovali segmentačný algoritmus na modeli konvolučnej neurónovej siete U-Net a vypočítali koeficienty podobnosti na vyhodnotenie výkonnosti modelu. Natrénovaný algoritmus bol aplikovaný na druhý súbor údajov 4004 celotelových vyšetrení počítačovej tomografie s cieľom preskúmať zmeny objemu a zoslabenia v závislosti od veku. Navrhnutý model vykazoval vysoké skóre Dice 94,3% na testovacom súbore, ktorý zahŕňal širokú škálu klinických údajov s veľkými abnormalitami. Model významne prekonal iný verejne dostupný segmentačný model na samostatnom súbore údajov (skóre Dice, 93,2% oproti 87,1%; $P < 0,001$). Vyvinutý model umožňuje robustnú a presnú segmentáciu 104 anatomických štruktúr. Anotovaný súbor údajov [30] a súbor nástrojov [31] sú verejne dostupné. [32]

2.3.5 Zhodnotenie aplikácií konvolučných neurónových sietí v segmentácii medicínskych obrazov

Táto oblasť je v neustálom vývoji a je veľa rôznych modelov konvolučných neurónových sietí alebo aj iných modelov neurónových sietí, ktoré tento problém riešia.

Spomenuté modely v čase ich vytvorenia riešili iba špecifický problém, zameriavali sa iba na jednu vec. Pre úspešné vyriešenie problému je potrebné mať model, ktorý sa zameriava na segmentáciu čo najviac významných štruktúr v tele a nie len na jednu štruktúru. Drvivá väčšina takýchto algoritmov sa zameriava iba takýmto spôsobom a kombinovať rôzne riešenia je časovo veľmi náročné.

Spomenuté riešenia vedia vyriešiť iba frakciu daného problému a preto je najlepšou možnosťou pre úspešné vypracovanie projektu TotalSegmentator ([32]), ktorý vie rozsegmentovať tie najvýznamnejšie štruktúry ľudskej anatómie v medicínskych zobrazeniach počítačovej tomografie, čo je presne potrebné na túto prácu, keďže treba určovať kde sú dané miesta v medicínskom zobrazení, ktoré označil rádiológ.

2.4 Počítačová grafika

Táto práca sa bude predovšetkým zameriavať trojrozmernou (3D) grafikou s dôrazom na tvorbu 3D modelov. Napriek tomuto zameraniu je výsledkom väčšiny projektov počítačovej grafiky dvojrozmerný (2D) obraz. Pochopenie a priama manipulácia s 2D obrazmi je kľúčová a vytvára základ pre 3D grafiku. Projekt sa ďalej zameriava aj na zobrazovanie medicínskych zobrazení v 2D grafických reprezentáciach a interakciu s nimi, čiže pochopenie dvojrozmerných zobrazení je kľúčové.

2.4.1 Úvod do počítačovej grafiky

Počítačové obrazovky zobrazujú obrázky pomocou pixelov usporiadaných do mriežky. Pixely, hoci sú malé a na displejoch s vysokým rozlíšením často neviditeľné, sú základnými zložkami. Obrazovky zvyčajne používajú 24-bitové farby, pričom každý pixel je špecifikovaný tromi 8-bitovými číslami, ktoré predstavujú červenú, zelenú a modrú úroveň. Alternatívou sú formáty odtieňov sivej a indexované farby. [5, 6]

2.4.2 Rastrová grafika

Základným modelom obrazovky je rastrová grafika, pri ktorej sa s pixelmi manipuluje vo vyrovnávacej pamäti. V minulosti sa pri rastrových zobrazeniach používali elektrónové lúče, ale moderné monitory s plochou obrazovkou sa líšia svojím mechanizmom. Napriek týmto zmenám definuje rastrovú grafiku koncepcia obrazov zložených z pixelových mriežok. [5, 6]

2.4.3 Vektorová grafika

Alternatívou je vektorová grafika, ktorá reprezentuje obrázky ako geometrické tvary, napríklad čiary a kruhy, a ponúka atribúty, ako je hrúbka čiary alebo farba výplne. Vektorová grafika, ktorá sa v minulosti používala priamo na obrazovkách, vyžaduje v porovnaní s rastrovou grafikou menej informácií na reprezentáciu obrázkov s jednoduchými geometrickými tvarmi. [5, 6]

2.4.4 Rozdiely medzi vektorovou a rastrovou grafikou

Rozdelenie medzi rastrovou a vektorovou grafikou pretrváva v softvéri na tvorbu obrázkov, pričom sa rozlišuje medzi programami na maľovanie a kreslenie. Príkladom tohto rozdelenia sú najmä programy Adobe Photoshop a Illustrator. [5]

Z hľadiska formátov súborov sú GIF, PNG, JPEG a WebP rastrové formáty, zatiaľ čo SVG je vektorový grafický formát. Metódy kompresie sa líšia; GIF a PNG používajú bezstratovú kompresiu, JPEG používa stratovú kompresiu a WebP podporuje obidve. SVG, ktorý je škálovateľný a vhodný pre webové prehliadače, využíva vektorovú grafiku. [5]

Obrázky, bez ohľadu na formát, sú špecifikované pomocou súradnicového systému. Rastrové obrázky sa zarovnávajú so systémom založeným na mriežke, zatiaľ čo vektorové obrázky prirodzene používajú súradnice v reálnych číslach. [5, 6] V projekte sa budeme venovať iba rastrovej grafike pre vykresľovanie a spracovávanie medicínskych zobrazení, keďže aj oni fungujú na rastrovej grafike.


2.4.5 Dvojrozmerná grafika

Generovanie 2D obrazu zahŕňa priradenie farieb jednotlivým bodom, z ktorých každý je identifikovaný číselnou dvojicou súradníc. Hoci pre body aj farby exis-

tujú číselné špecifikácie, tieto priradenia sú do určitej miery ľubovoľné. Preto je potrebné dôkladne preskúmať súradnicové systémy, ktoré spájajú čísla s bodmi, a farebné modely, ktoré spájajú čísla s farbami. [5, 6]

2.4.5.1 Pixelová mriežka

Digitálny obraz pozostáva z pixelov usporiadaných do riadkov a stĺpcov. Je dôležité poukázať, že pixel je vzorka, nie políčko. Každý pixel je identifikovaný dvojicou celých čísel, ktoré predstavujú jeho stĺpec a riadok. Napríklad súradnice (3,5) označujú pixel v treťom stĺpci a piatom riadku. Zvyčajne sú stĺpce číslované zľava doprava, počnúc nulou, zatiaľ čo riadky sú číslované zhora nadol, tiež počnúc nulou. [5]




Obr. 2.14: Ukážka pixelovej mriežky a vyznačenie pixelu na súradniciach (3,5) [5]

2.4.5.2 Farebné modely

V počítačovej grafike je farba základným aspektom a bežne sa používa farebný model RGB. V tomto modeli sa farby na obrazovke vytvárajú kombináciou červeného, zeleného a modrého svetla s rôznou intenzitou. Každá farba je špecifikovaná tromi číslami reprezentujúcimi intenzitu každej zložky v rozsahu od 0 (minimum) po 1 (maximum). Model RGB využíva 8 bitov na zložku, spolu 24 bitov pre farbu. [5, 6]

Hoci je RGB široko používaný, má určité obmedzenia vzhľadom na reakciu ľudského oka na široký rozsah vlnových dĺžok. Farebný gamut, ktorý predstavuje rozsah farieb, ktoré môže zariadenie produkovať, sa medzi zariadeniami, ako sú obrazovky a tlačiarne, líši. Napríklad tlačiarne často používajú farebný model CMYK. [5]

Iné farebné modely, ako napríklad HSV a HSL, majú za cieľ poskytnúť intuitívnejšiu reprezentáciu. HSV označuje odtieň, sýtosť a hodnotu, zatiaľ čo HSL nahrádza hodnotu svetlosťou. Pridanie zložky alfa v modeloch ako RGBA zavádza kontrolu priehľadnosti. Hodnota alfa 1 znamená úplnú nepriehľadnosť, zatiaľ čo 0 znamená úplnú priehľadnosť. Prelínanie alfa je bežná technika, pri ktorej sa farby popredia a pozadia kombinujú na základe ich hodnôt alfa. [5]



Obr. 2.15: Ukážka CMY a RGB farebných modelov [6]

2.4.6 Trojrozmerná grafika

V projekte bude využívaná 3D grafika iba na vykreslenie 3D avatara a vykresľovanie jednotlivých bodov v avatarovi, ktoré rádiológ vyznačí v medicínskom zobrazení/skene. Na vykreslenie týchto zobrazení je potrebné pochopiť, ako sa v počítačovej grafike niečo také vykresľuje a preto je potrebné zdefinovať si, že čo je to polygón v počítačovej grafike, ako sa taký polygón vykresľuje a vyfarbuje, ďalej ako tieto grafické zobrazenia posúvať, rotovať a škálovať.

2.4.7 Kreslenie čiar

Keď sa hovorí o "priamke", označuje sa tým úsečka - priama spojnica medzi dvoma bodmi v rovine. Najzákladnejšou formou je úsečka so šírkou jedného pixelu bez vyhladzovania, ktorá sa dosiahne vyfarbením pixelov pozdĺž geometrickej úsečky. [5]

Čiary však môžu byť zložitejšie. Komplikácie prináša vyhladzovanie a šírka čiary. Široká čiara môže byť reprezentovaná ako obdĺžnik. Čiary môžu mať ďalšie atribúty ovplyvňujúce ich vzhľad. Napríklad určenie konca širokej čiary vyvoláva otázky, či zahrnúť zaoblenú "čiapočku" alebo štvorcovú čiapočku, ktorá predlžuje čiaru o polovicu šírky čiary. [5]

Keď sa dve čiary pretínajú ako súčasť väčšieho útvaru, vznikajú úvahy o tom, ako by mali byť čiary spojené. Grafické systémy často podporujú čiary s rôznymi atribútmi, ako sú napríklad vzory čiar a bodiek. [5]


Stručne povedané, základné tvary, ako sú čiary, slúžia ako základné stavebné kamene v grafických rozhraniach, ktoré poskytujú jednoduchosť pomocou jedno-

duchých príkazov a zároveň zohľadňujú zložitosť pomocou premyslených úvah o vzhľade a atribútoch. [5]

2.4.7.1 Vyfarbovanie a zvýrazňovanie tvarov

Tvary na výkrese možno zviditeľniť dvoma spôsobmi: zvýraznením alebo vyplnením. Zvýraznenie zahŕňa obkreslenie tvaru, podobne ako ťahanie pera po jeho okraji. V prípade uzavretých tvarov, ako sú obdĺžniky alebo ovály, sa vyplnením vyfarbia všetky body vo vnútri tvaru. Tvar je možné obťahovať aj vyplňať, čo umožňuje odlišný vzhľad vnútra a obrysu. [5]

Keď tvar pretína sám seba, určenie vnútra sa stáva nejednoznačným. Riešia to dve pravidlá výplne, ktoré vychádzajú z čísla vinutia. Číslo navíjania okolo bodu znamená, koľkokrát sa tvar okolo neho navíja, pričom kladné číslo znamená navíjanie proti smeru hodinových ručičiek a záporné naopak. Na obrázku ľavé tvary znázorňujú čísla vinutia, vyplnené pomocou pravidiel založených na nenulovom a nepárnom čísle vinutia. [5]




Obr. 2.16: Ukážky vyfarbovacieho algoritmu [5]

Metódy ťahania a vyplňovania poskytujú flexibilitu pri vizualizácii tvarov v počítačovej grafike. Voľba medzi ťahom a výplňou, ako aj obsah výplne umožňujú v grafike celý rad kreatívnych možností. [5]

2.4.7.2 Definícia polygónov

V grafickom programovaní je nepraktické, aby grafické rozhranie obsahovalo všetky možné tvary ako základné prvky. Namiesto toho existujú metódy na vytváranie zložitejších tvarov, napríklad polygónov. Polygón je uzavretý tvar definovaný postupnosťou spojených úsečiek, ktorých vrcholy predstavujú koncové body. Pravidelné mnohouholníky majú rovnaké strany a uhly, zatiaľ čo vypuklé mnohouholníky nemajú na svojich hraniciach zárezy. [5]

Vytváranie a kreslenie mnohouholníkov sa dá dosiahnuť pomocou príkazov na ťahanie a vyplňovanie, pričom vrcholy sa zadávajú buď ako súradnicové polia, alebo ako samostatné polia súradníc. Klasicky sa zložité telesá v grafike vykresľujú prostredníctvom mnoho drobných polygónov, ktoré tento objekt zobrazujú. [5]



Obr. 2.17: Ukážka objektov zoskladaných z polygónov [5]

2.4.7.3 Translácia obrazu


Translačná transformácia v grafike zahŕňa posunutie každého bodu horizontálne a vertikálne o určené hodnoty. [5] Ak (x_0, y_0) predstavuje pôvodný bod a (x_1, y_1) transformovaný bod, translačný vzorec je daný:

$$x_1 = x_0 + e$$

$$y_1 = y_0 + f$$

Tu je horizontálny posun a f je vertikálny posun. Bežne grafický systém poskytuje funkciu ako $translate(e, f)$ na aplikáciu translačnej transformácie. Tento príkaz ovplyvňuje všetky nasledujúce kresliace operácie, pričom k súradniciam x pridáva e a k súradniciam y pridáva f . [5]

Ak napríklad sa použije písmeno "F" so stredom v bode $(0, 0)$ a použije sa $translate(4, 2)$ pred kreslením, každý bod písmena "F" sa posunie horizontálne o 4 jednotky a vertikálne o 2 jednotky. Výsledné "F" je teraz vycentrované na $(4, 2)$. [5]



Obr. 2.18: Ukážka translačnej transformácie v smere e a f [5]

Translácia ovplyvňuje všetky nasledujúce kresby, nielen bezprostredný tvar. Ak sa neskôr použije iná transformácia, skombinuje sa s transláciou, a nenahradí ju. Napríklad kombinácia translácie $translate(4, 2)$ s transláciou $translate(-1, 5)$ je ekvivalentná jednej translácii $translate(3, 7)$. [5]


2.4.7.4 Rotácia obrazu

Rotačná transformácia otáča každý bod okolo počiatku $(0, 0)$ o zadaný uhol v stupňoch alebo radiánoch. Uhol rotácie určuje rozsah rotácie a kladné uhly otáčajú objekty proti smeru hodinových ručičiek v súradnicovom systéme s osou y smerujúcou nahor. V pixelových súradniciach, kde os y smeruje nadol, je toto otáčanie v smere hodinových ručičiek. [5] Otočenie bodu (x, y) o uhol r je matematicky definované takto:

$$x_1 = \cos(r) * x - \sin(r) * y$$

$$y_1 = \sin(r) * x + \cos(r) * y$$

Pre afinnú transformáciu to znamená $e = f = 0, a = d = \cos(r), b = -\sin(r)$ a $c = \sin(r)$. [5] Aplikácia rotácie na bod je znázornená na nasledujúcom obrázku pre rotáciu o -135 stupňov:



Obr. 2.19: Ukážka rotačnej transformácie o 135 stupňov [5]


Pôvodný tvar "F" je znázornený svetlosivou farbou a výsledný tvar po otočení je znázornený tmavočervenou farbou. Šípka označuje posun ľavého horného rohu pôvodného "F" v dôsledku rotácie.

Grafické rozhranie zvyčajne poskytuje príkaz ako napr. *rotate(r)* na vykonanie rotácie. Tento príkaz sa použije pred kreslením objektov podliehajúcich rotácii. [5]

2.4.7.5 Škálovanie obrazu

Škálovacia transformácia mení veľkosť objektov vynásobením každej súradnice x a y špecifickými faktormi. [5] Pre bod (x_0, y_0) zväčšený koeficientmi a v smere x a d v smere y je transformovaný bod (x_1, y_1) daný: $x_1 = a * x_0$, $y_1 = d * y_0$.

Pri aplikácii na útvar so stredom v počiatku určujú faktory mierky horizontálne a vertikálne rozťahnutie alebo zmenšenie. Rovnomerné škálovanie, pri ktorom sú oba faktory rovnaké, zachováva tvar bez deformácie. Tu je príklad, v ktorom je pôvodný svetlosivý "F" rovnomerne zmenšený faktorom 3 horizontálne a 2 vertikálne, čím vznikne tmavočervený "F": [5]



Obr. 2.20: Ukážka škálovacej transformácie faktorom (3, 2) [5]

Ak tvar nie je vycentrovaný na $(0, 0)$, škálovanie ovplyvní aj jeho polohu. Škálovanie je v podstate transformácia, ktorá buď posúva body smerom od počiatku $(0, 0)$, alebo ich k nemu priťahuje. Na škálovanie okolo iného bodu možno použiť postupnosť troch transformácií, podobne ako pri rotáciách. [5]

Grafické rozhranie zvyčajne poskytuje funkciu ako $scale(a, d)$ na použitie škálovacích transformácií. Transformácia ovplyvňuje všetky následné súradnice x a y pri operáciách kreslenia. [5]

Povolené sú záporné faktory škálovania, čo vedie k odrazu tvaru spolu s roztiahnutím alebo zmenšením. Napríklad $scale(1, -1)$ odráža objekty vertikálne cez os x . [5]

Stojí za zmienku, že akúkoľvek afinnú transformáciu vrátane škálovania, rotácií a translácií možno vytvoriť kombináciou translácií, rotácií okolo počiatku a škálovaní okolo počiatku. [5]

Okrem toho transformácie vytvorené len z translácií a rotácií bez škálovania zachovávajú dĺžky a uhly v objektoch, ktoré transformujú, čo z nich robí "euklidovské" transformácie. Keď sa zavedie rovnomerné škálovanie, uhly a pomery strán sa zachovávajú, ale nie dĺžky. [5]

2.4.7.6 Import a export modelov

Je veľa formátov súborov, ktoré umožňujú uloženie rôzne umiestnenia polygónov, resp. ich vrcholov, hrán, plôch a súradnice textúr, ktoré tvoria nejaký model (tvar, či už jednoduchý alebo zložitý, napr. palma). Tieto údaje majú rôzne spôsoby ukladania, čiže vznikajú rôzne formáty súborov v akých vedľa byť uložené. Najznámejšie sú OBJ, FBX, STL, glTF. Ak je potrebné mať jednoduchý, široko pod-

porovaný formát pre statické modely, OBJ je dobrá voľba. Pre komplexné scény, animácie a interoperabilitu s nástrojmi Autodesk je FBX robustnou voľbou. Ak sa zameriavate na 3D tlač alebo pracujete len s geometriou, vhodný je formát STL. Pre moderné aplikácie v reálnom čase, najmä webové, získava na popularite glTF vďaka svojim vlastnostiam a efektívnosti. Keďže v projekte je potrebné narábať iba so statickými modelami, tak bude použitý OBJ formát. [16]

2.4.8 Grafické rámce

Pri porovnávaní viacerých grafických rozhraniach je potrebné zvážiť ich vlastnosti, možnosti a prípady použitia. Táto práca poskytne porovnanie OpenGL, DirectX a Vulkan, čo sú tri široko používané grafické rámce. [25]

2.4.8.1 OpenGL

Tento rámec je nezávislý od platformy a funguje v rôznych operačných systémoch vrátane Windows, MacOS, Linux a ďalších. Kompatibilita medzi platformami môže niekedy viesť k rozdielom vo výkone a funkciách. OpenGL má jednoduché rozhranie API, vďaka čomu je prístupné pre vývojárov. Má veľkú komunitu a rozsiahlu dokumentáciu. Niektorí vývojári považujú dizajn API za menej moderný v porovnaní s novšími alternatívami. Historicky je široko rozšírené, najmä v hernom priemysle. V posledných rokoch získavajú popularitu aj iné novšie API od tohto rámca. [25]

2.4.8.2 DirectX

Používa sa predovšetkým na platformách Windows a ponúka hlbokú integráciu s technológiami Microsoft. Má obmedzenú podporu vo viacerých platformách, čiže nie je natívne podporovaná v systémoch iných ako Windows. DirectX často ťaží z úzkej integrácie so systémom Windows a je optimalizovaný na hranie hier v sys-

téme Windows. Špecifická povaha pre jednotlivé platformy môže obmedzovať jeho dosah. DirectX ponúka komplexný súbor multimediálnych API vrátane Direct3D pre grafiku, DirectSound pre zvuk atď. Je úzko spätý s ekosystémom Windows. [25]

2.4.8.3 Vulkan

Tento rámec je navrhnutý na multiplatformové použitie a podporuje systémy Windows, Linux a ďalšie. Krivka učenia môže byť strmšia kvôli explicitnému ovládaniu a zvýšenej zložitosti. Vulkan poskytuje lepšiu kontrolu výkonu tým, že vývojárom poskytuje explicitnejšiu kontrolu nad grafickou kartou. Väčšia zložitosť môže spôsobiť, že bude menej vhodný pre začiatočníkov. Vulkan poskytuje viac nízkoúrovňovej kontroly nad zdrojmi grafickej karty, čo umožňuje efektívnu optimalizáciu. Táto nízkoúrovňová kontrola môže spôsobiť, že vývoj bude pre začiatočníkov náročnejší. [25]

2.4.9 Zhodnotenie grafických rámcov

Výber medzi týmito grafickými rámcami závisí od faktorov, ako sú požiadavky na platformu, odborné znalosti vývojára, ciele projektu a podobne. Často sa rozhoduje na základe špecifických potrieb daných aplikácií a platforiem, na ktoré sa vývojár zameriava. Tento projekt bude realizovaný pomocou rámca OpenGL, keďže je navrhnutý na multiplatformové použitie a podporuje systémy Windows, Linux, MacOS a ďalšie, čo pridáva na flexibilitu riešenia. Zároveň je viac vhodný pre začiatočníkov kvôli dlhému pôsobeniu tohto rámca, veľkej komunite a extenzívnej dokumentácii. Zároveň má tiež pomerne jednoduché rozhranie API, čo značne uľahčuje vývoj tejto práce.

2.5 Prenášanie označení z medicínskeho zobrazovania do 3D avatara

Na prenášanie označení z medicínskeho zobrazovania do 3D avatara je potrebné pre rádiológa vyhotoviť grafické používateľské rozhranie, pomocou ktorého by sa mu otvoril daný sken a vedel by si prechádzať jednotlivé vrstvy skenu a značiť si nálezy. Následne je potrebný špeciálny algoritmus, ktorý by tieto lokácie týchto nálezov ukladal a prenášal by ich na vykresleného 3D avatara v priestore.

2.5.1 Používateľské grafické rozhranie

V programovacom jazyku Python je veľa rámcov, ktoré umožňujú vyhotovenie grafického používateľského rozhrania a je potrebné zohľadniť ich vlastnosti pri výbere z týchto rámcov na úspešné vyriešenie tohto problému, keďže každý jeden má svoje výhody a nevýhody, ktoré musia byť zohľadnené a zvážené. Táto práca poskytne porovnanie rámcov Tkinter, PyQt a wxPython, čo sú tri široko používané rámce grafického používateľského rozhrania.

2.5.1.1 Tkinter

Tkinter je štandardná sada nástrojov grafického používateľského rozhrania, ktorá je súčasťou jazyka Python. Je široko používaný a ľahko sa učí, takže je vhodný aj pre začiatočníkov. Výhodou je, že je súčasťou jazyka Python a nie je potrebné ho dodatočne inštalovať. Je jednoduchý a ľahko použiteľný a práve preto je vhodný pre malé až stredne veľké aplikácie. Menej bohatý na funkcie v porovnaní s niektorými inými rámcami. Predvolený vzhľad sa môže zdať zastaraný. [21]

2.5.1.2 PyQt

PyQt je súbor väzieb jazyka Python pre knižnice Qt. Je to výkonný a komplexný rámec používaný na vývoj komplexných aplikácií. Je bohatý na funkcie a výkonný. Má moderný vzhľad a ovládanie. Podporuje bezplatné aj komerčné projekty. Vyžaduje inštaláciu, pretože nie je súčasťou štandardnej knižnice Pythonu. Nevýhodou je licencovanie na komerčné použitie. Rámec je dobre zdokumentovaný. [21]

2.5.1.3 wxPython

wxPython je súbor väzieb jazyka Python pre knižnicu wxWidgets z jazyka C++. Poskytuje natívne vyzerajúce aplikácie grafického rozhrania na rôznych platformách. Má natívny vzhľad a ovládanie na rôznych operačných systémoch. Má rozsiahlu sadu widgetov a má otvorený zdrojový kód. Dokumentácia môže byť pre začiatočníkov náročná. [21]

2.5.2 Zhodnotenie rámcov grafických používateľských rozhraní

Začiatočníci môžu považovať Tkinter za dobrý štartovací bod, keďže je jednoduchší, ale nevýhodou je zastaralý vzhľad a je menej bohatý na funkcie. Pre väčšie aplikácie je potrebné uprednostniť funkčne bohatý PyQt alebo wxPython. Pri výbere medzi týmito rámcami je dôležité zohľadniť dokumentácie, ktoré sú kľúčové na správne narábanie s knižnicami a plynulé implementovanie problému. Na báze tohto úsudku sa bude v práci využívať PyQt rámec, keďže je wxPython má náročnú dokumentáciu.

2.5.3 Algoritmus na prenášanie označení z medicínskeho zobrazenia do 3D avatara

Vyriešenie takéhoto problému je veľmi zložitá a je potrebné si podrobne prejsť, že čo treba spraviť, čo sa bude diať, ako sa to bude diať a rozdrobiť si to na menšie problémy. V práci sa použije metóda založená na voxeloch spomenutá v [7]. Okrem tejto metódy boli spomínané ešte ďalšie dve metódy a to metóda na základe orientačných bodov a metóda na základe povrchu, avšak tieto metódy nedostatočne súviseli so zadaním a voxelová metóda bola na tento problém najviac vhodná.

Je potrebné zarovnať alebo mapovať body z jedného súradnicového systému (rez skenu reprezentovaný pomocou 2D obrázka) do iného (3D model avatara). V tomto prípade je potrebné mať súradnice orgánov v medicínskom zobrazení a aj na 3D modeli avatara a treba odhadnúť polohu značiek, ktoré rádiológ zakreslil do rezu daného skenu. V tom prichádza voxelová metóda [7], keďže medicínske zobrazenie je reprezentované trojrozmernou dátovou štruktúrou (obrázky naskladané na sebe, čiže trojrozmerné pole) a taktiež 3D avatara je možné rozsekať do 3D mriežky, z čoho by vznikla voxelová reprezentácia 3D avatara. Keďže v skene a aj v 3D avatarovi máme záchytné body (orgány), tak touto metódou je možné odhadovať rádiológom vyznačené body v skene do 3D avatara.

Kapitola 3

Návrh

Ako už bolo spomenuté, toto je veľmi náročný problém a musíme zohľadniť, premyslieť a implementovať veľa vecí, ktoré nám poskytnú finálnu aplikáciu. Na začiatok začneme s 3D priestorom a avatarom reprezentujúcim ľudskú anatómiu. Ďalej prejdeme na narábanie s medicínskymi zobrazeniami, segmentáciu orgánov, interakciu so skenmi a nakoniec prenášanie informácií zakreslené do skenu rádiológom na 3D avatara.

3.1 3D avatar

V práci už boli uvedené výhody a nevýhody viacerých grafických rámcov, ale ako bolo spomenuté, tento projekt bude využívať OpenGL grafický rámec. Ako prvé sa implementuje 3D priestor pomocou tohto rámca, importuje sa model ľudskej anatómie (3D avatar) z OBJ formátu súboru a po jeho načítaní sa následne aj vykreslí. Všeobecný model ľudskej anatómie bol prebraný z diela Z-Anatomy [29], ktorý reprezentuje dôkladnú, podrobne rozpracovanú depikciu ľudského tela. K tomuto budú implementované aj tlačidlá na obrazovku, ktorých funkcionality bude

mať filtračný charakter, teda ak používateľ stlačí tlačidlo s obrázkom reprezentujúcim pľúca, tak pľúca sa v modeli prestanú vykresľovať, ak toto tlačidlo ťukne znova, tak sa začnú znova vykresľovať. Toto bude platiť pre každý orgán a aj celkovo kostru.

3.2 Predspracovanie, zobrazenie a interakcia s medicínskymi zobrazeniami

Projekt potrebuje spôsob ako načítavať skeny, čiže prehliadač súborov, načítanie skenov, predspracovanie načítaných skenov a umožnenie interakcie s načítanými medicínskymi zobrazeniami, čiže ich zobrazíť a umožnenie umiestňovania značiek na jednotlivé rezy skenu. Na prehliadač súborov bude použitý PyQt rámec, ktorý túto funkciu umožňuje pomerne jednoducho a elegantne. Na načítanie a predspracovanie skenov použijeme rámec MONAI, ktorý má robustné riešenie tohto problému. Vie spracovať dáta viacerými spôsobmi ako ITK, Nibabel, Numpy a Pydicom. [4] Po tejto udalosti sa budú dáta segmentovať, ale toto bude prebrané neskôr. Na zobrazenie jednotlivých rezov skenu, prechádzanie medzi nimi a umiestňovanie značiek bude aplikovaný znova PyQt rámec. Pomocou neho bude otvorené ďalšie okno aplikácie, kde okno sa prispôbí veľkosti daného rezu skenu, aby bolo jednoducho zrealizovateľné získavanie súradníc pri umiestňovaní značiek na sken. Na koliesko myši bude naviazaná udalosť na prechádzanie rezov skenu a na po stlačení ľavého tlačidla bude umiestnená značka na daný rez skenu.

3.3 Spracovanie medicínskeho zobrazenia

Ako už bolo spomenuté, najprv je potrebné lokalizovať miesto, kde rádiológ v danom medicínskom zobrazení označil nález. Zoberú sa pixelové súradnice daného

rezu skenu, kde rádiológ označil nález. Následne sa zistí, že či toto miesto sa nachádza v nejakom orgáne. Toto sa overí prostredníctvom implementácie nástroja TotalSegmentator [32], pomocou ktorého prebehne segmentácia orgánov v danom medicínskom zobrazení. Po segmentácii orgánov daného skenu bude možné určiť, že kde sa orgány nachádzajú, zobrazíť segmentáciu, poprípade aj zistiť objem daného orgánu.

3.4 Prenášanie značiek z medicínskeho zobrazenia do 3D avatara

Ako poslednú vec treba prepojiť interakciu s medicínskymi zobrazeniami a 3D avатарom. Je nutné vyrovnať alebo namapovať body z jedného súradnicového systému (reprezentovaného 2D obrázkom rezom skenu) do druhého (3D modelu avatara). V tomto prípade je nevyhnutné disponovať súradnicami orgánov v medicínskom obrazovaní a tiež v 3D modele avatara, a súčasne odhadovať polohu nálezov, ktoré rádiológ zakreslil do rezov daného skenu. Tu prichádza do úvahy voxelová metóda [7], keďže sken je vyjadrený 3D dátovou štruktúrou (2D polia vrstvené na sebe, čo tvorí trojrozmerné pole), a 3D avatara je taktiež možné rozdeliť na 3D mriežku, vytvárajúc voxelovú reprezentáciu 3D avatara. Vzhľadom k tomu, že v skene aj v 3D avatari máme pevné body (orgány), touto metódou je možné aproximovať body vyznačené rádiológom v skene do 3D avatara.

Literatúra

- [1] Mohamed Alloghani et al. “A systematic review on supervised and unsupervised machine learning algorithms for data science”. In: *Supervised and unsupervised learning for data science* (2020), s. 3–21.
- [2] Isaac Bankman. *Handbook of medical image processing and analysis*. Elsevier, 2008.
- [3] Avijit Dasgupta a Sonam Singh. “A fully convolutional neural network based structured prediction approach towards the retinal vessel segmentation”. In: *2017 IEEE 14th international symposium on biomedical imaging (ISBI 2017)*. IEEE. 2017, s. 248–251.
- [4] Andres Diaz-Pinto et al. “Monai label: A framework for ai-assisted interactive labeling of 3d medical images”. In: *arXiv preprint arXiv:2203.12362* (2022).
- [5] David J Eck. *Introduction to Computer Graphics*. 2021.
- [6] James D Foley et al. *Introduction to computer graphics*. Zv. 55. Addison-Wesley Reading, 1994.
- [7] A. Ghoneima et al. “Accuracy and reliability of landmark-based, surface-based and voxel-based 3D cone-beam computed tomography superimposition methods”. In: *Orthodontics & Craniofacial Research* 20.4 (2017), s. 227–236. DOI: <https://doi.org/10.1111/ocr.12205>. eprint: <https://doi.org/10.1111/ocr.12205>.

- onlinelibrary.wiley.com/doi/pdf/10.1111/ocr.12205. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1111/ocr.12205>.
- [8] Lee W Goldman. “Principles of CT and CT technology”. In: *Journal of nuclear medicine technology* 35.3 (2007), s. 115–128.
 - [9] Yu Gordienko et al. “Deep learning with lung segmentation and bone shadow exclusion techniques for chest X-ray analysis of lung cancer”. In: *Advances in Computer Science for Engineering and Education 13*. Springer. 2019, s. 638–647.
 - [10] John C. Gore. “Artificial intelligence in medical imaging”. In: *Magnetic Resonance Imaging* 68 (2020), A1–A4. ISSN: 0730-725X. DOI: <https://doi.org/10.1016/j.mri.2019.12.006>. URL: <https://www.sciencedirect.com/science/article/pii/S0730725X19307556>.
 - [11] Michael A Jacobs, Tamer S Ibrahim a Ronald Ouwerkerk. “MR imaging: brief overview and emerging applications”. In: *Radiographics* 27.4 (2007), s. 1213–1229.
 - [12] R Beulah Jeyavathana, R Balasubramanian a A Anbarasa Pandian. “A survey: analysis on pre-processing and segmentation techniques for medical images”. In: *International Journal of Research and Scientific Innovation (IJRSI)* 3.6 (2016), s. 113–120.
 - [13] Hany Kasban, MAM El-Bendary a DH Salama. “A comparative study of medical imaging techniques”. In: *International Journal of Information Science and Intelligent System* 4.2 (2015), s. 37–58.
 - [14] Sean Kitson. *Big Data in Medical Imaging: Pioneering Enhanced Patient Care and Diagnostic Precision*. Medical Imaging Blog. URL: <https://openmedscience.com/big-data-in-medical-imaging-pioneering-enhanced-patient-care-and-diagnostic-precision/>.

- [15] Jayanth Koushik. “Understanding convolutional neural networks”. In: *arXiv preprint arXiv:1605.09081* (2016).
- [16] Geon-hee Lee et al. “A study on the performance comparison of 3D file formats on the web”. In: *International journal of advanced smart convergence* 8.1 (2019), s. 65–74.
- [17] Le Lu et al. “Deep learning and convolutional neural networks for medical image computing”. In: *Advances in computer vision and pattern recognition* 10 (2017), s. 978–3.
- [18] Andreas S Panayides et al. “AI in medical imaging informatics: current challenges and future directions”. In: *IEEE journal of biomedical and health informatics* 24.7 (2020), s. 1837–1857.
- [19] Norbert J Pelc. “Recent and future directions in CT imaging”. In: *Annals of biomedical engineering* 42 (2014), s. 260–268.
- [20] S Perumal a Thambusamy Velmurugan. “Preprocessing by contrast enhancement techniques for medical images”. In: *International Journal of Pure and Applied Mathematics* 118.18 (2018), s. 3681–3688.
- [21] Guilherme Polo. *Pygtk, pyqt, tkinter and wxpython comparison*. 2017.
- [22] Peter Reimer et al. *Clinical MR imaging*. Springer, 2010.
- [23] DR Sarvamangala a Raghavendra V Kulkarni. “Convolutional neural networks in medical image understanding: a survey”. In: *Evolutionary intelligence* 15.1 (2022), s. 1–22.
- [24] Peter Savadjiev et al. “Demystification of AI-driven medical image interpretation: past, present and future”. In: *European radiology* 29 (2019), s. 1616–1624.
- [25] Joseph A Shiraef. “An exploratory study of high performance graphics application programming interfaces”. In: (2016).

- [26] K Kirk Shung, Michael Smith a Benjamin MW Tsui. *Principles of medical imaging*. Academic Press, 2012.
- [27] Paul Suetens. *Fundamentals of medical imaging*. Cambridge university press, 2017.
- [28] P Vasuki, J Kanimozhi a M Balkis Devi. “A survey on image preprocessing techniques for diverse fields of medical imagery”. In: *2017 IEEE International Conference on Electrical, Instrumentation and Communication Engineering (ICEICE)*. IEEE. 2017, s. 1–6.
- [29] Lluís Vinent. *Z-Anatomy*. GitHub repository. 2022. URL: <https://github.com/LluisV/Z-Anatomy>.
- [30] Jakob Wasserthal. *Dataset with segmentations of 117 important anatomical structures in 1228 CT images*. Ver. 2.0.1. Okt. 2023. DOI: 10.5281/zenodo.10047292. URL: <https://doi.org/10.5281/zenodo.10047292>.
- [31] Jakob Wasserthal et al. *Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images*. GitHub repository. 2023. URL: <https://www.github.com/wasserth/TotalSegmentator>.
- [32] Jakob Wasserthal et al. “Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images”. In: *Radiology: Artificial Intelligence* 5.5 (2023).
- [33] Jun Xu et al. “A deep convolutional neural network for segmenting and classifying epithelial and stromal regions in histopathological images”. In: *Neurocomputing* 191 (2016), s. 214–223.
- [34] Liya Zhao, Kebin Jia et al. “Multiscale CNNs for brain tumor segmentation and diagnosis”. In: *Computational and mathematical methods in medicine* 2016 (2016).