

Slovenská technická univerzita v Bratislave  
Fakulta informatiky a informačných technológií

FIIT-16768-116143

Peter Bartoš

# **Avatar medicínskeho vyšetrenia CT/MR**

Bakalárska práca

Vedúci práce: Ing. Miroslav Hlinka, PhD.

Máj 2024



Slovenská technická univerzita v Bratislave  
Fakulta informatiky a informačných technológií

FIIT-16768-116143

**Peter Bartoš**

# **Avatar medicínskeho vyšetrenia CT/MR**

Bakalárska práca

Študijný program: Informatika

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky,  
FIIT STU, Bratislava

Vedúci práce: Ing. Miroslav Hlinka, PhD.

Máj 2024



## **ZADANIE BAKALÁRSKEJ PRÁCE**



Autor práce: Peter Bartoš  
Študijný program: informatika  
Študijný odbor: informatika  
Evidenčné číslo: FIIT-16768-116143  
ID študenta: 116143  
Vedúci práce: Ing. Miroslav Hlinka  
Vedúci pracoviska: Ing. Katarína Jelemenská, PhD.

Názov práce: **Avatar medicínskeho vyšetrenia CT/MR**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania: V súčasnosti sa poskytuje prehľad o klinických náleزو vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní podľa častí tela a orgánov. Táto forma neposkytuje dostatočný celkový prehľad. Cieľom práce je vypracovať systém grafického prehľadu všetkých klinických nálezoformou avatara. Preskúmajte možnosti automatického umiestnenia grafických značiek určitých nálezo (napr. nádory, zranení atď.) na zobrazení avatara. Navrhnite systém automatickej transformácie pozície nálezu na čiastočnej CT/MR snímke konkrétneho pacienta (napríklad malé dieťa, muži a ženy rôznych postáv v rôznych polohách) do normalizovaného grafického zobrazenia avatara. Navrhnite vlastné riešenie pre modelovanie transformácie zobrazenia. Toto navrhnuté riešenie implementuje tak, aby vznikol funkčný prototyp. Vyhodnoťte presnosť generovanej pozície grafickej značky na avatare porovnaním s pozíciou vyhodnocovaného bodu na CT/MR snímkach rôznych pacientov (dieťa, muž, žena, rôzne polohy pacienta.)

Rozsah práce: 40

Termín odovzdania práce: 21. 05. 2024

Dátum schválenia zadania práce: 03.05.2023

Zadanie práce schválil: doc. Ing. Valentino Vranić, PhD. – garant študijného programu



Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Modrom Kameni, Máj 2024

Peter Bartoš



# Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree Course: Informatika

Author: Peter Bartoš

Bachelor's Thesis: Avatar medicínskeho vyšetrenia CT/MR

Supervisor: Ing. Miroslav Hlinka, PhD.

Máj 2024

Development of medical examinations, with the primary goal of enhancing the interpretation of medical images by radiologists has presented itself as a complex task for the last few years. This paper is focused on the exploration of this development, that enhances the interpretation of medical images by radiologists using a 3D Avatar Widget. The proposed system integrates advanced rendering techniques with interactive tools to facilitate a more comprehensive analysis of CT/MR scans. The Avatar Widget serves as a dynamic platform, allowing radiologists to visualize and interact with the CT/MR scans in three dimensions. By combining organ segmentation, radiological annotations, and 3D modeling, the proposed system aims to enhance the radiological diagnostic process. The integration of findings onto the 3D model provides a holistic perspective, facilitating a more comprehensive understanding of the relationships between radiological abnormalities and anatomical structures. For achieving our goal, we use CT/MR scans from Siemens Healthineers internal database, MONAI framework for preprocessing of medical images, TotalSegmentator's U-Net convolutional neural network for segmentation of organs, PyQt framework for interaction of radiologists to mark findings in CT/MR scans and OpenGL framework for 3D human anatomy model rendering.



# Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Informatika

Autor: Peter Bartoš

Bakalárská práca: Avatar medicínskeho vyšetrenia CT/MR

Vedúci bakalárskeho projektu: Ing. Miroslav Hlinka, PhD.

Máj 2024

Rozvoj lekárskych vyšetrení s primárnym cieľom zlepšiť interpretáciu lekárskych snímok rádiológmi sa v posledných rokoch predstavuje ako zložitá úloha. Tento článok je zameraný na skúmanie tohto vývoja, ktorý zlepšuje interpretáciu lekárskych snímok rádiológmi pomocou 3D avatara. Navrhovaný systém integruje pokročilé techniky vykresľovania s interaktívnymi nástrojmi na uľahčenie komplexnejšej analýzy CT/MR skenov. Avatar Widget slúži ako dynamická platforma, ktorá umožňuje rádiológom vizualizovať a interagovať s CT/MR skenmi v troch rozmeroch. Kombináciou segmentácie orgánov, rádiologických anotácií a 3D modelovania sa navrhovaný systém zameriava na zlepšenie rádiologického diagnostickeho procesu. Integrácia zistení do 3D modelu poskytuje holistickú perspektívu, ktorá uľahčuje komplexnejšie pochopenie vzťahov medzi rádiologickými abnormálitami a anatomickými štruktúrami. Na dosiahnutie nášho cieľa používame skeny CT/MR z internej databázy Siemens Healthineers, rámec MONAI na predspracovanie medicínskych zobrazení, U-Net konvolučnú neurónovú sieť TotalSegmentator na segmentáciu orgánov, rámec PyQt na interakciu rádiológov na označenie nálezov v CT/MR skenoch a rámec OpenGL pre 3D vykresľovanie modelu ľudskej anatómie.



## **Pod'akovanie**

Moje pod'akovanie patrí vedúcemu mojej práce Ing. Miroslavovi Hlinkovi, PhD. za jeho ochotu a užitočné rady ktoré mi poskytol pri písaní bakalárskej práce.



# Obsah

<b>1</b>	<b>Úvod</b>	<b>1</b>
1.1	Úvod do problémovej oblasti . . . . .	1
1.2	Zámer projektu . . . . .	2
<b>2</b>	<b>Analýza problému</b>	<b>3</b>
2.1	Úvod do medicínskych zobrazení . . . . .	3
2.1.1	Počítačová tomografia . . . . .	4
2.1.2	Magnetická rezonancia . . . . .	6
2.2	Predspracovanie medicínskych zobrazení . . . . .	7
2.2.1	MONAI . . . . .	8
2.3	Umelá inteligencia . . . . .	9
2.3.1	Hlboké učenie . . . . .	11
2.3.2	Konvolučné neurónové siete . . . . .	15
2.3.2.1	Konvolučná vrstva . . . . .	16
2.3.2.2	Aktivačná vrstva . . . . .	17
2.3.2.3	Združovacia vrstva . . . . .	18
2.3.2.4	Plne prepojená vrstva . . . . .	19
2.3.3	Porozumenie medicínskym zobrazeniam . . . . .	20
2.3.3.1	Klasifikácia medicínskych zobrazení . . . . .	20

2.3.3.2	Segmentácia medicínskych zobrazení . . . . .	21
2.3.3.3	Lokalizácia medicínskych zobrazení . . . . .	21
2.3.3.4	Detekcia v medicínskych zobrazeniach . . . . .	21
2.3.4	Aplikácie konvolučných neurónových sietí v segmentácii me- dicínskych obrazov . . . . .	22
2.3.4.1	Viaccestná a viacškálová konvolučná neurónová sieť	22
2.3.4.2	Konvolučná neurónová sieť založená na záplatách .	22
2.3.4.3	Odvodzovanie viacerých značiek v konvolučnej ne- urónovej sieti . . . . .	23
2.3.4.4	U-Net . . . . .	23
2.3.4.5	TotalSegmentator . . . . .	24
2.3.5	Zhodnotenie aplikácií konvolučných neurónových sietí v seg- mentácii medicínskych obrazov . . . . .	24
2.4	Počítačová grafika . . . . .	25
2.4.1	Úvod do počítačovej grafiky . . . . .	25
2.4.2	Dvojrozmerná grafika . . . . .	26
2.4.2.1	Pixelová mriežka . . . . .	26
2.4.3	Trojrozmerná grafika . . . . .	27
2.4.4	Kreslenie čiar . . . . .	27
2.4.4.1	Vyfarbovanie a zvýrazňovanie tvarov . . . . .	27
2.4.4.2	Definícia polygónov . . . . .	28
2.4.4.3	Translácia obrazu . . . . .	29
2.4.4.4	Rotácia obrazu . . . . .	30
2.4.4.5	Škálovanie obrazu . . . . .	31
2.4.4.6	Import a export modelov . . . . .	33
2.4.5	Grafické rámce . . . . .	33
2.4.5.1	OpenGL . . . . .	33

2.4.5.2	Vulkan . . . . .	34
2.4.6	Zhodnotenie grafických rámsov . . . . .	34
2.5	Prenášanie označení z medicínskeho zobrazenia do 3D avatara . . . . .	35
2.5.1	Používateľské grafické rozhranie . . . . .	35
2.5.1.1	PyQt . . . . .	35
2.5.1.2	wxPython . . . . .	35
2.5.1.3	Zhodnotenie rámsov grafických používateľských ro- zhraní . . . . .	36
2.5.2	Algoritmy na prenášanie označení z medicínskeho zobraze- nia do 3D avatara . . . . .	36
2.5.2.1	Voxelizačná metóda . . . . .	37
2.5.2.2	Metóda orientačných bodov . . . . .	37
2.5.2.3	Metóda ohraničujúcich boxov . . . . .	38
2.5.2.4	Zhodnotenie algoritmov na prenášanie označení z medicínskeho zobrazenia do 3D avatara . . . . .	39
2.5.3	Riešenia podobných problémov . . . . .	39
2.5.4	Pohľad z klinickej praxe . . . . .	41
<b>3</b>	<b>Návrh vlastného riešenia</b>	<b>43</b>
3.1	Zadefinovanie špecifikácií . . . . .	47
3.1.1	Frontend . . . . .	48
3.1.1.1	3D avatar . . . . .	50
3.1.1.2	Zobrazovanie skenov . . . . .	51
3.1.1.3	Zobrazovanie klinických nálezov . . . . .	52
3.1.1.4	Testovanie použiteľnosti . . . . .	53
3.1.2	Backend . . . . .	54
3.1.2.1	Predspracovanie, zobrazenie a interakcia s medicín- skymi zobrazeniami . . . . .	54

## Obsah

---

3.1.2.2	Spracovanie medicínskeho zobrazenia . . . . .	56
3.1.2.3	Prenášanie značiek z medicínskeho zobrazenia do 3D avatara . . . . .	56
<b>4</b>	<b>Implementácia</b>	<b>59</b>
4.1	Zadefinovanie štruktúry behu aplikácie . . . . .	61
4.2	Zobrazenie 3D atlasu tela . . . . .	62
4.3	Predspracovanie dát . . . . .	63
4.4	Segmentácia medicínskych zobrazení . . . . .	64
4.5	Postspracovanie dát . . . . .	65
4.6	Grafické používateľské rozhranie . . . . .	66
4.7	Prenášanie vyznačených nálezov z medicínskeho zobrazenia do 3D avatara . . . . .	68
<b>5</b>	<b>Zhrnutie výsledkov</b>	<b>71</b>
5.1	Testovanie použiteľnosti . . . . .	71
5.2	Vplyv segmentácie na umiestňovanie klinických nálezov z CT/MR do 3D avatara . . . . .	74
5.3	Testovanie aproximovaného umiestňovania nálezov z 3 najbližších segmentácií . . . . .	76
<b>6</b>	<b>Záver</b>	<b>77</b>
<b>Literatúra</b>		<b>78</b>
<b>A</b>	<b>Plán práce</b>	<b>A-1</b>
<b>B</b>	<b>Technická dokumentácia</b>	<b>B-1</b>
B.1	Finálna aplikácia . . . . .	B-1
B.1.1	Práca s aplikáciou . . . . .	B-1

## Obsah

---

B.1.1.1	Ovládanie kamery v aplikácií . . . . .	B-2
B.1.1.2	Nahranie medicínskeho zobrazenia . . . . .	B-2
B.1.1.3	Spracovanie vybraného medicínskeho zobrazenia . .	B-3
B.1.1.4	Vizualizácia vybraného medicínskeho zobrazenia . .	B-3
B.1.1.5	Zakresľovanie klinických nálezov do medicínskeho zobrazenia . . . . .	B-4
B.1.1.6	Načítanie uloženého avatara . . . . .	B-4
B.1.2	Dôležité funkcie . . . . .	B-5

<b>C</b>	<b>Opis digitálnej časti práce</b>	<b>C-1</b>
----------	------------------------------------	------------

# Kapitola 1

## Úvod

### 1.1 Úvod do problémovej oblasti

Medicínske zobrazovanie zohráva kľúčovú úlohu v modernej zdravotnej starostlivosti a poskytuje lekárom neoceniteľný pohľad na vnútorné štruktúry ľudského tela. Skenovanie počítačovou tomografiou a magnetickou rezonanciou ponúka najmä podrobne prierezové snímky, ktoré pomáhajú pri diagnostike a plánovaní liečby rôznych zdravotných stavov. Keďže objem a zložitosť lekárskych zobrazovacích údajov neustále narastá [19], potreba pokročilých nástrojov, ktoré uľahčujú presnú interpretáciu a analýzu, je čoraz zreteľnejšia.

Jednou dôležitou výzvou, ktorej čelia rádiológovia počas vyšetrenia CT skenov, je efektívna integrácia rádiologických nálezov do zmysluplného 3D kontextu. Ako bolo spomenuté už v samotnom zadaní: „V súčasnosti sa poskytuje prehľad o klinických nálezoch vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní podľa častí tela a orgánov. Táto forma neposkytuje dostatočný celkový prehľad“, hoci sú informatívne, často chýba priestorové porozumenie nevyhnutné na pochopenie anatomických vzťahov medzi abnormalitami a okolitými štruktú-

rami. Vyriešenie tohto nedostatku si vyžaduje vývoj inovatívnych riešení, ktoré využívajú možnosti najmodernejších techník segmentácie obrazu, 3D modelovania a grafického vykresľovania.

## 1.2 Zámer projektu

V tejto práci sa budeme zaoberať touto výzvou prostredníctvom vytvorenia 3D avatara pre CT/MR lekárske vyšetrenia. Cieľom je poskytnúť rádiológom nástroj, ktorý bezproblémovo kombinuje pokročilé vykresľovanie CT snímok, užívateľsky prívetivé možnosti anotácie a interaktívne 3D zobrazenie ľudskej anatómie.

Tým, že navrhovaný systém umožňuje rádiológom anotovať nálezy priamo na CT snímky, chce poskytnúť prirodzený a intuitívny prostriedok na zachytenie diagnostických poznatkov. Ďalší krok zahŕňa implementovanie algoritmu na overenie priestorovej zhody medzi rádiologickými anotáciami a segmentovanými oblasťami CT snímok. Tento algoritmus je kľúčový pri zabezpečovaní presného zobrazenia nálezov na 3D reprezentáciu ľudskej anatómie.

Riešením tohto problému táto práca prispieva k pokroku v oblasti medicínskych zobrazovacích nástrojov a podporuje komplexnejší a efektívnejší prístup k rádiologickej analýze. Úspešná implementácia avatara má potenciál zlepšiť celkový pracovný postup rádiológov, čo v konečnom dôsledku povedie k efektívnejšej sta-rostlivosti o pacientov.

# Kapitola 2

## Analýza problému

### 2.1 Úvod do medicínskych zobrazení

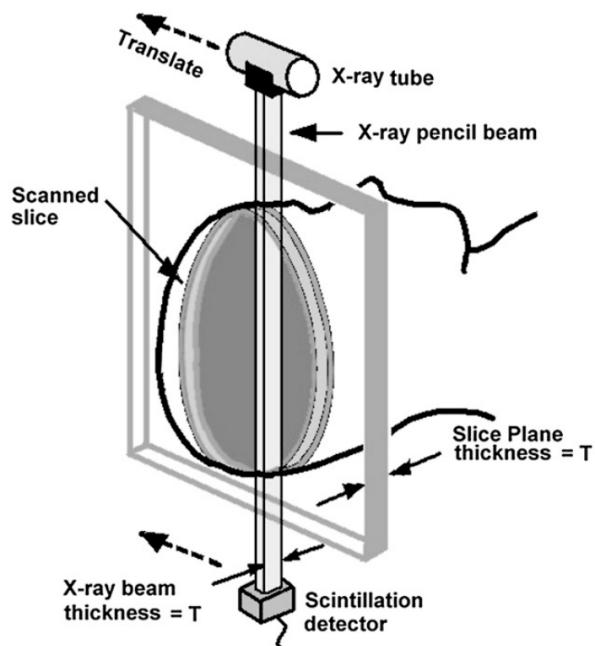
Lekárske zobrazovanie je kľúčovou oblasťou zdravotnej starostlivosti, ktorá využíva rôzne technológie na vytváranie vizuálnych zobrazení vnútra ľudského tela. Tieto snímky sú dôležité pri diagnostike, plánovaní liečby a monitorovaní zdravotných stavov. Zohráva tiež úlohu pri včasnej diagnostike pacienta, plánovaní individuálnej liečby, populačnom skríningu, hodnotení a predpovedaní výsledkov liečby, medicíne založenej na dôkazoch a predklinickom a klinickom výskume. Vďaka tomu, že lekárske zobrazovanie poskytuje lekárom neinvazívny a podrobny pohľad na anatomické štruktúry a fyziologické procesy, zohráva rozhodujúcu úlohu v modernej medicíne. [36, 34]

V medicínskom zobrazovaní sa používa niekoľko metód, z ktorých každá ponúka jedinečné výhody a uspokojuje špecifické diagnostické potreby. Medzi najčastejšie používané lekárske zobrazovacie metódy patria: X-ray (röntgenové zobrazovanie), počítačová tomografia, magnetická rezonancia, ultrazvukové zobrazovanie. [18, 34] Táto práca sa zameria iba na počítačovú tomografiu a magnetickú rezonanciu.

### 2.1.1 Počítačová tomografia

Počítačová tomografia, bežne známa ako CT, je lekárska zobrazovacia technika, ktorá využíva röntgenovú technológiu na vytvorenie podrobnych prierezových snímok vnútorných štruktúr tela. [25, 10]

Proces CT zobrazovania zahŕňa použitie röntgenového žiarenia, ktoré je nasmerované cez telo z viacerých uhlov. Detektory na opačnej strane pacienta zachytia röntgenové lúče po ich prechode telom a tieto údaje sa potom spracujú v počítači na vytvorenie podrobnych dvojrozmerných rezov (alebo tomografických snímok) skenovanej oblasti. Tieto rezy možno ďalej rekonštruovať a vytvoriť trojrozmerné obrazy, ktoré umožňujú komplexné vyšetrenie anatómie. [25, 10]



Obr. 2.1: CT usporiadanie: Osový rez cez pacienta je vyžarovaný úzkym röntgenovým lúčom (šírky ceruzky), keď prepojený röntgenový trubicový detektor skenuje pacienta v lineárnej translácii. Translácie sa opakujú v mnohých uhloch. Hrúbka lúča je ekvivalentná hrúbke rezu. [10]

Charakteristickou črtou CT zobrazovania je jeho schopnosť odhaliť mäkké tkaniivá, kosti a cievy s pozoruhodnou presnosťou, vďaka čomu je obzvlášť cenné pri zisťovaní a diagnostike širokého spektra zdravotných stavov. CT sa bežne používa v rôznych lekárskych špecializáciách, okrem iného v rádiológii, onkológii, neurológii a ortopédii. [25, 10]

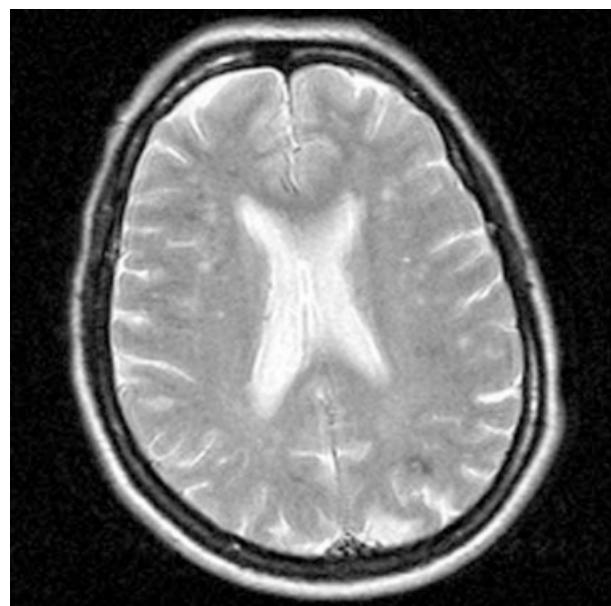
Pokrok v technológií CT viedol k vývoju multidetektorových CT skenerov, ktoré dokážu získať viacero rezov súčasne, čím sa výrazne skracuje čas skenovania a zlepšuje kvalita obrazu. Okrem toho inovácie, ako napríklad CT skenovanie s kontrastom, zahŕňajú použitie kontrastných látok na zlepšenie viditeľnosti určitých štruktúr alebo abnormalít. [25, 10]



Obr. 2.2: Príklad CT skenu [25]

### 2.1.2 Magnetická rezonancia

Magnetická rezonancia (ďalej ako MR) je neinvazívna medicínska zobrazovacia technika, ktorá využíva silné magnety a rádiofrekvenčné impulzy na generovanie detailných snímok vnútorných štruktúr tela. Na rozdiel od röntgenových lúčov alebo počítačovej tomografie, MRI nepoužíva ionizujúce žiarenie, čo z neho robí bezpečnú a všestrannú zobrazovaciu modalitu. [29, 16]



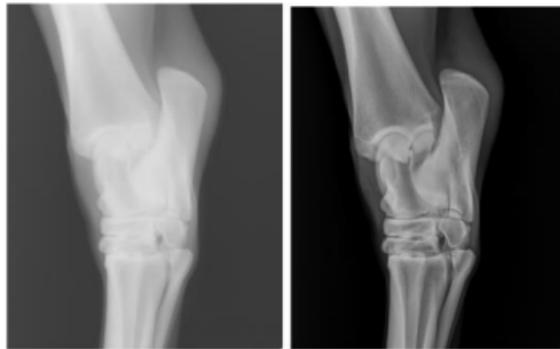
Obr. 2.3: Príklad MR skenu [25]

MRI sa presadilo ako diagnostický a výskumný nástroj v mnohých oblastiach medicíny vďaka svojej schopnosti poskytnúť vynikajúce ohraničenie mäkkých tkanív v rôznych oblastiach záujmu. Okrem T1- a T2-vážených zobrazení bolo navrhnutých mnoho špecializovaných MRI techník na získavanie metabolických alebo biofyzikálnych informácií. Difúzne vážené zobrazenie umožňuje nahliadnuť do pohybu molekúl vody v tkáni a zobrazenie pomocou difúzneho tenzora môže odhaliť orientáciu vlákien v dráhach bielej hmoty. Metabolické informácie o objekte záujmu možno získať pomocou spektroskopie protónov, okrem zobrazenia iných jadier, napríklad sodíka. Dynamické zobrazenie s použitím kontrastných látok a v poslednom čase aj protónová spektroskopia zohrávajú dôležitú úlohu v onkologickom zobrazení. Keď sa tieto techniky skombinujú, môžu lekárovi pomôcť pri stanovení diagnózy alebo monitorovaní liečebného režimu. Jednou z hlavných výhod rôznych typov MR zobrazenia je možnosť operátora manipulovať s kontrastom obrazu pomocou rôznych voliteľných parametrov, ktoré ovplyvňujú druh a kvalitu poskytovaných informácií. Medzi prvky používané na získanie MR obrazu a faktory, ktoré ovplyvňujú tvorbu MR obrazu, patrí MR prístrojové vybavenie, lokalizácia MR signálu, gradienty, k-priestor a pulzné sekvencie. [29, 16]

## 2.2 Predspracovanie medicínskych zobrazení

Predspracovanie zohráva priamo kľúčovú úlohu pri analýze medicínskych snímok a zahrňa rad techník zameraných na zvýšenie kvality a užitočnosti nespracovaných medicínskych snímok. [3, 26, 17, 37] Hlavným cieľom predbežného spracovania je zmieriť šum, opraviť artefakty, normalizovať intenzitu a pripraviť údaje na následnú analýzu. Nasledujúci zoznam poskytuje prehľad o rôznych krokoch predspracovania, ktoré sa bežne používajú na medicínske snímky: redukcia šumu,

normalizácia intenzity, zvýšenie kontrastu, korekcia artefaktov, registrácia obrazu, priestorové filtrovanie, prevzorkovanie, orezanie obrazu, korekcia nerovnomernosti a kontrola kvality. [3, 26, 17, 37]



Obr. 2.4: Príklad predspracovania skenu [37]

Systematickým uplatňovaním týchto techník predspracovania sa analytici medicín-skych snímok snažia zvýšiť spoľahlivosť a interpretovateľnosť dát. Ďalej sa usilujú o zabezpečenie toho, aby následné analýzy a diagnostické procesy boli založené na kvalitných reprezentáciách údajov. Výber konkrétnych krokov predspracovania závisí od vlastností zobrazovacej modality, povahy údajov a požiadaviek zamýšľanej analýzy. [3, 26, 17, 37]

### 2.2.1 MONAI

Rámec určený na analýzu zdravotníckych a lekárskych snímok. Poskytuje nástroje na urýchlenie vývoja a nasadenia modelov hlbokého učenia v oblasti medicínskeho zobrazovania. Obsahuje načítavače údajov a rôzne techniky rozšírenia údajov prispôsobené pre súbory lekárskych zobrazovacích údajov. Taktiež ponúka celý rad stratových funkcií a hodnotiacich metrík vhodných pre úlohy lekárskeho zobrazovania. Poskytuje rozsiahlu dokumentáciu, ktorá pomáha pri pochopení a používaní rámca. [5] Tento rámec bude využitý v riešení projektu.

## 2.3 Umelá inteligencia

Umelá inteligencia sa stala veľmi dôležitým aspektom v oblasti medicínskeho zobrazovania a spôsobila revolúciu v spôsobe, akým zdravotníčki pracovníci analyzujú, interpretujú a využívajú zobrazovacie údaje. Integrácia technológií umelej inteligencie prináša významný pokrok v efektívnosti, presnosti a celkovej starostlivosti o pacientov. Umelá inteligencia pomáha pri rekonštrukcii obrazu, redukcii a vylepšovaní šumu, segmentácii a anotácií obrazu, počítačom podporovanej diagnostike, personalizovanom plánovaní liečby a optimalizácii pracovných postupov. [24, 12, 31]

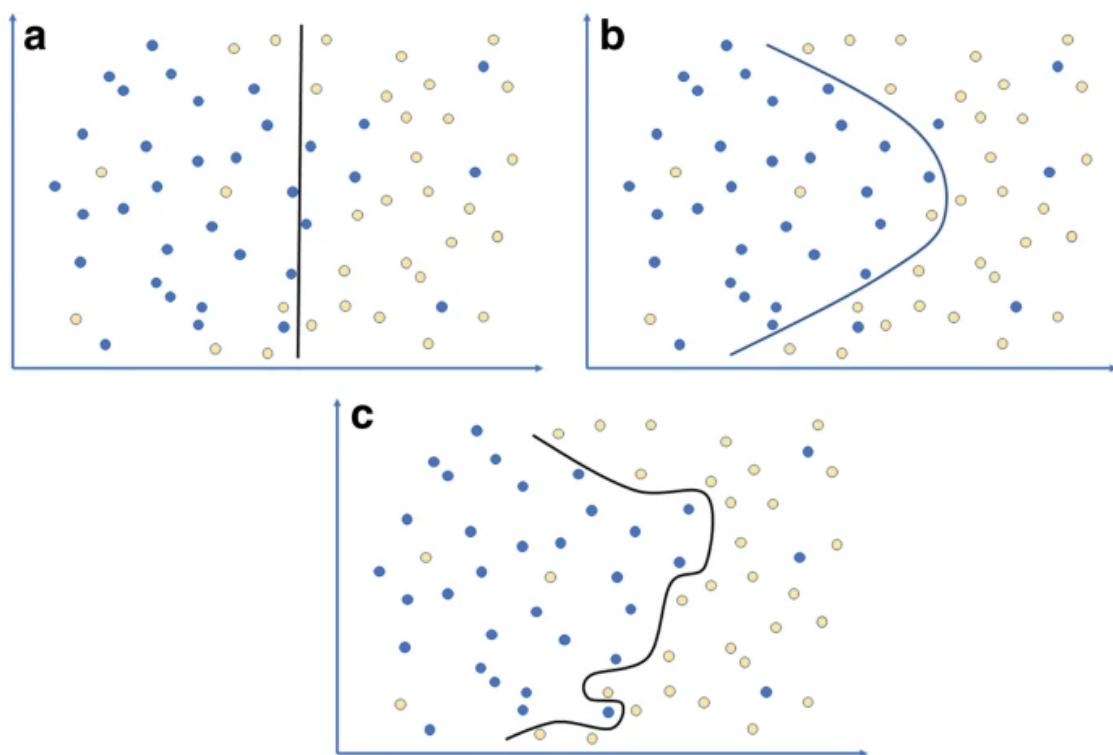
Samozrejme, v tomto odvetví čelí umelá inteligencia veľa problémom. Tradičné metódy, ktoré sa spoliehajú na explicitné odborné znalosti, môžu čeliť prekážkam pri transformácii ľudských odborných znalostí do počítačových modelov, najmä ak je znalostná báza neúplná. Na riešenie tohto problému rastie záujem o iný prístup známy ako "objaviteľská veda" (inak aj ako "veda o objavovaní", angl. discovery science). Tento prístup sa zameriava na dolovanie veľkých súborov údajov s cieľom odhalieť nové vzory a formulovať hypotézy. Na rozdiel od tradičných metód prístupy discovery science neobsahujú modely a sú založené výlučne na údajoch. [31]

Jednou z rozšírených aplikácií tohto prístupu v rádiológii je analýza textúryälebo "rádiomika". V tomto kontexte sa algoritmy učia charakteristické reprezentácie vzhľadu orgánov a tkanív zo súboru trénovaných obrázkov. Ak sú trénované obrázky manuálne označené, nazýva sa to učenie pod dohľadom. Ak nie je žiadne označovanie, metódy učenia bez dohľadu automaticky zisťujú vzory v údajoch. [31, 2]

## Kapitola 2. Analýza problému

---

Bez ohľadu na dohľad sa tieto metódy spoliehajú na extrakciu rôznych znakov z obrazov, napríklad charakterísk textúry. Cieľom je použiť tieto vlastnosti na rozlišovanie medzi rôznymi triedami vo vysokorozmerných priestoroch vlastností. Na tento účel sa používajú rôzne štatistické techniky a techniky strojového učenia, ako napríklad logistická regresia, stroje podporných vektorov a rozhodovacie stromy. Takto vyzerá zjednodušený príklad v dvojrozmernom poli bodov: [31]

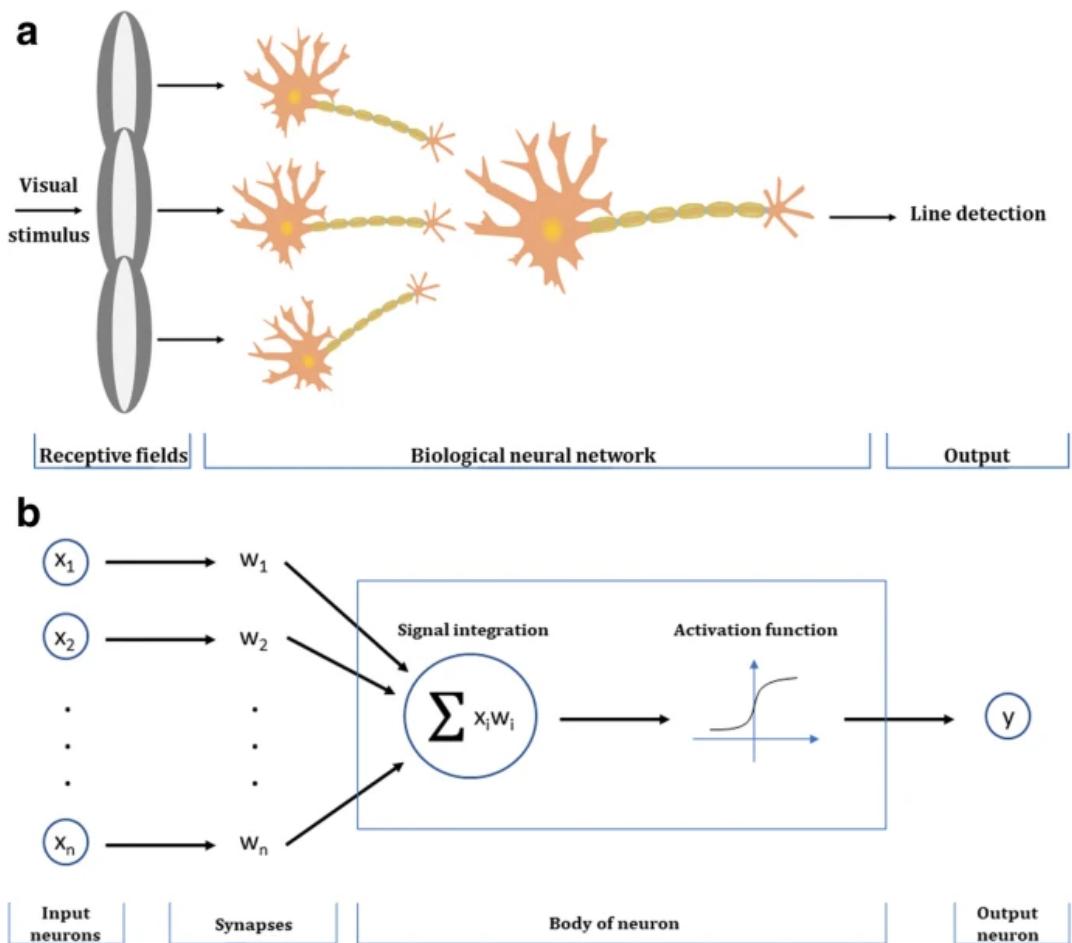


Obr. 2.5: Príklad rozhodovacích hraníc medzi dvoma skupinami dátových bodov v dvojrozmernom priestore s rastúcou zložitosťou od a, b až po c; a je príliš jednoduchá, zatiaľ čo c je nadmerne prispôsobená [31]

### 2.3.1 Hlboké učenie

V rádiológii sa mnohé prístupy založené na údajoch zameriavajú na vlastnosti, ktoré odrážajú dôležité vlastnosti pozorované ľudskými rádiológmi, ako je hustota, heterogenita a tvar nádoru. Súbor metód strojového učenia, ktoré získavajú na popularite, však dokáže automaticky identifikovať najdôležitejšie vlastnosti pre konkrétnu úlohu bez ľudského zásahu do návrhu vlastností. Táto kategória metód sa nazýva hlboké učenie a preukázala schopnosť prekonáť kvalitu výstupu ľudí v určitých úlohách. [31]

Systémy hlbokého učenia sú konštruované pomocou umelých neurónových sietí. Každá umelá neurónová sieť pozostáva z umelých "neurónovalebo uzlov usporiadanych do poľa. Tieto uzly prijímajú ako vstup súbor hodnôt funkcií, z ktorých každá je vynásobená príslušnou váhou. Uzol potom sčítava vážené vstupy a výsledok prechádza nelineárnu aktivačnou funkciou, ktorá určuje výstup neurónu. V podstate každý umelý neurón prijíma rozhodnutie na základe vážených dôkazov. Cieľom tohto návrhu je zjednodušene simulať správanie biologického neurónu, ktorý integruje vstupy zo synapsí a vysiela výstupný signál inému neurónu. [31, 22]



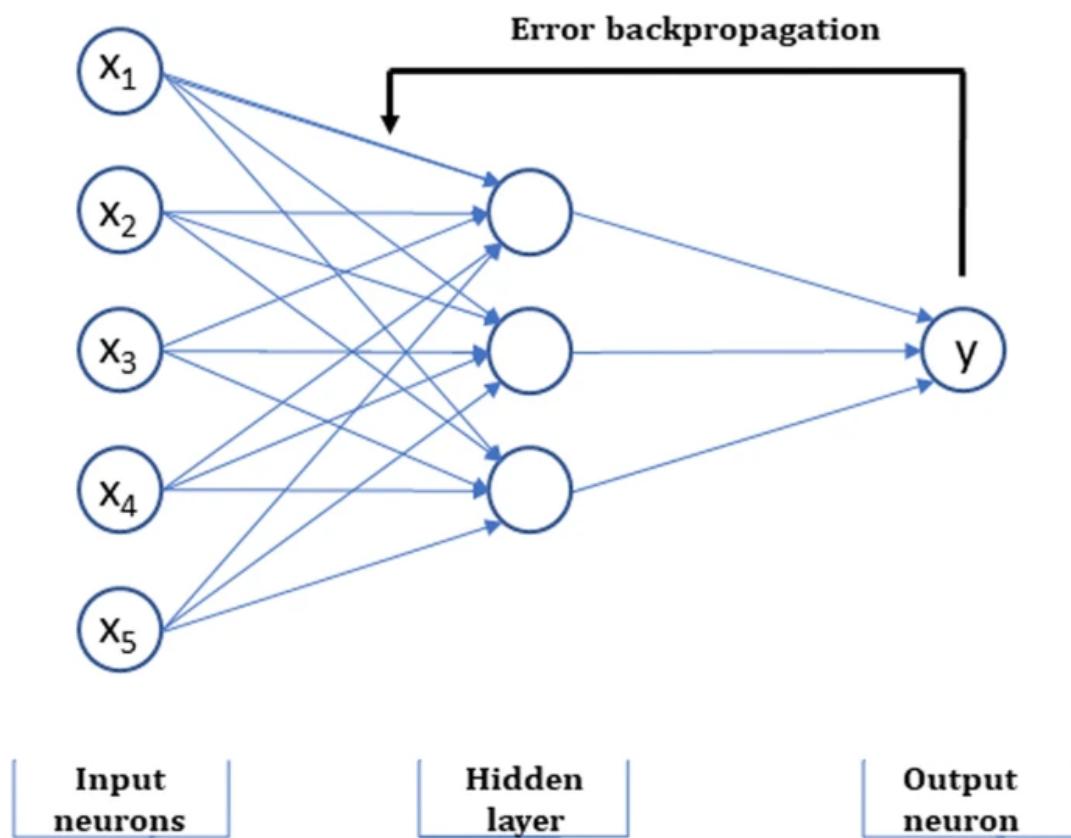
Obr. 2.6: Schematická reprezentácia jednoduchej biologickej neurónovej siete a analogickej umelej neurónovej siete [31]

Váhy a odchýlky siete zohrávajú kľúčovú úlohu pri určovaní jej správania. Aby však bola sieť efektívna, je potrebné tieto parametre jemne doladiť prostredníctvom procesu trénovania. [31, 22]

Počas trénovania je sieť vystavená súboru vstupných údajov (napríklad obrázkov, v našom prípade jednotlivé rezy skenu) a jej aktuálna konfigurácia spracúva tieto vstupy a vytvára výstup. Tento výstup sa potom kvantitatívne porovnáva so skutočným požadovaným výstupom pomocou metriky nazývanej "stratová funkcia". Stratová funkcia v podstate meria, ako ďaleko je predikcia siete od skutočného požadovaného výsledku. [31, 22]

Teraz prichádza zaujímavá časť nazývaná spätné šírenie. Je to technika, pri ktorej sieť vyhodnocuje svoj výkon a upravuje svoje parametre tak, aby minimalizovala stratu. Predstavte si to ako proces pokusov a omylov - sieť dostáva spätnú väzbu o svojich predpovediach a upravuje svoje vnútorné nastavenia, aby sa priblížila k správnym odpovediam. Táto úprava sa vykonáva miernou úpravou každého parametra smerom, ktorý znižuje celkovú stratu. [31, 22]

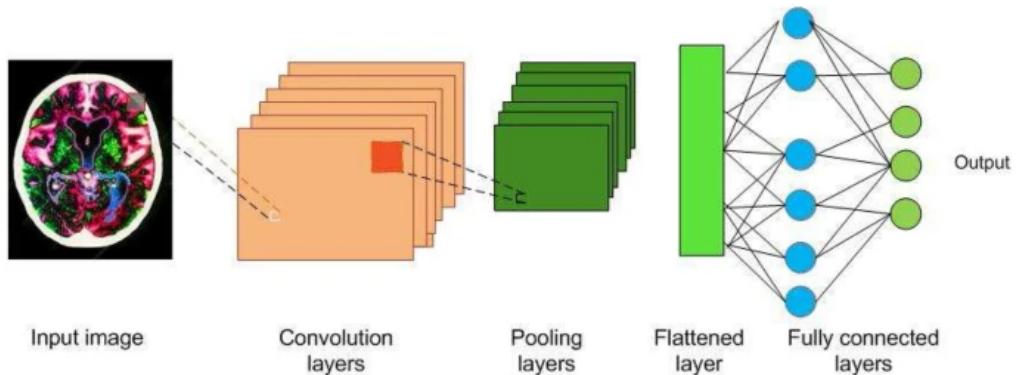
Celý tento proces je iteračný. Sieť prechádza trénovanými údajmi viackrát, pričom v každej iterácii zdokonaľuje svoje parametre. Cieľom je nájsť stav, v ktorom je stratová funkcia siete minimalizovaná, čo znamená, že robí čo najpresnejšie predpovede. Je to ako učiť sieť tým, že sa jej ukazujú príklady a vedie ju to k tomu, aby krok za krokom zlepšovala svoje predpovede, až kým nebude naozaj dobrá v úlohe, ktorú je od nej vyžadovaná na vykonávanie. [31, 22]



Obr. 2.7: Schematické znázornenie umelej neurónovej siete so spätným šírením chybových signálov počas tréningového procesu [31]

### 2.3.2 Konvolučné neurónové siete

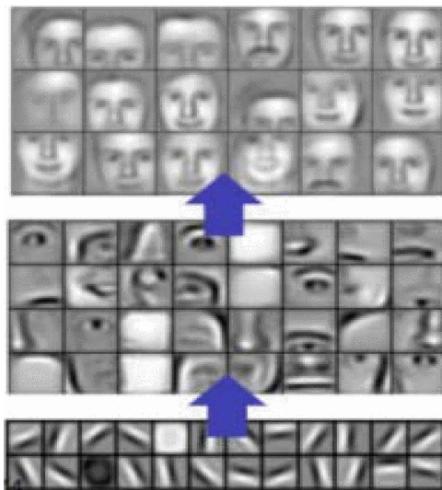
Chápanie obrazu zvieratami je veľmi fascinujúci proces, ktorý je pre ne veľmi jednoduchý. Ale pre stroj, ktorému chceme umožniť porozumieť obrazu, je v tomto procese veľa skrytých zložitostí. U zvierat to funguje tak, že oči zachytávajú obraz, ktorý je spracovaný neurónmi a odoslaný do mozgu na interpretáciu. Konvolučná neurónová sieť je algoritmus hlbokého učenia inšpirovaný zrakovou kôrou zvieracieho mozgu a jeho cieľom je napodobniť zrakovo-vizuálny mechanizmus zvierat. Konvolučná neurónova sieť predstavuje obrovský skok v oblasti porozumenia obrazu, ktorý zahŕňa klasifikáciu obrazu, segmentáciu, lokalizáciu, detekciu atď. Účinnosť konvolučnej neurónovej siete v oblasti porozumenia obrazu je hlavným dôvodom jej hojného využívania. Konvolučné neurónové siete sa skladajú z konvolucií, ktoré majú naučiteľné váhy a skreslenia podobné neurónom (nervovým bunkám) zvierat. Konvolučné vrstvy, aktivačné funkcie, združovanie a plne prepojené vrstvy sú základnými stavebnými prvkami konvolučnej neurónovej siete. [30]



Obr. 2.8: Stavebné bloky konvolučnej neurónovej siete [30]

### 2.3.2.1 Konvolučná vrstva

Zraková kôra mozgu zvierat sa skladá z neurónových buniek, ktoré extrahujú vlastnosti obrazov. Každá neurónová bunka extrahuje rôzne vlastnosti, ktoré pomáhajú pri porozumení obrazu. Konvolučná vrstva je modelovaná nad neurónovými buniami a jej cieľom je extrahovať vlastnosti, ako sú hrany, farby, textúra a orientácia gradientu. Konvolučné vrstvy sa skladajú z učiteľných filtrov nazývaných konvolučné filtre alebo jadrá s veľkosťou  $n \times m \times d$ , kde premenné n a m sú dimenzie konvolučného filtra a d je hĺbka obrazu. Počas priameho prechodu sú jadrá konvolované cez šírku a výšku vstupného objemu a vypočítava sa bodový súčin medzi vstupmi filtra a vstupom. Intuitívne sa konvolučná neurónová sieť učí filtro, ktoré sa aktivujú, keď narazia na hrany, farby, textúry atď. Výstup konvolučnej vrstvy sa privádza do vrstvy aktivačnej funkcie. [30, 20]



Obr. 2.9: Rozpoznávanie abstraktných prvkov v konvolučných neurónových sieťach [20]

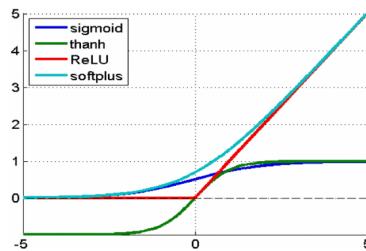
### 2.3.2.2 Aktivačná vrstva

Aktivačná funkcia pre konvolučnú neurónovú sieť je nealineárna, keďže údaje v reálnom svete sú väčšinou nelineárne. Aktivačné funkcie zohrávajú kľúčovú úlohu tým, že do údajov zavádzajú nelineárne transformácie. Ich účelom je zabezpečiť, aby sa reprezentácia vstupného priestoru mapovala na odlišný výstupný priestor, ktorý vyhovuje špecifickým požiadavkám modelu alebo danej úlohy. Tu sa väčšinou používa sigmoid, hyperbolický tangens a usmernená lineárna jednotka (angl. rectified linear unit, v skrate ReLU). [30, 20]

Sigmoid vezme reálne číslo  $x$  a rozdrobí ho do rozsahu medzi 0 a 1. Najmä veľké záporné a kladné vstupy sú umiestnené veľmi blízko nuly, resp. jednotke. Vyjadruje sa ako  $f(x) = \frac{1}{1+e^{-x}}$ . [30, 20]

Hyperbolický tangens vezme reálne číslo  $x$  a rozdrobí ho medzi -1 a 1. Vyjadruje sa ako  $f(x) = \frac{1-e^{-2x}}{1+e^{-2x}}$ . [30, 20]

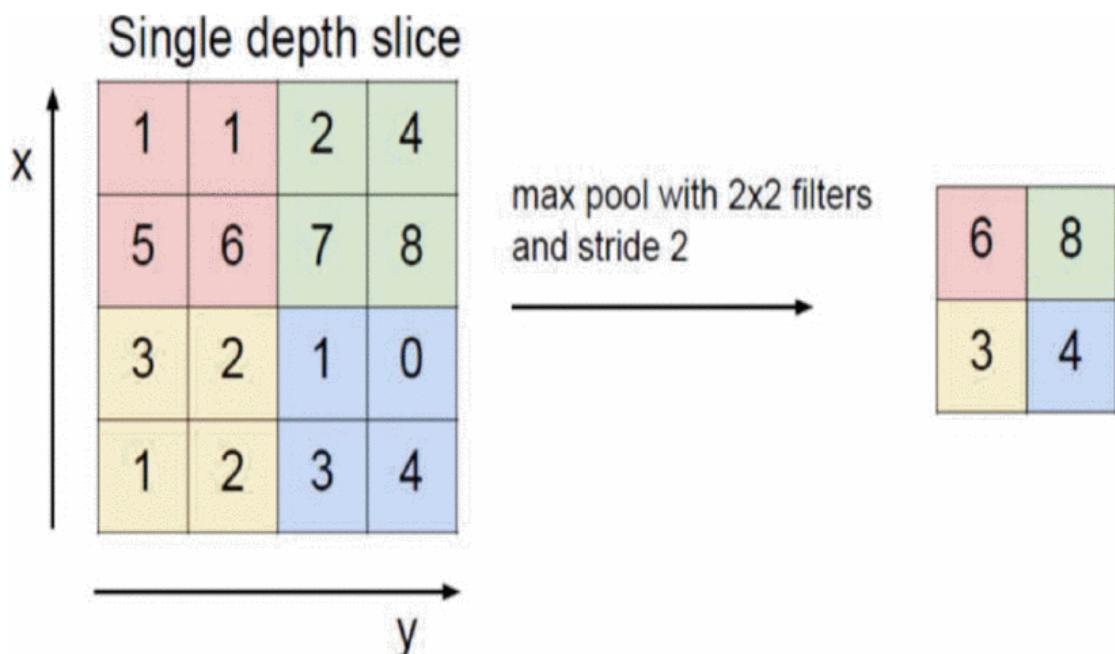
Usmernená lineárna jednotka berie reálne číslo  $x$  a prevádzza  $x$  na 0, ak je  $x$  záporné. Táto funkcia je najčastejšie používanou nelineárnu funkciou pre konvolučné neurónové siete, v porovnaní s ostatnými dvoma zaberá menej výpočtového času, a tým pádom je rýchlejšia a je vyjadrená ako  $f(x) = \max(0, x)$ . [30, 20]



Obr. 2.10: Bežné typy nelineárnych funkcií v konvolučných neurónových sieťach [20]

### 2.3.2.3 Združovacia vrstva

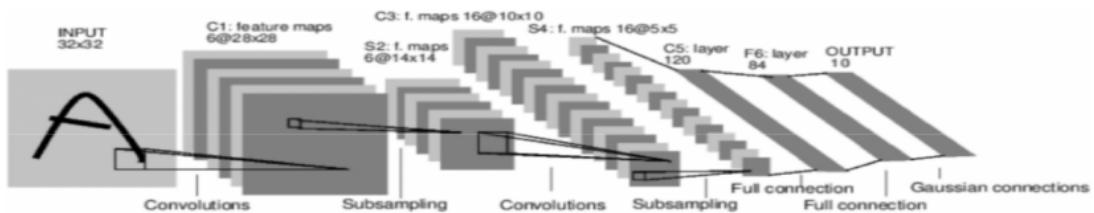
V konvolučnej neurónovej sieti nasleduje ďalej združovacia vrstva. Táto vrstva vykonáva nelineárne znižovanie vzorkovania konvolvovanej funkcie. Znižuje výpočtový výkon potrebný na spracovanie údajov prostredníctvom redukcie dimenzionality. Zmenšuje priestorovú veľkosť agregovaním údajov v priestore alebo typu funkcie, kontroluje nadmerné prispôsobenie a prekonáva translačné a rotačné odchýlky obrazov. Výsledkom operácie združovania je rozdelenie jeho vstupu na súbor obdlžnikových políčok. Každá škvrna sa nahradí jednou hodnotou v závislosti od zvoleného typu združovania. Existujú rôzne typy združovania a tými sú: maximálne a priemerné. [30, 20]



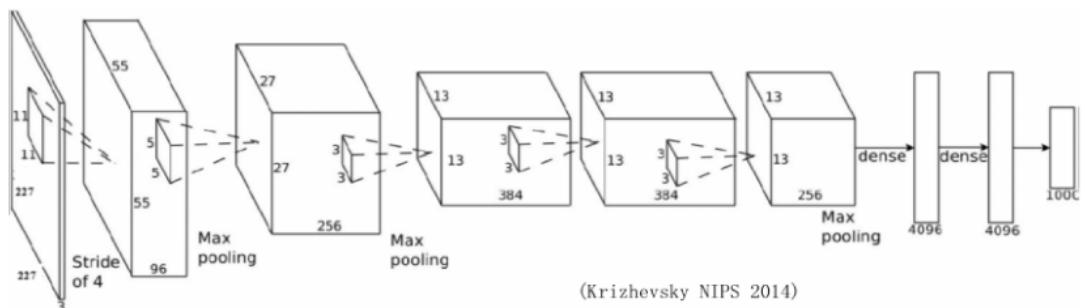
Obr. 2.11: Predvedenie maximálneho združovania s filtrom  $2 \times 2$  a krokom 2, ktoré viedie k zníženiu vzorkovania každého bloku  $2 \times 2$  na 1 blok (pixel). [20]

### 2.3.2.4 Plne prepojená vrstva

Táto vrstva je podobná umelej neurónovej sieti, kde každý uzol má prichádzajúce spojenia zo všetkých vstupov a všetky spojenia majú priradené váhy. Výstupom je súčet všetkých vstupov vynásobený príslušnými váhami. Hlavnou nevýhodou plne prepojených vrstiev je však značný počet parametrov, čo viedie k výpočtovo zložitému trénovaniu. Na vyriešenie tohto problému sa používajú techniky, ako je vysadzovanie, ktoré znižujú počet uzlov a spojení. Napríklad architektúry ako LeNet a AlexNet dokázali navrhnúť hlboké a široké siete a zároveň udržať výpočtovú zložitosť na zvládnuteľnej úrovni. [30, 20]



Obr. 2.12: Ukážka Lenet architektúry konvolučnej neurónovej siete [20]



Obr. 2.13: Ukážka Alexnet architektúry konvolučnej neurónovej siete [20]

### 2.3.3 Porozumenie medicínskym zobrazeniam

Ako už bolo spomenuté, lekárske zobrazovanie je potrebné na vizualizáciu vnútor-ných orgánov s cieľom odhaliť abnormality v ich anatómii alebo fungovaní. Lekár-ske zobrazovacie zariadenia, ako sú röntgeny, počítačová tomografia, magnetická rezonancia a ultrazvukové skenery, zachytávajú anatómiu alebo fungovanie vnútor-ných orgánov a prezentujú ich ako obrázky. Ako sme spomenuli v predspracovaní medicínskych zobrazeniach, obrázky musia byť zrozumiteľné na presné zistenie anomálií alebo diagnostiku funkčných abnormalít. Ak sa zistí abnormalita, musí sa určiť jej presné umiestnenie, veľkosť a tvar. Tieto úlohy tradične vykonávajú vyškolení lekári na základe svojho úsudku a skúseností. Cieľom inteligentných systémov zdravotnej starostlivosti je vykonávať tieto úlohy pomocou inteligentného porozumenia lekárskym obrazom. Klasifikácia, segmentácia, detekcia a lokalizácia lekárskych obrazov sú dôležité úlohy v rámci porozumenia lekárskym obrazom.  
[30]

#### 2.3.3.1 Klasifikácia medicínskych zobrazení

Klasifikácia lekárskych snímok zahŕňa určenie a priradenie značiek lekárskym sním-kam z pevne stanoveného súboru. Táto úloha zahŕňa extrakciu príznakov z obrazu a priradenie štítkov pomocou extrahovaných príznakov. Nech  $I$  označuje obrázok zložený z pixelov a  $c_1, c_2, \dots, c_r$  označujú štítky. Pre každý pixel  $x$  sa vytvorí vek-tor príznakov  $\zeta$  pozostávajúci z hodnôt  $f(x_i)$  sa extrahuje z okolia  $N(x)$  pomocou  $\zeta = (f(x_0), f(x_1), \dots, f(x_k))$ , kde  $x_i \in N(x)$  pre  $i = 0, 1, \dots, k$ . [30]

Značka zo zoznamu značiek  $c_1, c_2, \dots, c_r$  sa priradí k obrázku na základe  $\zeta$ . [30]

### 2.3.3.2 Segmentácia medicínskych zobrazení

Segmentácia lekárskych snímok pomáha pri porozumení obrazu, extrakcii a rozpoznávaní príznakov a pri kvantitatívnom hodnotení lézií alebo iných abnormalít. Poskytuje cenné informácie na analýzu patologických stavov a následne pomáha pri diagnostike a plánovaní liečby. Cieľom segmentácie je rozdeliť obraz na oblasti, ktoré majú silné korelácie. Segmentácia zahŕňa rozdelenie obrazu  $I$  na konečnú množinu oblastí  $R_1, R_2, \dots, R_S$  ako je vyjadrené v  $I = \bigcup_{i=1}^S R_i, R_i \cap R_j = \emptyset$  and  $i \neq j$ . [30]

### 2.3.3.3 Lokalizácia medicínskych zobrazení

Automatická lokalizácia patológie na snímkach je dôležitým krokom k automatickému plánovaniu akvizície a úlohám následnej analýzy snímok, ako je segmentácia a funkčná analýza. Lokalizácia zahŕňa predpovedanie objektu na snímke, nakreslenie ohraničujúceho poľa okolo objektu a označenie objektu.

Lokalizačná funkcia  $f(I)$  na obraze  $I$  vypočíta  $c, l_x, l_y, l_w, l_h$ , ktoré predstavujú označenie triedy, súradnice centroidu  $x$  a  $y$  a podiel ohraničujúceho boxu vzhľadom na šírku a výšku obrazu, ako je vyjadrené v  $f(I) = (c, l_x, l_y, l_w, l_h)$ . [30]

### 2.3.3.4 Detekcia v medicínskych zobrazeniach

Detekcia obrazu je zameraná na klasifikáciu a lokalizáciu oblastí záujmu nakreslením ohraničujúcich boxov okolo viacerých oblastí záujmu a ich označením. To pomáha určiť presné umiestnenie rôznych orgánov a ich orientáciu. Nech  $I$  je obrázok s  $n$  objektmi alebo oblasťami záujmu. Potom detekčná funkcia  $D(I)$  vypočíta  $c_i, x_i, y_i, w_i, h_i$  a to sú v uvedenom poradí označenie triedy, súradnice centroidu  $x$  a  $y$ , podiel ohraničujúceho boxu vzhľadom na šírku a výšku obrazu  $I$ , ako je uvedené v  $\bigcup_{i=1}^n c_i, x_i, y_i, w_i, h_i = D(I)$ . [30]

### **2.3.4 Aplikácie konvolučných neurónových sietí v segmentácii medicínskych obrazov**

Konvolučné neurónové siete by boli použité na implementáciu účinnej segmentácie obrazov mozgu, srdca, prsníkov, sietnice, pľúc, pečene, tenkého čreva, hrubého čreva, stromálnych a epitelových tkanív, a podobne. Práca prejde pári riešení a optimálne riešenie je nájsť čo najširšie, najrobustnejšie riešenie, keďže je potrebné segmentovať všetky orgány v medicínskom zobrazení.

#### **2.3.4.1 Viaccestná a viacškálová konvolučná neurónová sieť**

V prípade segmentácie mozkových nádorov bola v práci [43] navrhnutá viacškálová architektúra konvolučnej neurónovej siete na extrakciu lokálnych aj globálnych znakov v rôznych mierkach. Model dosahoval lepšie výsledky vďaka rôznym príznakom extrahovaným v rôznom rozlíšení. Výpočtový čas sa znížil využitím dvojrozmernej konvolučnej neurónovej siete namesto trojrozmernej konvolučnej neurónovej siete. Tri veľkosti políčok  $48 * 48$ ,  $28 * 28$  a  $12 * 12$  boli vstupom pre tri konvolučné neurónové siete na extrakciu príznakov. Všetky extrahované príznaky boli vložené do vrstvy FC. Hodnotenie modelu sa uskutočnilo pomocou DSC a presnosti. Výkon modelu bol takmer rovnako stabilný ako najlepšia metóda s presnosťou takmer 90%. [30]

#### **2.3.4.2 Konvolučná neurónová sieť založená na záplatách**

Rakovina prsníka sa dá predpovedať automatickou segmentáciou hustoty prsníka a charakterizovaním mamografických texturálnych vzorov. Výhody konvolučnej neurónovej siete založenej na záplatách boli využité v [41]. Metóda využívala aj metódu superpixelov na nadmerné segmentovanie H&E obrazov rakoviny prsníka na atómové obrazy. Výsledkom boli prirodzené hranice, pričom chyby boli jemné

a menej výrazné, zatiaľ čo metódy posuvných okien mali za následok kľukaté hranice. Na segmentáciu a klasifikáciu stromálnych a epitelových oblastí v histopatologických obrazoch na detekciu rakoviny prsníka a hrubého čreva sa kombinovali techniky konvolučnej neurónovej siete založené na záplatách aj superpixelové techniky. Navrhnutý model prekonal CNN s podporným vektorovým strojom (angl. support vector machine, ďalej ako SVM). Porovnanie sa uskutočnilo s metódami využívajúcimi ručne vytvorené príznaky. Dosiahlo presnosť 100% a CNN-Ncut-SVM s hlbokým učením mal lepšiu plochu pod krivkou ako ostatné konvolučné neurónové siete. [30]

#### **2.3.4.3 Odvodzovanie viacerých značiek v konvolučnej neurónovej sieti**

Segmentácia sietnicových ciev bola v práci [4] riešená ako viacznačkový inferenčný problém a riešená pomocou konvolučnej neurónovej siete. Model extrahoval zelený kanál z obrazu RGB fundu, keďže cievy vykazujú vysoký kontrast v zelenom kanáli. Model bol v šiestej vrstve prevzorkovaný, aby sa zvýšila priestorová dimenzia pre štruktúrovaný výstup. Výstup modelu konvolučnej neurónovej siete bol modelovaný ako vektor namiesto skaláru kvôli viacnásobným značkám. Dosiahlo presnosť 84.98%, citlivosť 76.91%, špecifickosť 98.01%, presnosť 95.33%, a plochu pod krivkou 97.44%. [30]

#### **2.3.4.4 U-Net**

Segmentácia plúc a techniky vylúčenia kostných tieňov na analýzu rakoviny plúc pomocou architektúry U-net sú navrhnuté v [11]. Snímky boli predspracované na odstránenie kostného tieňa a na segmentáciu plúcneho ROI sa použila jednoduchá architektúra U-net. Získané výsledky boli veľmi sľubné a ukázali dobrú rýchlosť a presnú segmentáciu. [30]

#### **2.3.4.5 TotalSegmentator**

Predstavuje model segmentácie pomocou hlbokého učenia, ktorý dokáže automaticky a robustne segmentovať všetky hlavné anatomicke štruktúry na medicínskych snímkach počítačovej tomografie. V tejto retrospektívnej štúdii bolo 1204 vyšetrení počítačovej tomografie (z rokov 2012, 2016 a 2020) použitých na segmentáciu 104 anatomických štruktúr (27 orgánov, 59 kostí, 10 svalov a 8 ciev), ktoré sú relevantné pre prípady použitia, ako je volumetria orgánov, charakterizácia ochorenia a plánovanie chirurgickej terapie alebo rádioterapie. Snímky z počítačovej tomografie boli náhodne vybrané z rutinných klinických štúdií, a preto predstavujú súbor údajov z reálneho sveta (rôzne vekové kategórie, abnormality, skenery, časti tela, sekvencie a miesta). Autori na tomto súbore údajov natrénovali segmentačný algoritmus na modeli konvolučnej neurónovej siete U-Net a vypočítali koeficienty podobnosti na vyhodnotenie výkonnosti modelu. Natrénovaný algoritmus bol aplikovaný na druhý súbor údajov 4004 celotelových vyšetrení počítačovej tomografie s cieľom preskúmať zmeny objemu a zoslabenia v závislosti od veku. Navrhnutý model vykazoval vysoké skóre Dice 94,3% na testovacom súbore, ktorý zahŕňal širokú škálu klinických údajov s veľkými abnormalitami. Model významne prekonal iný verejne dostupný segmentačný model na samostatnom súbore údajov (skóre Dice, 93,2% oproti 87,1%;  $P < 0,001$ ). Vyvinutý model umožňuje robustnú a presnú segmentáciu 104 anatomických štruktúr. Anotovaný súbor údajov [38] a súbor nástrojov [39] sú verejne dostupné. [40]

### **2.3.5 Zhodnotenie aplikácií konvolučných neurónových sietí v segmentácii medicínskych obrazov**

Táto oblasť je v neustálom vývoji a je veľa rôznych modelov konvolučných neurónových sietí alebo aj iných modelov neurónových sietí, ktoré tento problém riešia.

Spomenuté modely v čase ich vytvorenia riešili iba špecifický problém, zameriavali sa iba na jednu vec. Pre úspešné vyriešenie problému je potrebné mať model, ktorý sa zameriava na segmentáciu čo najviac významných štruktúr v tele a nie len na jednu štruktúru. Drvivá väčšina takýchto algoritmov sa zameriava iba takýmto spôsobom a kombinovať rôzne riešenia je časovo veľmi náročné.

Spomenuté riešenia vedia vyriešiť iba frakciu daného problému a preto je najlepšou možnosťou pre úspešné vypracovanie projektu TotalSegmentator ([40]), ktorý vie rozsegmentovať tie najvýznamnejšie štruktúry ľudskej anatómie v medicínskych zobrazeniach počítačovej tomografie, čo je presne potrebné na túto prácu, keďže treba určovať kde sú dané miesta v medicínskom zobrazení, ktoré označil rádiológ.

## 2.4 Počítačová grafika

Táto práca sa bude predovšetkým zameriavať trojrozmernou (3D) grafikou s dôrazom na tvorbu 3D modelov. Napriek tomuto zameraniu je výsledkom väčšiny projektov počítačovej grafiky dvojrozmerný (2D) obraz. Pochopenie a priama manipulácia s 2D obrazmi je kľúčová a vytvára základ pre 3D grafiku. Projekt sa ďalej zameriava aj na zobrazovanie medicínskych zobrazení v 2D grafických reprezentáciach a interakciu s nimi, čiže pochopenie dvojrozmerných zobrazení je kľúčové.

### 2.4.1 Úvod do počítačovej grafiky

Počítačové obrazovky zobrazujú obrázky pomocou pixelov usporiadaných do mriežky. Pixely, hoci sú malé a na displejoch s vysokým rozlíšením často neviditeľné, sú základnými zložkami. Obrazovky zvyčajne používajú 24-bitové farby, pričom každý pixel je špecifikovaný troma 8-bitovými číslami, ktoré predstavujú červenú, zelenú

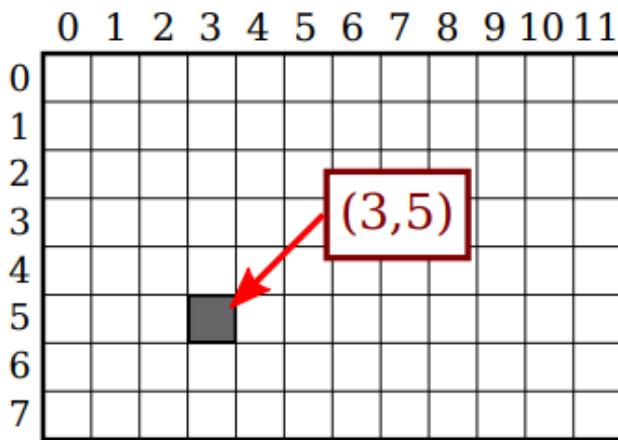
a modrú úroveň. Alternatívou sú formáty odtieňov sivej a indexované farby. [7, 8]

### 2.4.2 Dvojrozmerná grafika

Generovanie 2D obrazu zahŕňa priradenie farieb jednotlivým bodom, z ktorých každý je identifikovaný číselnou dvojicou súradníc. Hoci pre body aj farby existujú číselné špecifikácie, tieto priradenia sú do určitej miery ľubovoľné. Preto je potrebné dôkladne preskúmať súradnicové systémy, ktoré spájajú čísla s bodmi, a farebné modely, ktoré spájajú čísla s farbami. [7, 8]

#### 2.4.2.1 Pixelová mriežka

Digitálny obraz pozostáva z pixelov usporiadaných do riadkov a stĺpcov. Je dôležité poukázať, že pixel je vzorka, nie poličko. Každý pixel je identifikovaný dvojicou celých čísel, ktoré predstavujú jeho stĺpec a riadok. Napríklad súradnice (3,5) označujú pixel v treťom stĺpci a piatom riadku. Zvyčajne sú stĺpce číslované zľava doprava, počnúc nulou, zatiaľ čo riadky sú číslované zhora nadol, tiež počnúc nulou. [7]



Obr. 2.14: Ukážka pixelovej mriežky a vyznačenie pixelu na súradničiach (3,5) [7]

### 2.4.3 Trojrozmerná grafika

V projekte bude využívaná 3D grafika iba na vykreslenie 3D avatara a vykreslovanie jednotlivých bodov v avatarovi, ktoré rádiológ vyznačí v medicínskom zobrazení/skene. Na vykreslenie týchto zobrazení je potrebné pochopiť, ako sa v počítačovej grafike niečo také vykresluje a preto je potrebné zadefinovať si, že čo je to polygón v počítačovej grafike, ako sa taký polygón vykresluje a vyfarbuje, ďalej ako tieto grafické zobrazenia posúvať, rotovať a škálovať.

### 2.4.4 Kreslenie čiar

Ked' sa hovorí o "priamke", označuje sa tým úsečka - priama spojnica medzi dvoma bodmi v rovine. Najzákladnejšou formou je úsečka so šírkou jedného pixelu bez vyhľadzovania, ktorá sa dosiahne vyfarbením pixelov pozdĺž geometrickej úsečky.  
[7]

Ked' sa dve čiary pretínajú ako súčasť väčšieho útvaru, vznikajú úvahy o tom, ako by mali byť čiary spojené. Grafické systémy často podporujú čiary s rôznymi atribútmi, ako sú napríklad vzory čiar a bodiek. [7]

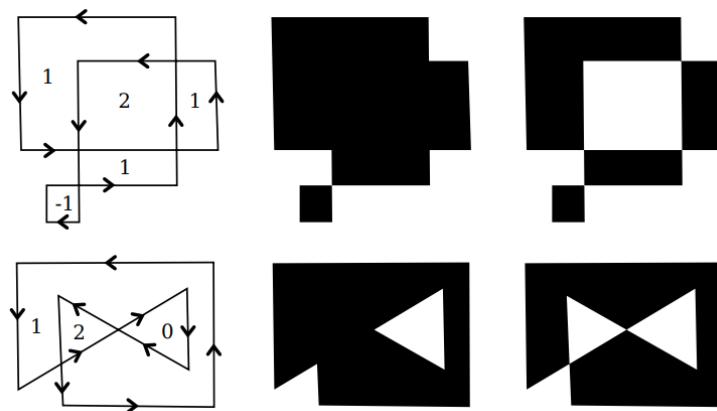
Stručne povedané, základné tvary, ako sú čiary, slúžia ako základné stavebné kamene v grafických rozhraniach, ktoré poskytujú jednoduchosť pomocou jednoduchých príkazov a zároveň zohľadňujú zložitosť pomocou premyslených úvah o vzhľade a atribútoch. [7]

#### 2.4.4.1 Vyfarbovanie a zvýrazňovanie tvarov

Tvary na výkrese možno zviditeľniť dvoma spôsobmi: zvýraznením alebo vyplnením. Zvýraznenie zahŕňa obkreslenie tvaru, podobne ako ťahanie pera po jeho

okraji. V prípade uzavretých tvarov, ako sú obdlžníky alebo ovály, sa vyplnením vyfarbia všetky body vo vnútri tvaru. Tvar je možné obťahovať aj vyplňať, čo umožňuje odlišný vzhľad vnútra a obrysu. [7]

Keď tvar pretína sám seba, určenie vnútra sa stáva nejednoznačným. Riešia to dve pravidlá výplne, ktoré vychádzajú z čísla vinutia. Číslo navíjania okolo bodu znamená, koľkokrát sa tvar okolo neho navíja, pričom kladné číslo znamená navíjanie proti smeru hodinových ručičiek a záporné naopak. Na obrázku ľavé tvary znázorňujú čísla vinutia, vyplnené pomocou pravidiel založených na nenulovom a nepárnom číslе vinutia. [7]



Obr. 2.15: Ukážky vyfarbovacieho algoritmu [7]

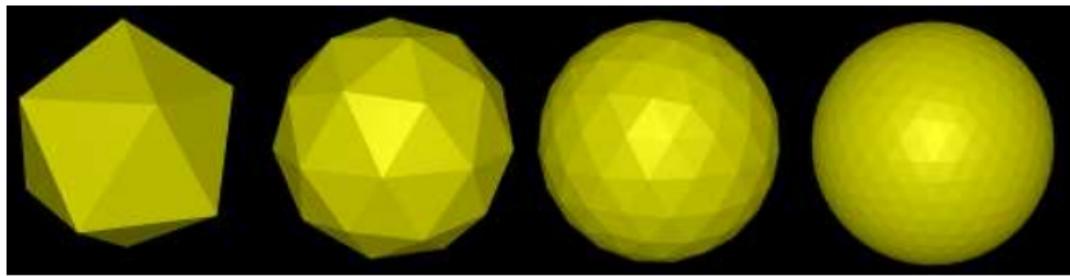
Metódy ťahania a vyplňovania poskytujú flexibilitu pri vizualizácii tvarov v počítačovej grafike. Voľba medzi ťahom a výplňou, ako aj obsah výplne umožňujú v grafike celý rad kreatívnych možností. [7]

#### 2.4.4.2 Definícia polygónov

V grafickom programovaní je nepraktické, aby grafické rozhranie obsahovalo všetky možné tvary ako základné prvky. Namiesto toho existujú metódy na vytváranie zložitejších tvarov, napríklad polygónov. Polygón je uzavretý tvar definovaný postup-

nosťou spojených úsečiek, ktorých vrcholy predstavujú koncové body. Pravidelné mnogouholníky majú rovnaké strany a uhly, zatiaľ čo vypuklé mnogouholníky nemajú na svojich hraniciach zárezy. [7]

Vytváranie a kreslenie mnogouholníkov sa dá dosiahnuť pomocou príkazov na ťahanie a vyplňovanie, pričom vrcholy sa zadávajú buď ako súradnicové polia, alebo ako samostatné polia súradníc. Klasicky sa zložité telesá v grafike vykresľujú prostredníctvom mnoho drobných polygónov, ktoré tento objekt zobrazujú. [7]



Obr. 2.16: Ukážka objektov zoskladaných z polygónov [7]

#### 2.4.4.3 Translácia obrazu

Translačná transformácia v grafike zahrňa posunutie každého bodu horizontálne a vertikálne o určené hodnoty. [7] Ak  $(x_0, y_0)$  predstavuje pôvodný bod a  $(x_1, y_1)$  transformovaný bod, translačný vzorec je daný:

$$x_1 = x_0 + e$$

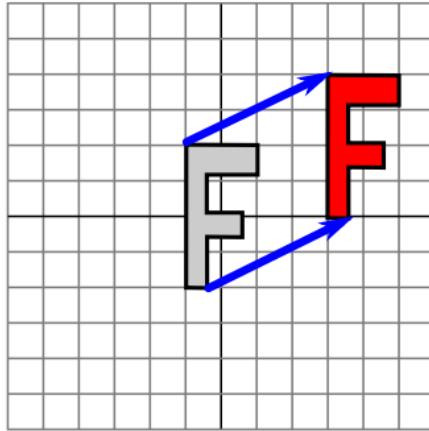
$$y_1 = y_0 + f$$

Tu je horizontálny posun a  $f$  je vertikálny posun. Bežne grafický systém poskytuje funkciu ako  $\text{translate}(e, f)$  na aplikáciu translačnej transformácie. Tento príkaz ovplyvňuje všetky nasledujúce kresliace operácie, pričom  $k$  súradniciam  $x$  pridáva  $e$  a k súradniciam  $y$  pridáva  $f$ . [7]

## Kapitola 2. Analýza problému

---

Ak napríklad sa použije písmeno "F" so stredom v bode  $(0, 0)$  a použije sa  $translate(4, 2)$  pred kreslením, každý bod písmena "F" sa posunie horizontálne o 4 jednotky a vertikálne o 2 jednotky. Výsledné "F" je teraz vycentrované na  $(4, 2)$ . [7]



Obr. 2.17: Ukážka translačnej transformácie v smere  $e$  a  $f$  [7]

Translácia ovplyvňuje všetky nasledujúce kresby, nielen bezprostredný tvar. Ak sa neskôr použije iná transformácia, skombinuje sa s transláciou, a nenahradí ju. Napríklad kombinácia translácie  $translate(4, 2)$  s transláciou  $translate(-1, 5)$  je ekvivalentná jednej translácii  $translate(3, 7)$ . [7]

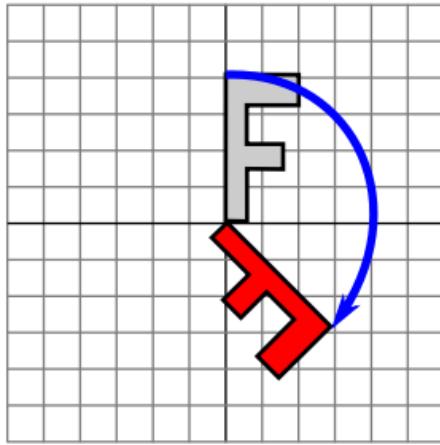
### 2.4.4.4 Rotácia obrazu

Rotačná transformácia otáča každý bod okolo počiatku  $(0, 0)$  o zadaný uhol v stupňoch alebo radiánoch. Uhol rotácie určuje rozsah rotácie a kladné uhly otáčajú objekty proti smeru hodinových ručičiek v súradnicovom systéme s osou  $y$  smerujúcou nahor. V pixelových súradniciach, kde os  $y$  smeruje nadol, je toto otáčanie v smere hodinových ručičiek. [7] Otočenie bodu  $(x, y)$  o uhol  $r$  je matematicky definované takto:

$$x_1 = \cos(r) * x - \sin(r) * y$$

$$y_1 = \sin(r) * x + \cos(r) * y$$

Pre affinnú transformáciu to znamená  $e = f = 0, a = d = \cos(r), b = -\sin(r)$  a  $c = \sin(r)$ . [7] Aplikácia rotácie na bod je znázornená na nasledujúcim obrázku pre rotáciu o -135 stupňov:



Obr. 2.18: Ukážka rotačnej transformácie o 135 stupňov [7]

Pôvodný tvar "F" je znázornený svetlosivou farbou a výsledný tvar po otočení je znázornený tmavočervenou farbou. Šípka označuje posun ľavého horného rohu pôvodného "F" v dôsledku rotácie.

Grafické rozhranie zvyčajne poskytuje príkaz ako napr. *rotate(r)* na vykonanie rotácie. Tento príkaz sa použije pred kreslením objektov podliehajúcich rotácií. [7]

#### 2.4.4.5 Škálovanie obrazu

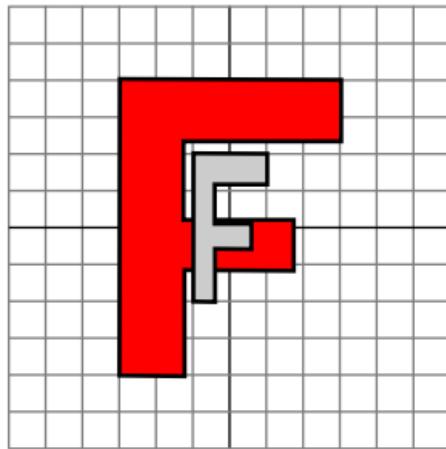
Škálovacia transformácia mení veľkosť objektov vynásobením každej súradnice  $x$  a  $y$  špecifickými faktormi. [7] Pre bod  $(x_0, y_0)$  zväčšený koeficientmi  $a$  v smere  $x$  a  $d$  v smere  $y$  je transformovaný bod  $(x_1, y_1)$  daný:  $x_1 = a * x_0, y_1 = d * y_0$ .

Pri aplikácii na útvar so stredom v počiatku určujú faktory mierky horizontálne a

## Kapitola 2. Analýza problému

---

vertikálne roztiahnutie alebo zmenšenie. Rovnomerné škálovanie, pri ktorom sú oba faktory rovnaké, zachováva tvar bez deformácie. Tu je príklad, v ktorom je pôvodný svetlosivý "F" rovnomerne zmenšený faktorom 3 horizontálne a 2 vertikálne, čím vznikne tmavočervený "F": [7]



Obr. 2.19: Ukážka škálovacej transformácie faktorom (3, 2) [7]

Ak tvar nie je vycentrovaný na  $(0, 0)$ , škálovanie ovplyvní aj jeho polohu. Škálovanie je v podstate transformácia, ktorá buď posúva body smerom od počiatku  $(0, 0)$ , alebo ich k nemu príťahuje. Na škálovanie okolo iného bodu možno použiť postupnosť troch transformácií, podobne ako pri rotáciach. [7]

Grafické rozhranie zvyčajne poskytuje funkciu ako  $scale(a, d)$  na použitie škálovacích transformácií. Transformácia ovplyvňuje všetky následné súradnice  $x$  a  $y$  pri operáciách kreslenia. [7]

Povolené sú záporné faktory škálovania, čo vedie k odrazu tvaru spolu s roztiahnutím alebo zmenšením. Napríklad  $scale(1, -1)$  odráža objekty vertikálne cez os  $x$ . [7]

Okrem toho transformácie vytvorené len z translácií a rotácií bez škálovania zachovávajú dĺžky a uhly v objektoch, ktoré transformujú, čo z nich robí euklidov-

ské"transformácie. Keď sa zavedie rovnomerné škálovanie, uhly a pomery strán sa zachovajú, ale nie dĺžky. [7]

#### **2.4.4.6 Import a export modelov**

Je veľa formátov súborov, ktoré umožňujú uloženie rôzne umiestnenia polygónov, ktoré tvoria nejaký model (tvar, či už jednoduchý alebo zložitý, napr. palma). Tieto údaje majú rôzne spôsoby ukladania, čiže vznikajú rôzne formáty súborov v akých vedia byť uložené. Najznámenjšie sú OBJ, FBX, STL, glTF. Ak je potrebné mať jednoduchý, široko podporovaný formát pre statické modely, OBJ je dobrá voľba. Pre komplexné scény, animácie a interoperabilitu s nástrojmi Autodesk je FBX robustnou voľbou. Ak sa zameriavate na 3D tlač alebo pracujete len s geometriou, vhodný je formát STL. Pre moderné aplikácie v reálnom čase, najmä webové, získava na popularite glTF vďaka svojim vlastnostiam a efektívnosti. Keďže v projekte je potrebné narábať iba so statickými modelami, tak bude použitý OBJ formát. [21]

### **2.4.5 Grafické rámce**

Pri porovnávaní viacerých grafických rozhraniach je potrebné zvážiť ich vlastnosti, možnosti a prípady použitia. Táto práca poskytne porovnanie OpenGL a Vulkan, čo sú dve široko používané grafické rámce. [33]

#### **2.4.5.1 OpenGL**

Tento rámc je nezávislý od platformy a funguje v rôznych operačných systémoch vrátane Windows, MacOS, Linux a ďalších. Kompatibilita medzi platformami môže niekedy viest k rozdielom vo výkone a funkciách. OpenGL má jednoduché rozhranie API, vďaka čomu je prístupné pre vývojárov. Má veľkú komunitu a rozsiahlu dokumentáciu. Niektorí vývojári považujú dizajn API za menej mo-

derný v porovnaní s novšími alternatívami. Historicky je široko rozšírené, najmä v hernom priemysle. V posledných rokoch získavajú popularitu aj iné novšie API od tohto rámca. [33]

### 2.4.5.2 Vulkan

Tento rámec je navrhnutý na multiplatformové použitie a podporuje systémy Windows, Linux a ďalšie. Krivka učenia môže byť strmšia kvôli explicitnému ovládaniu a zvýšenej zložitosti. Vulkan poskytuje lepšiu kontrolu výkonu tým, že vývojárom poskytuje explicitnejšiu kontrolu nad grafickou kartou. Väčšia zložitosť môže spôsobiť, že bude menej vhodný pre začiatočníkov. Vulkan poskytuje viac nízkoúrovňovej kontroly nad združením grafickej karty, čo umožňuje efektívnu optimalizáciu. Táto nízkoúrovňová kontrola môže spôsobiť, že vývoj bude pre začiatočníkov náročnejší. [33]

## 2.4.6 Zhodnotenie grafických rámcov

Výber medzi týmito grafickými rámcami závisí od faktorov, ako sú požiadavky na platformu, odborné znalosti vývojára, ciele projektu a podobne. Tento projekt bude realizovaný pomocou rámca OpenGL, keďže je navrhnutý na multiplatformové použitie a podporuje systémy Windows, Linux, MacOS a ďalšie, čo pridáva na flexibilitu riešenia. Zároveň je viacej vhodný pre začiatočníkov kvôli dlhému pôsobeniu tohto rámca, veľkej komunite a extenzívnej dokumentácií. Zároveň má tiež pomerne jednoduché rozhranie API, čo značne uľahčuje vývoj tejto práce.

## 2.5 Prenášanie označení z medicínskeho zobrazenia do 3D avatara

Na prenášanie označení z medicínskeho zobrazenia do 3D avatara je potrebné pre rádiológa vyhotoviť grafické používateľské rozhranie, pomocou ktorého by sa mu otvoril daný sken a vedel by si prechádzať jednotlivé vrstvy skenu a značiť si nálezy. Následne je potrebný špeciálny algoritmus, ktorý by tieto lokácie týchto nálezov ukladal a prenášal by ich na vykresleného 3D avatara v priestore.

### 2.5.1 Používateľské grafické rozhranie

V programovacom jazyku Python je veľa rámcov, ktoré umožňujú vyhotovenie grafického používateľského rozhrania a je potrebné zohľadniť ich vlastnosti pri výbere z týchto rámcov na úspešné vyriešenie tohto problému, keďže každý jeden má svoje výhody a nevýhody, ktoré musia byť zohľadnené a zvážené. Táto práca poskytne porovnanie rámcov PyQt a wxPython, čo sú dve široko používané rámce grafického používateľského rozhrania.

#### 2.5.1.1 PyQt

PyQt je súbor väzieb jazyka Python pre knižnice Qt. Je to výkonný a komplexný rámcový rámec používaný na vývoj komplexných aplikácií. Je bohatý na funkcie a výkonný. Má moderný vzhľad a ovládanie. Podporuje bezplatné aj komerčné projekty. Vyžaduje inštaláciu, pretože nie je súčasťou štandardnej knižnice Pythonu. Nevýhodou je licencovanie na komerčné použitie. Rámec je dobre zdokumentovaný. [27]

#### 2.5.1.2 wxPython

wxPython je súbor väzieb jazyka Python pre knižnicu wxWidgets z jazyka C++. Poskytuje natívne vyzerajúce aplikácie grafického rozhrania na rôznych platformách.

mách. Má natívny vzhľad a ovládanie na rôznych operačných systémoch. Má rozsiahlu sadu widgetov a má otvorený zdrojový kód. Dokumentácia môže byť pre začiatočníkov náročná. [27]

#### **2.5.1.3 Zhodnotenie rámcov grafických používateľských rozhraní**

Pri výbere medzi týmito rámcami je dôležité zohľadniť dokumentácie, ktoré sú kľúčové na správne narábanie s knižnicami a plynulé implementovanie problému. Na báze tohto úsudku sa bude v práci využívať PyQt rámeč, keďže je wxPython má náročnú dokumentáciu.

### **2.5.2 Algoritmy na prenášanie označení z medicínskeho zo- brazenia do 3D avatara**

Vyriešenie takéhoto problému je veľmi zložité a je potrebné si podrobne prejsť, že čo treba spraviť, čo sa bude diať, ako sa to bude diať a rozdrobiť si to na menšie problémy. V práci by bolo možné použiť metódu založenú na voxeloch, ktorá je spomenutá v [9].

Okrem tejto metódy boli spomínané ešte ďalšie dve metódy a to metóda na základe orientačných bodov a metóda na základe povrchu. Najprv sa v práci opíše voxelová metóda a následne metóda orientačných bodov. Metóda na základe povrchu nebude uvážená v práci, keďže nesúvisela zo zadáním projektu. Nakoniec bude rozobraná metóda na základe ohraničujúcich boxov preberaná v práci [23].

### 2.5.2.1 Voxelizačná metóda

Je potrebné zarovnať alebo mapovať body z jedného súradnicového systému (rez skenu reprezentovaný pomocou 2D obrázka) do iného (3D model avatara). V tomto prípade je potrebné mať súradnice orgánov v medicínskom zobrazení a aj na 3D modeli avatara a treba odhadnúť polohu značiek, ktoré rádiológ zakreslil do rezu daného skenu.

V tom prichádza voxelová metóda [9], keďže medicínske zobrazenie je reprezentované trojrozmernou dátovou štruktúrou (obrázky naskladané na sebe, čiže trojrozmerné pole) a taktiež 3D avatara je možné rozsekať do 3D mriežky, z čoho by vznikla voxelová reprezentácia 3D avatara. V tomto riešení často napomáha deformácieľná registrácia z DICOM [6], ktorá ponúka mapovanie rastru série obrázkov (scan) na inú sériu obrázkov (e.g Avatar rastrový model) s pomocou regisračnej matice.

Kedže v skene a aj v 3D avatarovi máme lokácie orgánov, tak touto metódou je možné odhadovať rádiológom vyznačené body v skene do 3D avatara. [9]

### 2.5.2.2 Metóda orientačných bodov

Ako už bolo spomínané v predchádzajúcej voxelizačnej metóde, je potrebné mapovať body z jedného súradnicového systému do druhého. Pomocou tejto metódy spomínanej v [9] je možné navrhnúť riešenie takým spôsobom, že v 3D modeli ľudského avatara (atlas tela) by boli manuálne vyznačené orientačné body (napríklad vyznačenie jednotlivých stavcoch chrbtice) a na tieto dané body je možné dané segmentácie orgánov, svalov a kostí namapovať. Od daných orientačných bodov by teda bolo možné prepočítavať jednotlivé body v segmentáciách.

Táto metóda by úspešne vedela odhadovať rádiológom vyznačené body v práve otvorenom medicínskom zobrazení do 3D atlasu tela. [9]

### 2.5.2.3 Metóda ohraničujúcich boxov

Poslednou analyzovanou metódu v tejto práci ohľadom jadra daného problému bude metóda ohraničujúcich boxov. Táto metóda je silne založená podľa metód v publikácií [23].

Ako už bolo zdôrazňované v predchádzajúcich metódach, v dispozícii už sú segmentácie častí ľudského tela, 3D atlas ľudského tela a zo skenu je potrebné preniesť vyznačenú pozíciu do implementácie 3D priestoru. Keďže sú k dispozícii segmentácie, tak v dátovej štruktúre skenu vieme vyznačiť ohraničujúci kváder, kde daná anatomická štruktúra začína a končí.

Toto isté je možné spraviť aj v 3D ľudskom avatarovi, čím by boli získané ohraničujúce súradnice. Teraz je možné jednoducho naškálovať podľa dielikov zo segmentovanej štruktúry súradnice jednotlivých bodov segmentácie v danej anatomickej štruktúre 3D ľudského atlasu.

Týmto pádom sa dá aj pomerne jednoducho určovať pozície mimo segmentácií (priestor, ktorý nie je odsegmentovaný neurónovou sieťou), keďže je možné kontrolovať, že v akom ohraničujúcom kvádri sa vyznačený bod v skene nachádza a podľa neho určovať polohu v 3D priestore. [23]

#### **2.5.2.4 Zhodnotenie algoritmov na prenášanie označení z medicínskeho zobrazenia do 3D avatara**

Všetky tri metódy majú svoje výhody a nevýhody, avšak metóda ohraničujúcich kvádrov má svoje jedinečné vlastnosti, ktoré ju robia atraktívnu voči ostatným spomenutým metódam.

Voxelizačná metóda a metóda orientačných bodov závisia na presnom zarovnaní bodov z jedného súradnicového systému do druhého. Tento proces môže byť náchylný na chyby a môže si vyžadovať komplexné algoritmy pre zarovnanie a kapacity dátového úložiska. Na druhej strane, metóda ohraničujúcich boxov využíva jednoduchší prístup, ktorý sa sústredí na vytvorenie ohraničujúcich boxov okolo anatomických štruktúr. Tento prístup môže byť efektívnejší a menej náchylný na chyby.

Metóda ohraničujúcich boxov by mohla byť robustnejšia voči deformáciám a variáciám v tvare a veľkosti anatomických štruktúr, pretože sa sústredí na celkový rozsah štruktúry a nie na jednotlivé body. Nevýhodou ale je nepresnosť v detailoch a limitované použitie pri niektorých deformáciach skenov.

Voxelizačná metóda a metóda orientačných bodov by mohli mať problémy pri presnom zarovnaní bodov v prípade veľkých deformácií. Na základe týchto faktorov je metóda ohraničujúcich boxov vhodnejšou voľbou pre náš prototyp, pretože je jednoduchšia a môže byť robustnejšia voči variáciám v dátach.

### **2.5.3 Riešenia podobných problémov**

Podobný problém tejto práci sa rieši v publikácii [35], ktorá je o vývoji automatizovanej metódy lokalizácie a identifikácie anatomických orientačných bodov na 3D

## Kapitola 2. Analýza problému

---

modeloch kostí rekonštruovaných z CT snímok. Tradičná manuálna identifikácia orientačných bodov je súčasťou bežnej, ale časovo náročnej a náchylná na problémy s opakovateľnosťou a presnosťou. [35]

Navrhovaná metóda založená na počítačovej grafike sa snaží tieto nedostatky odstrániť segmentáciou povrchu modelu na rôzne oblasti orientačných bodov na základe zakrivenia povrchu a použitím iteračného procesu s využitím matice priestorových príbuzenských vzťahov na automatické označenie týchto oblastí. [35]

Výsledky štúdie, ktoré boli porovnané s manuálnymi identifikáciami vykonanými skúsenými ortopedickými chirurgmi, ukazujú, že automatická metóda dosiahla porovnateľný alebo lepší výkon s menšou variabilitou lokalizácie orientačných bodov. [35]

Zistenia naznačujú, že automatizovaná metóda môže priniesť reprodukovateľné výsledky, čím sa zvýši spoľahlivosť plánovania operácie a intraoperačného vedenia. V závere štúdie sa poukazuje na potenciálne využitie tohto prístupu pri plánovaní operácií a navigácií a navrhujú sa smery budúceho výskumu na ďalšie zdokonalenie metodiky. [35]

Tiež podobný problém tejto práci sa rieši v publikácií [42], ktorá predstavuje komplexnú štúdiu o vývoji automatického anotačného systému pre trojrozmerné (3D) cefalometrické orientačné body pri zobrazovaní počítačovou tomografiou (CT). Kefalometrická analýza má zásadný význam pre diagnostiku, plánovanie chirurgických zákrokov a hodnotenie liečby v kraniofaciálnych prípadoch. [42]

Manuálna identifikácia cefalometrických orientačných bodov je časovo náročná a vyžaduje si odborné znalosti, čo viedlo k dopytu po automatizovaných systémoch na zlepšenie efektívnosti a pracovného postupu. Automatizácia pri 3D určovaní orientačných bodov však čelí výzvam, ako sú obmedzené trénované údaje a výpoč-

tová zložitosť spracovania vysokorozmerných obrazov. [42]

V článku sa tiež rozoberá použitie CT údajov, počet orientačných bodov potrebných na 3D cefalometriu, techniky normalizácie údajov, výber lokálnych orientačných bodov a rozdiely v kraniofaciálnych štruktúrach zachytených VAE. [42]

Autori dospeli k záveru, že hoci je systém v počiatočnom štádiu vývoja, je príslušom na zníženie pracovného zaťaženia odborníkov tým, že poskytuje počiatočné odhady orientačných bodov, ktoré si vyžadujú len malé úpravy. Budúce vylepšenia by mohli integrovať viacstupňový rámec do jednotného systému učenia a potenciálne dosiahnuť vyššiu presnosť s väčším počtom tréningových údajov. [42]

#### **2.5.4 Pohľad z klinickej praxe**

V klinickej praxi bude vhodné používať kombinácie algoritmov a presnosť polohovania zvýšiť váhovaným zjednotením viacerých rôznych výsledkov do najpravdepodobnejších koordinátov.

Vo všeobecnosti je možné predpokladať 3 použitia:

1. Metódy ohraničujúcich boxov ako prvoplánové určenie hrubej polohy nálezu a metódu na optimalizáciu výberu presnejších algoritmov v ďalšom stupni.
2. Doplňujúcou metódou je určenie relatívnej polohy trianguláciou bodu voči najbližším známym anatomickým landmarkom.
3. Najpresnejšou metódou je transformovanie polohy nálezu vnútri rozpoznaného orgánu na určenie príslušnej polohy v rámci tohto istého orgánu v 3D modeli avatara prostredníctvom deformovateľnej registrácie segmentácií daného organu.

Pre účel prototypu bude v tomto projekte použítá prvá metóda a využitie ná-

## Kapitola 2. Analýza problému

---

ročnejších a presnejších metód klinickej presnosti nie je predmetom nášho prototypu.

# Kapitola 3

## Návrh vlastného riešenia

Ako už bolo spomenuté, v súčasnosti sa poskytuje prehľad o klinických náleزوch vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní podľa častí tela a orgánov. Táto forma neposkytuje dostatočný celkový prehľad. Často chýba priestorové porozumenie nevyhnutné na pochopenie anatomických vzťahov medzi abnormalitami a okolitými štruktúrami. Cieľom práce teda je implementovať lepšiu alternatívu prehľadu klinických náleزوch s použitím moderných vizualizačných a grafických riešení.

Koncept práce bude zahŕňať vytvorenie softvérovej aplikácie, ktorá umožňuje rádiológom efektívne integrovať rádiologické nálezy z CT/MR skenov do 3D kontextu. Jednou z hlavných funkcií by bolo interaktívne zobrazenie 3D modelu tela pacienta, kde by boli zvýraznené detekované anomálie a nálezy. Doktori by mohli pohodlne preskúmať tieto 3D modely a získať lepšie priestorové porozumenie o ich umiestnení a vzťahu k okolitým štruktúram.

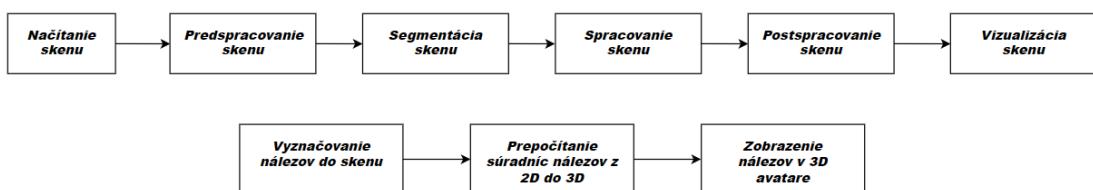
Výstupná softvérová aplikácia by teda fungovala tak, že najprv by sa načítal sken, ktorý by si používateľ vybral podľa svojej voľby. Medicínske zobrazenia by sa

### Kapitola 3. Návrh vlastného riešenia

---

zvalidovalo a predspracovalo podľa potreby. Ďalej by sa rozsegmentovali najdôležitejšie anatomické štruktúry ľudského tela, aby mal softvér od čoho porovnávať polohy v skene a 3D modely ľudského tela. Potom začne postspracovanie pre utvrdenie tvarov segmentácie a nastavenie štandardnej veľkosti rozmeru prierezu skenu. Po spracovaní skenu bude možné toto zobrazenie vizualizovať.

Po vykonaní týchto krokov je možné začať vyznačovať klinické nálezy vo vizualizovanom medicínskom zobrazení. Tieto jednotlivé body náleزوv sa prepočítajú zo súradnicového systému skenu do súradnicového systému 3D modelu a následne sa zobrazili v ľudskom atlase.

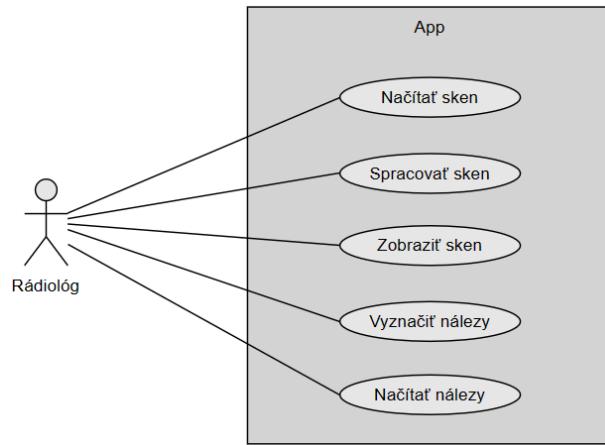


Obr. 3.1: Bloková schéma reprezentujúca koncept implementačných detailov projektu formou dátového potrubia

Celkovo by výstup tejto práce reprezentoval nástroj, ktorý by zlepšil efektivitu a presnosť diagnózy a plánovania liečby pomocou lepšej vizualizácie a porozumenia rádiologických náleزوv v 3D kontexte.

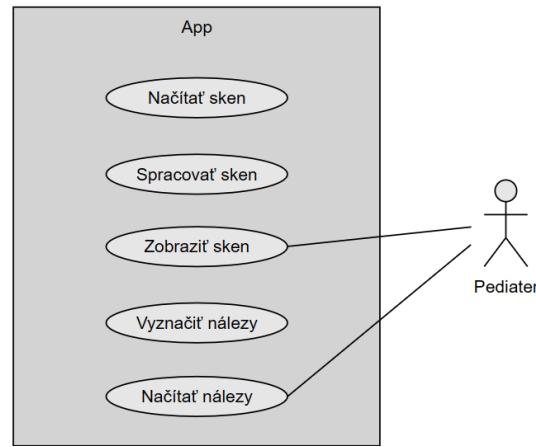
Najprv budú zadefinované generické prípady použitia pre tento projekt, napríklad rádiológ a pediater.

Rádiológ vyznačuje nálezy do medicínskeho zobrazenia zatiaľ čo inému doktorovi poskytuje elegantnú vizualizáciu klinických nálezov pacienta oproti štruktúrovanému textu:



Obr. 3.2: Generický príklad použiteľnosti pre rádiológa

Pediater si prezerá klinické nálezy pomocou vizualizácie, ktoré mu poskytlo riešenie tohto projektu a získava lepšie priestorové porozumenie o ich umiestnení a vzťahu k okolitým štruktúram oproti štruktúrovanému textu:

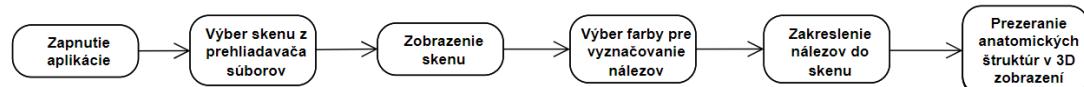


Obr. 3.3: Generický príklad použiteľnosti pre pediatra

### Kapitola 3. Návrh vlastného riešenia

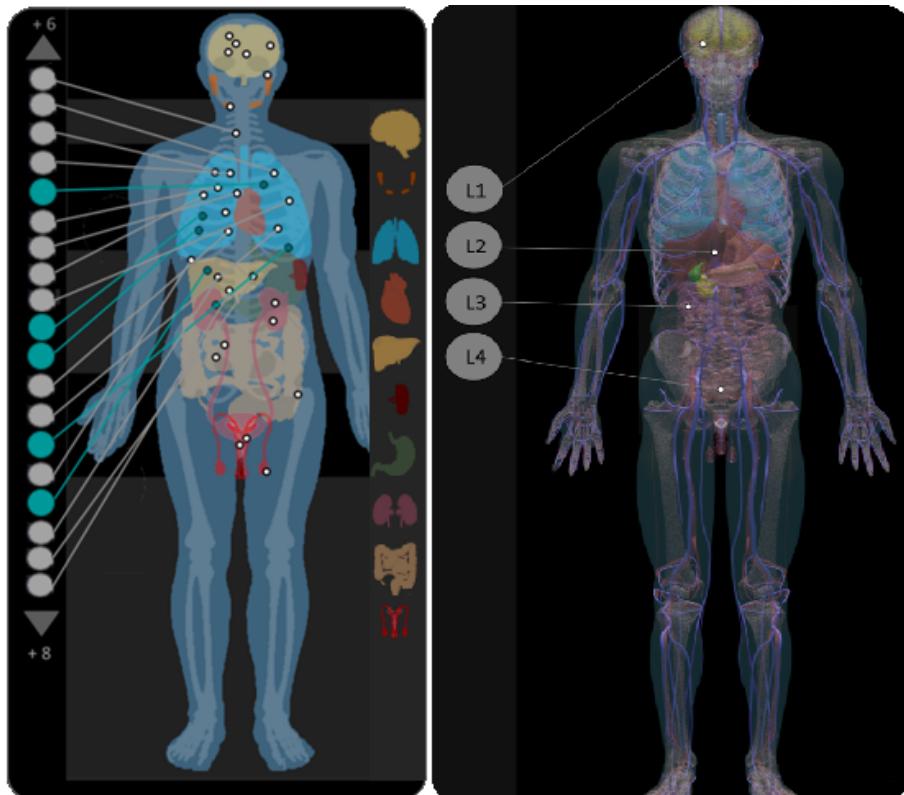
---

Ďalej bude zadefinovaný pracovný postup používateľa v aplikácii. Riešenie tohto bude vyzeráť nasledovne zobrazené pomocou diagramu aktivít:



Obr. 3.4: Generický pracovný postup používateľa

Používateľovi sa po zapnutí aplikácie otvorí okno s ľudským atlasom človeka. Ako návrh môžeme použiť nasledovné obrázky:



Obr. 3.5: Návrhy prototypu aplikácie zobrazujúce atlas ľudského tela

Tieto návrhy figurujú iba ako záchytné body a teda budú prerobené.

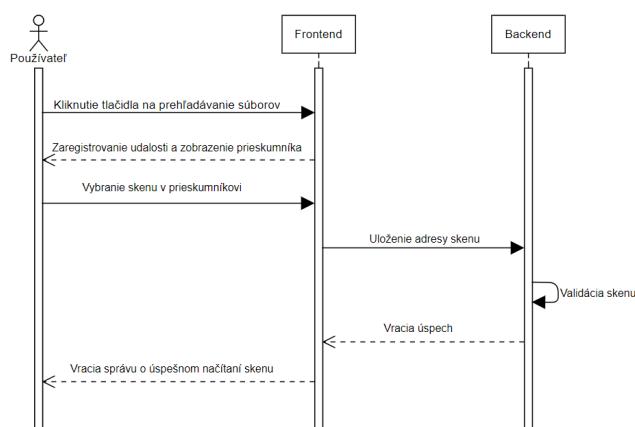
### 3.1 Zadefinovanie špecifikácií

Aplikácia sa bude skladať z dvoch častí, ktorými bútú frontend a backend.

V podkapitole frontend nižšie bude uvedený dizajn aplikácie, čiže časť riešenia, ktorá umožňuje používateľovi interagovať s aplikáciou a zabezpečuje mu užívateľskú skúsenosť. Na začiatku bude uvedený 3D priestor a avatar reprezentujúcim ľudskú anatómiu. Ďalej sa prejde na narábanie s medicínskymi zobrazeniami, interakciu s nimi a vyznačovaním klinických nálezov v skene pacienta.

Druhá časť aplikácie, teda backend, bude tiež uvedený v jeho samostatnej podkapitole. Sem patrí rozbor, ktorý sa zaobráva načítavaním, predspracovaním, spracovaním a zobrazovaním medicínskych dát. Taktiež sem patrí riešenie prenášania značiek zakreslených v medicínskom zobrazení rádiológom do 3D zobrazenia atlasu ľudskej anatómie.

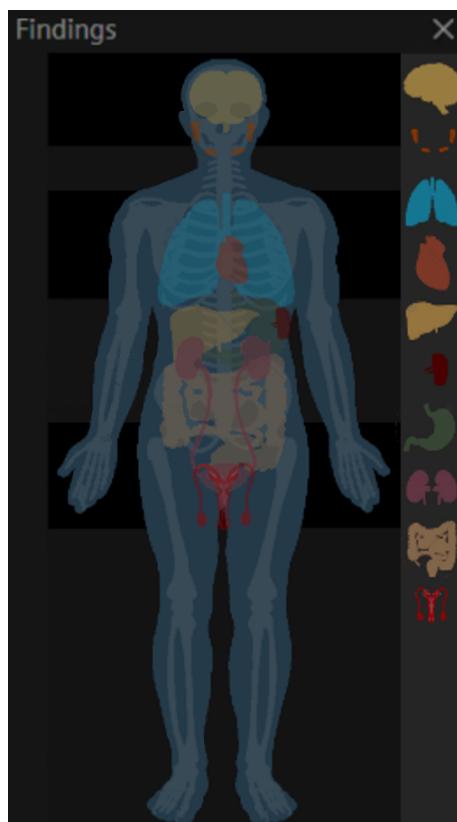
Frontend a backend medzi sebou komunikujú pre správne fungovanie aplikácie. Keď používateľ použíjte nejakú riadiacu funkcionality na frontende, tak sa táto udalosť zaregistruje, pošle sa na backend a ten túto požiadavku vybaví.



Obr. 3.6: Príklad procesu načítania skenu pre uvedenie komunikácie medzi frontendom a backendom

### 3.1.1 Frontend

Používateľské rozhranie používateľovi musí poskytovať vykonávať všetky riadiace činnosti ohľadom aplikácie. Teda po zapnutí aplikácie vidí používateľ hned všetky prvky ovládania. Do stredu obrazovky sa mu zobrazí ľudský atlas. Návrh pre opísané zobarazenie vyzerá nasledovne:



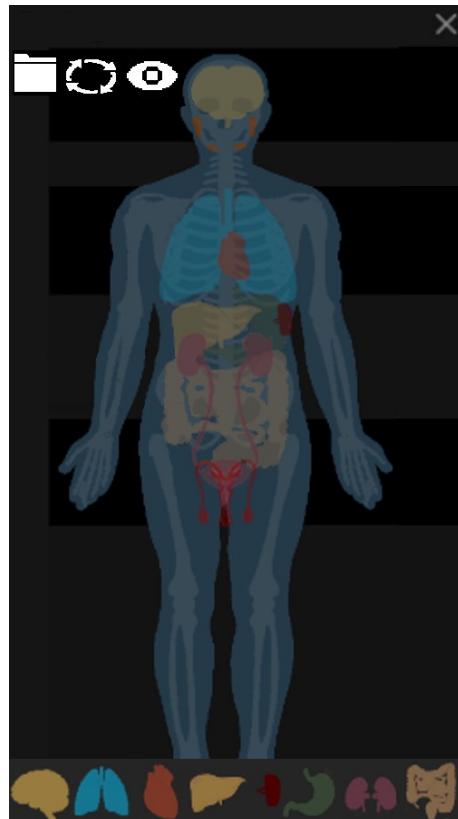
Obr. 3.7: Návrh prototypu zobrazujúci hlavnú obrazovku aplikácie

Hore zobrazené návrhy ale budú prerobené. V hornej časti sa budú zobrazovať tlačidlá, ktoré mu umožnia načítať sken z prieskumníka súborov poskytovaný jeho operačným systémom. Ďalej tam bude tlačidlo na spracovanie vybraného skenu. Posledné tlačidlo mu poskytne vizualizáciu skenu a po jeho kliknutí si bude môcť vybrať farbu zakresľovania nálezov a následne listovať sken a zakresľovať do neho

### Kapitola 3. Návrh vlastného riešenia

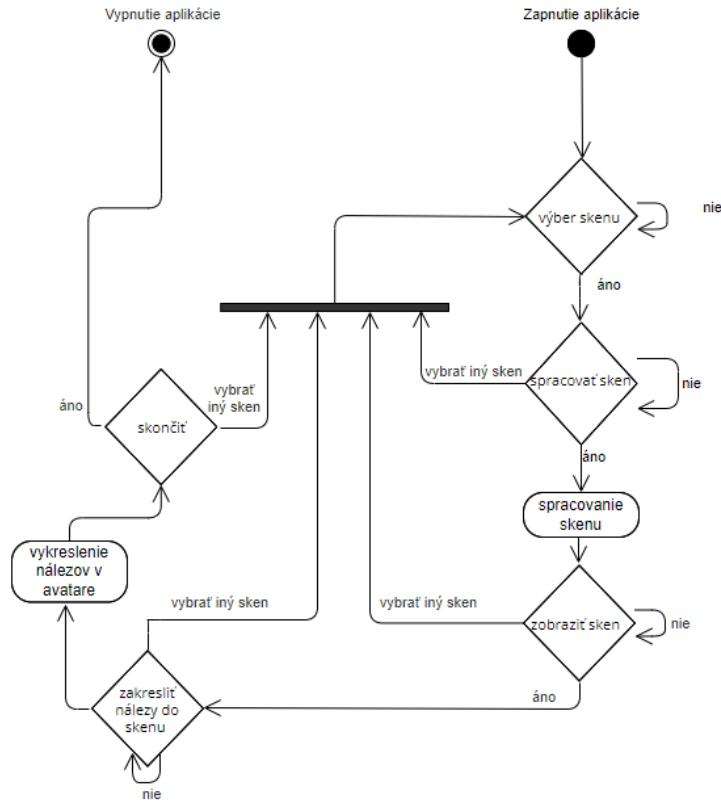
---

klinické nálezy, ktoré sa súčasne budú zobrazovať v 3D avatarovi. Prototyp hlavnej obrazovky teda vyzerá nasledovne:



Obr. 3.8: Prototyp zobrazujúci hlavnú obrazovku aplikácie

Teraz je potrebné zadefinovať ako teda bude používateľ narábať s aplikáciou. Na začiatku si vždy vyberá zo skenu. Potom začne spracovanie medicínskeho zobrazenia až na jeho povel. Po spracovaní si ho môže otvoriť a začať do neho zakresľovať nálezy. Je dôležité podotknúť, že hocikedy v tomto procese sa môže rozhodnúť a je mu aj umožnené zmeniť výber skenu. Diagram aktivít opisujúci ovládanie hlavnej funkcionality používateľom vyzerá nasledovne:



Obr. 3.9: Riadenie aplikácie používateľom

### 3.1.1.1 3D avatar

Ako prvé sa implementuje 3D priestor, importuje sa model ľudskej anatómie (3D avatar) a po jeho načítaní sa následne aj vykreslí. Bude teda vykreslený všeobecný model ľudskej anatómie, ktorý reprezentuje dôkladnú, podrobne rozpracovanú de-pikciu ľudského tela. K tomuto budú implementované aj tlačidlá na obrazovku, ktorých funkcia bude mať filtračný charakter, teda ak používateľ stlačí tla-čidlo s obrázkom reprezentujúcim pľúca, tak pľúca sa v modeli prestanú vykreslovať, ak toto tlačidlo ťukne znova, tak sa začnú znova vykreslovať. Toto bude platíť pre každý orgán a aj celkovo kostru. Vizualizačný prototyp navrhovaného riešenia je možné vidieť už v spomínanom obrázku 3.8 ohľadom hlavnej obrazovky.

### 3.1.1.2 Zobrazovanie skenov

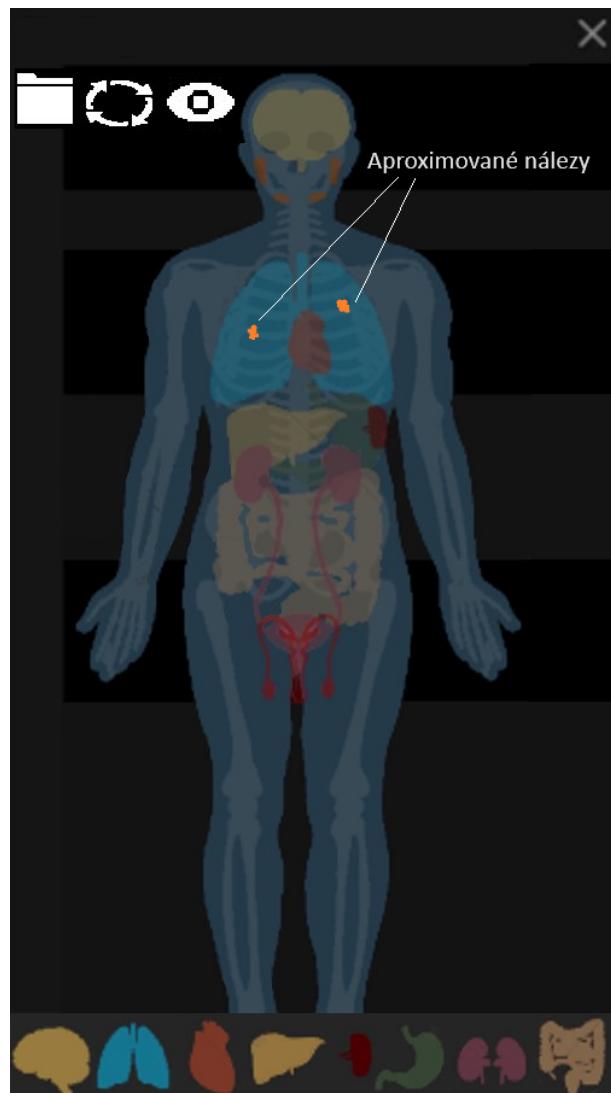
Je potrebné používateľovi poskytnúť možnosť zobrazenia medicínskeho zobrazenia po načítaní a spracovaní tejto dátovej jednotky. Používateľ bude schopný si jednotlivé vrstvy skenu prezerať a listovať. Keď sa rádiológ rozhodne, tak bude môcť do práve prezeranej vrstvy medicínskeho zobrazenia aj zakreslovať jednotlivé klinické nálezy, ktoré na tomto zobrazení pacienta postrehol. Tieto značky sa v reálnom čase budú prenášať aj na 3D avatara ľudskej anatómie. Prototyp takéhoto používateľského grafického rozhrania môže vyzerať takto:



Obr. 3.10: Okno zobrazujúce daný prierez skenu s vyznačenými nálezmi

### 3.1.1.3 Zobrazovanie klinických nálezov

Po zakreslení klinických nálezov do daného prierezu medicínskeho zobrazenia sa tieto body začnú v reálnom čase zjavovať v 3d atlase ľudskej anatómie. Takto vyzerá prototyp obrazovky, kde sú už nálezy zakreslené:



Obr. 3.11: Prototyp obrazovky pri zobrazovaní klinických nálezov v avatare

### 3.1.1.4 Testovanie použiteľnosti

V skratke, testovanie použiteľnosti je základným postupom v snahe o dizajn zamieraný na používateľa. Tento test bude zhodený nad týmto riešením a jeho výsledky budú zverejnené v kapitole *Zhrnutie výsledkov 5.*

Najprv bude zadefinované testovacie prostredie všetkých používateľov, ktorí budú testovať aplikáciu. Testovacie prostredie bude obsahovať zariadenie, operačný systém, rozlíšenie obrazovky a veľkosť obrazovky. Takto vyzerá teda testovacie prostredie všetkých používateľov:

Testovacie prostredie	
Zariadenie	Laptop
Operačný systém	Windows 11
Rozlíšenie obrazovky	1920x1080
Veľkosť obrazovky	24 palcov

Obr. 3.12: Tabuľka zobrazujúca detailly testovacieho prostredia

Na záver budú zadefinované testovacie úlohy, ktoré budú musieť používatelia určení na testovanie vykonať. Jednotlivé úlohy budú obsahovať popis úlohy, predpoklady na vykonanie, kritéria ukončenia, maximálny možný čas a predvolenú cestu riešenia. Vizualizácia tejto špecifikácie, v ktorej sú jednotlivé úlohy zadefinované:

## Kapitola 3. Návrh vlastného riešenia

---

Úloha	Popis	Predpoklady	Kritériá ukončenia	Max. čas	Cesta riešenia
1	Odfiltrovanie pľúc z 3D avatara	Aplikácia otvorená na hlavnej obrazovke	Používateľ uvidí, že sa pľúca v 3D atlase ľudského tela už nevykreslujú	10 s	Hlavná obrazovka -> Prejsť kurzorom na spodnú stranu obrazovky k filtračným tlačidlám -> Tuknutie tlačidla na s depikciou pľúc
2	Načítanie skenu do aplikácie	Aplikácia otvorená na hlavnej obrazovke	Používateľ uvidí výpis, že sa sken úspešne načítal	30 s	Hlavná obrazovka -> Prejsť kurzorom na hornú stranu obrazovky k riadiacim tlačidlám -> Tuknutie tlačidla na s depikciou priečinku -> Vybrať v prieskumníku nejaký sken -> Kliknúť v prieskumníku "Otvoriť"
3	Spracovať a vizualizovať sken	Aplikácia otvorená na hlavnej obrazovke	Používateľovi sa zobrazí nové okno, ktoré mu zobrazí sken	30 s	Hlavná obrazovka -> Prejsť kurzorom na hornú stranu obrazovky k riadiacim tlačidlám -> Tuknutie tlačidla na s depikciou spracovania -> Tuknutie tlačidla na s depikciou vizualizácie Okno s výberom farby -> Odkliknutie výberu farby zakreslovania do skenu
4	Prelistovanie skenu a zakreslenie ľubovoľného nálezu do práve vizualizovaného medicínskeho zobrazenia	Aplikácia otvorená na hlavnej obrazovke s už spracovaným skenom a s otvoreným oknom vizualizácie skenu	Používateľ po vyznačení do skenu uvidí vykreslenie zaznačenia v 3D atlase ľudskej anatómie	15 s	Okno s vizualizáciou skenu -> Prelistovať vizualizovaný sken -> Zakreslenie nálezu do skenu

Obr. 3.13: Tabuľka zobrazujúca detaľy testovacích úloh

### 3.1.2 Backend

V tejto časti aplikácie sa budú robiť procesy, ktoré bežia na pozadí, ktoré si používateľ vyžiada svojou interakciou s komponentami na frontende. Ide teda o načítavanie skenov, ich validáciu, predspracovanie, segmentáciu jednotlivých anatomických štruktúr, postspracovanie a na záver pripravenie na vizualizáciu.

#### 3.1.2.1 Predspracovanie, zobrazenie a interakcia s medicínskymi zobrazeniami

Projekt potrebuje spôsob ako načítať skeny, čiže prieskumník súborov, načítanie skenov, predspracovanie načítaných skenov a umožnenie interakcie s načítanými medicínskymi zobrazeniami, čiže ich zobraziť a umožnenie umiestňovania značiek na jednotlivé rezy skenu.

### Kapitola 3. Návrh vlastného riešenia

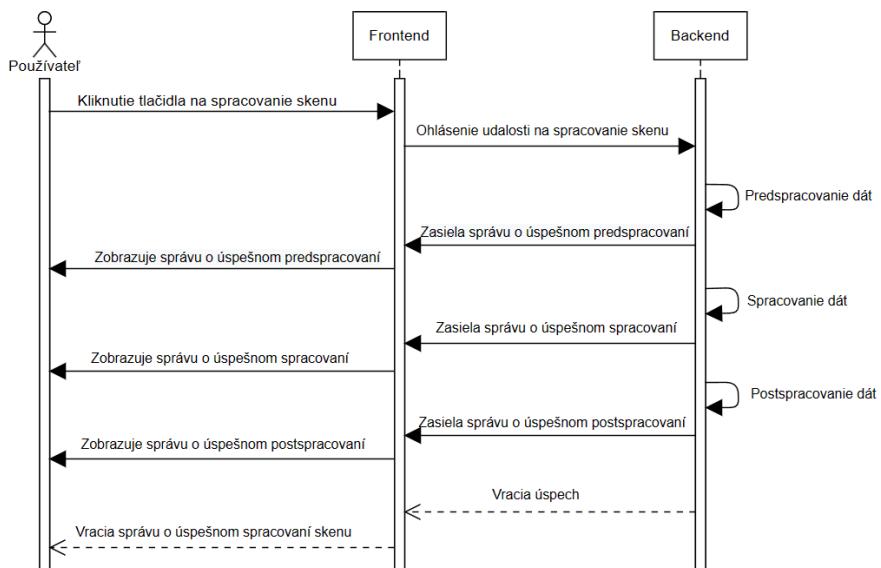
---

Na to bude implementovaný prieskumník súborov. Toto bude prieskumník daného operačného systému, tým pádom je používateľ už oboznámený s týmto rozhraním. Tým pádom ľahko a elegantne vie vybrať súbor na spracovanie.

Po tejto udalosti sa budú dátá segmentovať, ale toto bude prebrané do detailu neskôr v *implementácii 4*. Na frontende bol definovaný prototyp ako bude vyzerat zobrazenie jednotlivých rezov skenu, prechádzanie medzi nimi a umiestňovanie značiek. Dané rozhranie je potrebné prepojiť s dátovými štruktúrami na backende, z ktorých sa jednotlivé rezy budú ľahko a elegantne spracovať.

Na vizualizáciu skenu sa bude otvárať ďalšie okno aplikácie, kde okno sa prispôsobí veľkosti daného rezu skenu, aby bolo jednoducho zrealizovaťné získavanie súradníc pri umiestňovaní značiek na sken. Vstupnými udalosťami používateľa bude naviazaná udalosť na prechádzanie rezov skenu a umiestňovanie značiek na daný rez skenu.

Sekvenčný diagram zobrazujúci tento tok by vyzeral teda nasledovne:



Obr. 3.14: Priebeh spracovania skenu

### **3.1.2.2 Spracovanie medicínskeho zobrazenia**

Ako už bolo spomenuté, najprv je potrebné lokalizovať miesto, kde rádiológ v danom medicínskom zobrazení označil nález. Zoberú sa pixelové súradnice daného rezu skenu, kde rádiológ označil nález. Následne sa zistí, že či toto miesto sa nachádza v nejakom orgáne. Toto sa overí prostredníctvom implementácie nástroja na to určeného, pomocou ktorého prebehne segmentácia orgánov v danom skene.

Po segmentácii orgánov daného medicínskeho zobrazenia bude možné určiť, že kde sa orgány nachádzajú, zobraziť segmentáciu, poprípade aj zistiť objem daného orgánu. Táto funkcionálita bude naviazaná na vstupnú operáciu, ktorá je používateľovi dostupná pri prezeraní skenu.

### **3.1.2.3 Prenášanie značiek z medicínskeho zobrazenia do 3D avatara**

Ako poslednú vec treba prepojiť interakciu s medicínskymi zobrazeniami a 3D avatarom. Je nutné vyrovnať alebo namapovať body z jedného súradnicového systému (reprezentovaného 2D obrázkom rezom skenu) do druhého (3D modelu avatara).

V tomto prípade je nevyhnutné disponovať súradnicami orgánov v medicínskom zobrazení a tiež v 3D modele avatara. Súčasne je nevyhnutné ešte odhadovať polohu nálezov, ktoré rádiológ zakreslil do rezov daného skenu.

Prichádza do úvahy metóda ohraničujúcich boxov [23] (celkový algoritmus návrhu riešenia z obrázku 3.15), keďže sken je vyjadrený 3D dátovou štruktúrou (2D polia vrstvené na sebe, čo tvorí trojrozmerné pole), segmentácie sú vyjadrené 3D dátovou štruktúrou (True-False trojrozmerné pole) a 3D ľudský atlas má dostupné súradnice, tak je možné vytvoriť ohraničujúce kvádre okolo všetkých dôležitých

### Kapitola 3. Návrh vlastného riešenia

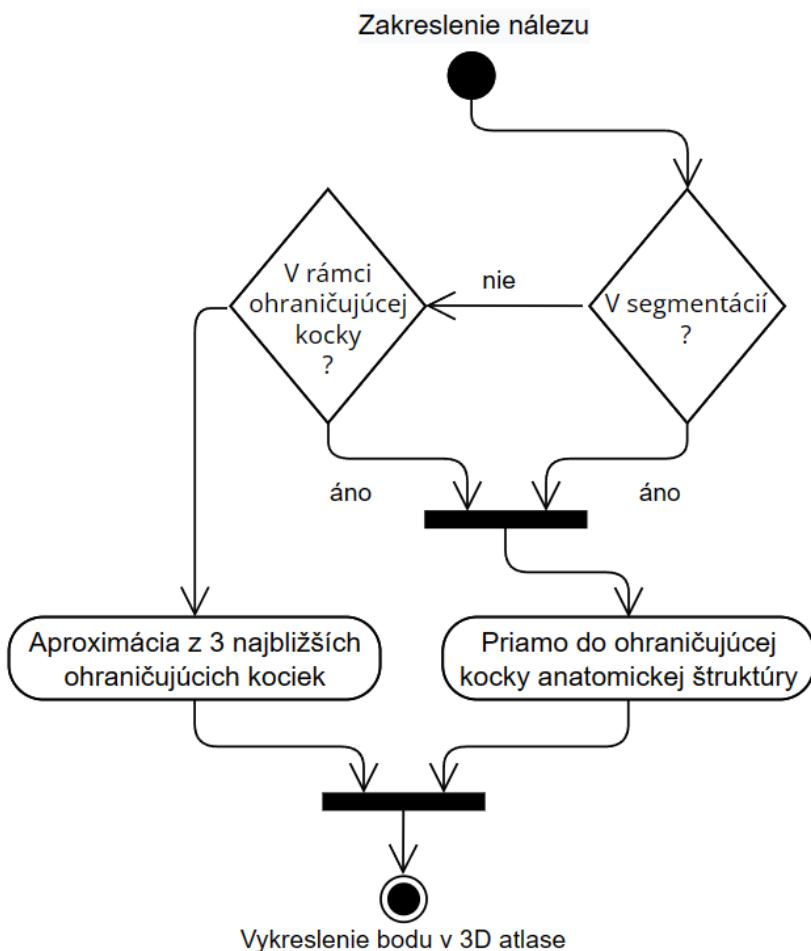
---

štruktúr (aj všeobecných ako napríklad trup), ktoré dávajú priestor na approximáciu súradníc.

Vzhľadom k tomu, že v medicínskom zobrazení aj v 3D avatare sú pevné body (orgány, svaly, kosti,...), touto metódou je možné approximovať body vyznačené rádiológom v skene do 3D avatara takým spôsobom, že sa po vyznačení skontroluje v akom ohraničujúcim boxe sa práve bod nachádza a podľa toho ohraničujúceho kvádra zo segmentácie medicínskeho zobrazenia sa mapuje bod do ohraničujúceho kvádra 3D ľudského atlasu.

Avšak toto riešenie nezahŕňa všetky možné okrajové prípady a v kapitolách *Implementácia 4*, *Zhrnutie výsledkov 5* a *Záver 6* im bude venovaná značná pozornosť a možné nápady pre vylepšenia.

Široký prehľad tohto riešenia daného problému by sa dalo znázorniť nasledujúcim diagramom, ktorý opisuje postup zvládnutia tejto úlohy:



Obr. 3.15: Zobrazenie prenášania značiek z medicínskeho zobrazenia do 3D avatara. Ak sa bod nachádza priamo v segmentácii, tak sa priamo mapuje do orgánu, keďže sa ľahko určuje jej poloha. Ak sa nenachádza v žiadnej segmentácii, ale je v rámci ohraničujúceho kvádra anatomickej štruktúry, tak sa bude jeho pozícia odvýjať od toho. Ak sa nenachádza ani v jednom, tak sa poloha approximuje z 3 najbližších ohraničujúcich kvádrov anatomických štruktúr.

# Kapitola 4

## Implementácia

Implementácia je realizovaná v programovacom jazyku *Python 3*.

Na vykreslovanie 3D modelu ľudskej anatómie bol použitý rámec *OpenGL*. Tento rámec slúži na vytváranie grafických aplikácií, ktoré využívajú 2D alebo 3D grafiku.

Na odchytávanie udalostí ako je klik myšou, ťuknutie klávesu alebo podržanie myši v projekte je použitý rámec *PyGame*. Je to knižnica určená na vytváranie multimediálnych aplikácií. Poskytuje jednoduché a priamočiare rozhranie pre prácu s grafikou, zvukom a ovládaním klávesnice a myši.

Ďalej na zobrazovanie ľudského atlasu v danom prostredí bude použitý rámec *PyWavefront*, ktorý slúži na načítanie, spracovanie a prácu s 3D modelmi. Je špecializovaný na formát OBJ, ktorý je široko používaný pre reprezentáciu trojrozmerných objektov a scén v počítačovej grafike.

Pre efektívne narábanie s dátovými štruktúrami bude využitá knižnica *cotypes* a text *numpy*.

## Kapitola 4. Implementácia

---

*Ctypes* knižnica ponúka vytváranie a manipuláciu dátových typov z programovacieho jazyka C do programovacieho jazyka Python pre efektívnejšie narábanie s dátovými štruktúrami.

*Numpy* je knižnica určená pre vedecké výpočty a manipuláciu s numerickými dátami. Poskytuje výkonné nástroje na prácu s poliami a maticami, čo umožňuje efektívne vykonávanie matematických operácií, lineárnu algebru, analýzu dát a iné numerické úlohy.

Tieto knižnice sú potrebné pre efektívne narábanie s dátovými štruktúrami, ktoré nám poskytne po segmentácii medicínskych zobrazení neúronová siet.

Ako už bolo spomínané v predchádzajúcich kapitolách, na narábanie s medicínskymi zobrazeniami je v projekte využitý rámec *MONAI*, ktorý slúži na predspracovanie a augmentáciu dát alebo populárne architektúry modelov umelej inteligencie, ako napríklad konvolučné neúronové siete.

*MONAI* poskytuje bohatú kolekciu nástrojov a funkcií pre vývoj a validáciu modelov umelej inteligencie zameraných na analýzu skenov, ako sú napríklad magnetická rezonancia, počítačová tomografia a röntgenové snímky. Pracovať s touto knižnicou bolo v projekte umožnené vďaka [28].

Na segmentáciu anatomických štruktúr v medicínskych zobrazeniach bude využité dva modely konvolučnej neurónovej siete UNet [15], kde pre počítačovú tomografiu sa použije TotalSegmentator [40] a pre magnetické rezonancie model z publikácie [1].

Na využitie týchto modelov bude použitá knižnica *PyTorch*. Tento nástroj je široko používaný pre vedecké výpočty a vývoj modelov hlbokého učenia.

Po segmentácii medicínskych skenov je potrebné pre jednotlivé vrstvy skenu nastaviť pevnú veľkosť, aby pri mapovaní bodov v grafickom používateľskom rozhraní

nevznikali nekonzistentnosti. Na to bude použitý rámec *skimage*. Tento rámec obsahuje kolekciu algoritmov pre spracovanie rôznych obrazových reprezentácií v počítačovom videní.

Pre jednotlivé segmentácie anatomických štruktúr tela je potrebné aj odstrániť z nich šum a utvrdiť tvar. Na to bude použitý rámec *sciPy*, ktorý má súbor takýchto funkcií a nástrojov, či už za účelom matematických, vedeckých alebo inžinierskych výpočtov.

Na neposlednom mieste sa treba sústrediť aj na používateľské rozhranie a na interakciu používateľa s aplikáciou. Na posledné spracovanie vyhotovených a vysegmentovaných skenov bude použitá knižnica *Matplotlib*, ktorá utvrdí konzistentnosť výsledných snímkov pre vykreslovanie skenov používateľovi. Knižnica *Matplotlib* slúži na vizualizáciu dát a tvorbu grafov a vizuálnych prezentácií.

Na záver je použitá knižnica *PyQt*, ktorá umožní rádiológovi zobraziť sken po spracovaní a vykreslovať do neho nálezy, ktoré boli v danom medicínskom zobrazení pacienta nájdené.

## 4.1 Zadefinovanie štruktúry behu aplikácie

Aplikácia je implementovaná s použitím dvoch vlákien, ktoré medzi sebou komunikujú a zabezpečujú funkcionality používateľského grafického rozhrania pomocou rámca *PyQt* a 3D grafické zobrazenie s využitím *OpenGL* a *Pygame* knižníc. Štruktúra behu aplikácie je nasledovná:

1. **Hlavné vlákno s PyQt obsluhou:** Toto vlákno je zodpovedné za inicializáciu a riadenie grafického užívateľského rozhrania. Obsluha udalostí, ako je napríklad vyznačenie náleزو v medicínskom zobrazení, výber súboru skenu, sú spracovávané v tomto vlákne.

2. **Vedľajšie vlákno s OpenGL a Pygame obsluhou:** Toto vlákno sa stará o inicializáciu a riadenie grafického vykresľovania okna s atlasom ľudského tela, filtrovacími a riadiacimi tlačidlami. Tu sa vykonávajú operácie spojené s vykresľovaním 3D modelov, spracovávaním udalostí a všetky operácie súvisiace s grafickým výstupom.

Komunikácia medzi týmito dvoma vláknami je zabezpečená pomocou mechanizmov synchronizácie a zdieľania spoločných premenných, ktoré sa kontrolujú v cykle udalostí na obidvoch vláknach.

Hlavné vlákno môže posielat príkazy a dátá vedľajšiemu vláknu na základe užívateľskej interakcie, zatiaľ čo vedľajšie vlákno môže posielat príkazy a dátá hlavnému vláknu o udalostiach získaných počas vykonávania grafických operácií alebo taktiež interakcie používateľa.

## 4.2 Zobrazenie 3D atlasu tela

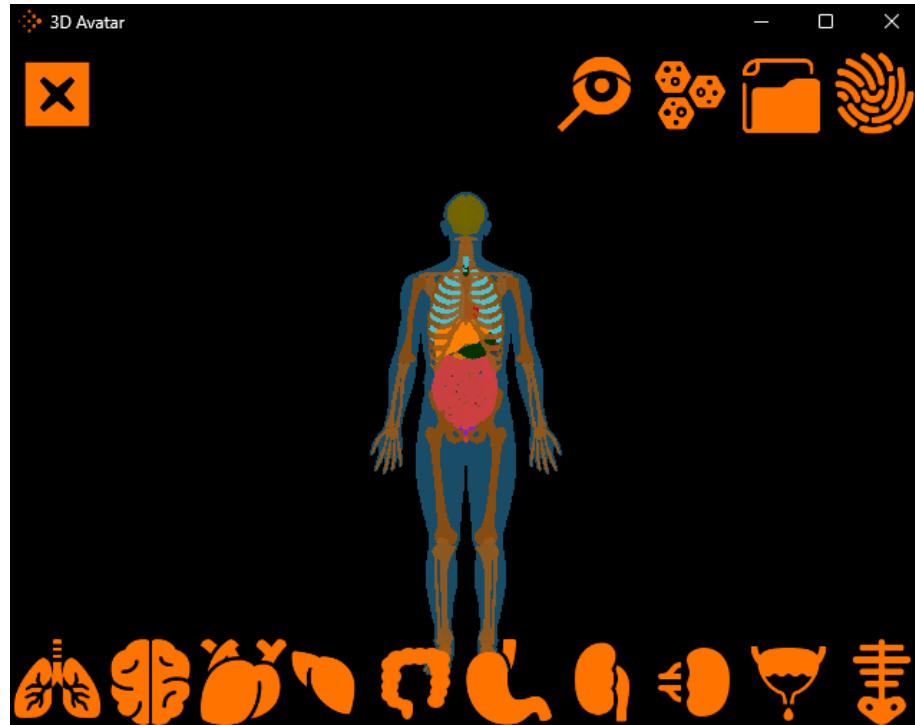
Na zobrazenie 3D atlasu tela boli exportovať jednotlivé anatomické štruktúry ľudského tela do OBJ formátu. Následne pomocou knižnice *PyWavefront* boli načítané do behu programu. Ďalej pre jednotlivé načítané anatomické štruktúry sú zadefinované VBO (angl. vertex buffer object) a VAO (angl. vertex array object) premenné. Tu sa vypočítajú aj jednotlivé ohraničujúce boxy okolo jednotlivých anatomických štruktúr a uložia sa do premenných, aby s nimi bolo možné narábať neskôr.

Po tomto sa bude narábať s rámcem *OpenGL* a zadefinuje sa perspektívna projekcia, povolí sa priestorové vykresľovanie a vykreslia sa jednotlivé anatomické štruktúry, vypne sa priestorové vykresľovanie a vykreslia sa aj nálezy (aby boli na vrchu vykreslené) vo vykresľovacom cykle.

Teraz sa zadefinuje ortografická projekcia pre vykresľovanie statických objektov a

začnú sa vykresľovať tlačidlá na skrytie jednotlivých orgánov a riadiace tlačidlá programu vo vykresľovacom cykle.

Finálna obrazovka vyzerá nasledovne:



Obr. 4.1: Hlavná obrazovka aplikácie zobrazujúca 3D avatara, filtračné a riadiace tlačidlá

### 4.3 Predspracovanie dát

Ako prvé sa nakopíruje cesta k vybranému súboru/priečinku s dátami skenu. Po uložení tejto adresy do premennej sa použije *MONAI* knižnica a vloží sa ako vstupný parameter adresa k dátam skenu do funkcie na načítanie zobrazenia.

Táto funkcia podporuje ITK, Nibabel, Numpy a Pydicom formáty, ale implementácia používateľského rozhrania, ktorá je zdokumentovaná neskôr podporuje vy-

bratie iba priečinku a nie súbora. Následne sa spraví transformácia jeho zobrazenia a zmena orientácie. [28]

## 4.4 Segmentácia medicínskych zobrazení

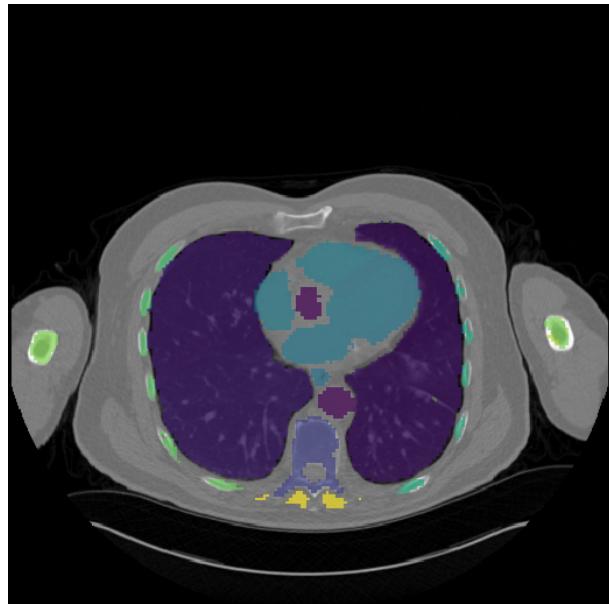
Pri segmentácii sa načíta meno daného modelu neurónovej siete podľa toho, že či medicínske zobrazenie je počítačová tomografia alebo magnetická rezonancia. Keďže je priam nemožné to zistiť z dát pri všetkých možných formátoch, ktoré boli spomenuté, tak v projekte aplikácia určuje, že či ide o magnetickú rezonanciu alebo počítačovú tomografiu tak, že sa program pozrie na meno daného súboru dát medicínskeho zobrazenia a hľadá v ňom skratku mr alebo ct a podľa toho rozhodne.

Teraz sa pomocou knižnice *MONAI* model stiahne, ale predtým najprv skontroluje, že či sa už nenachádza v súborovej štruktúre implementácie projektu a ak ho nájde, tak ho využije a nestahuje ho znova.

Následne sa načíta čítač konfigurácie modelu a predspracuje podľa neho dátu. Ďalej sa načíta model a pomocou knižnice *PyTorch* vykoná evaluáciu a vykoná segmentáciu. Po vykonanej evaluácii model podľa svojej konfigurácie ešte postsprocesuje dátu [28].

Nakoniec pomocou knižnice *SciPy* sa jednotlivé segmentácie vyčistia od šumu binárnu eróziu a utvrdí sa im tvar binárnu dilatáciou. [32]

Segmentácia medicínskeho zobrazenia vo finálnej verzií už postspracovaná vyzerá nasledovne:



Obr. 4.2: Zobrazenie zosegmentovaných anatomických štruktúr v medicínskom zobrazení

## 4.5 Postspracovanie dát

Na pripravenie vysegmentovaných dát medicínskeho zobrazenia pre vykreslovanie do používateľského rozhrania je vždy potrebné ich urobiť konzistentné, aby sedel súradnicový systém vyznačovania nálezov.

Najprv je potrebné každú vrstvu skenu preškálovať na rozmery  $512 * 512$ . Tento rozmer je najčastejšie používaný rozmer CT skenov generovaných súčasnými CT skenermi. Niektoré rekonštrukcie MR obrázkov používajú menšie rozlíšenie, napríklad  $128 * 128$  pixelov. Prichádzajú na trh aj CT skenery s vysokým rozlíšením  $1024 * 1024$ . Kvôli tomuto treba škálovať vrstvu skenu na rozmery  $512 * 512$ .

Po tomto kroku sa vymenia dimenzie pre príjemnejšie narábanie so skenom. Prvá dimenzia bude reprezentovať vrstvu skenu a posledné dve dimenzie budú reprezentovať súradnice  $x$  a  $y$ , ktoré reprezentujú pixel v danej vrstve skena. Teraz sa vypočíta ohraničujúci box pre jednotlivé segmentácie anatomických štruktúr a

uložia sa do premenných pre pozdejšie využívanie.

Ďalej je v implementácii vytvorená kópia už spracovaného medicínskeho zobrazenia, na ktorú sa nalepia segmentácie pre vizualizáciu úspešnosti neurónovej siete, ktorú si používateľ aplikácie môže kedykoľvek zobraziť, pri vyznačovaní nálezov.

Postsprocesované medicínske zobrazenie vizualizované v aplikácií vyzerá nasledovne:



Obr. 4.3: Zobrazenie postsprocesovaného rezu medicínskeho zobrazenia

## 4.6 Grafické používateľské rozhranie

Je potrebné používateľovi zobraziť spracované dát prostredníctvom ďalšieho okna, na ktorom si bude vedieť vykresľovať nálezy do skenu ľudského tela.

Po kliknutí na ikonu pre zobrazenie dát vyskočí ďalšie okno, ktoré od používateľa čaká výber farby, akým bude vykresľovať do skenu vykresľovať. Rámcem *PyQt* má

## Kapitola 4. Implementácia

---

na toto už pripravenú klasu, ktorá toto umožnuje jednoducho naimplementovať. Po vybraní farby (ak si používateľ farbu nevyberie a pokračuje ďalej, vyberie sa predvolene nastavená farba) sa toto okno uzavrie a otvorí sa nové okno už s načítaným skenom s veľkosťou okna  $512 * 512$ . Táto veľkosť okna sa nedá meniť, aby súradnice kliknutia myši sa zhodovali čo najpresnejšie so zobrazenou vrstvou skenu.

Po kliknutí myšou sa prepočíta pozícia v 3D modely avatara a umiestni sa bod v reálnom čase na danú pozíciu zakliknutú v skene zobrazenú v tomto okne a aj v okne s 3D avatarom.

Okno, ktoré zobrazuje sken a umožňuje jeho listovanie a značenie klinických nálezov do neho, vyzerá nasledovne:



Obr. 4.4: Zobrazenie medicínskeho zobrazenia v okne pre listovanie a vyznačovanie klinických nálezov

## 4.7 Prenášanie vyznačených nálezov z medicínskeho zobrazenia do 3D avatara

Po vyznačení bodu rádiológom v skene sa zoberú súradnice tohto vyznačenia, čiže na daná vrstva a súradnice  $x, y$  na vyznačenej vrstve.

Teraz zbehne naprieč všetkými segmentáciami funkcia, ktorá hľadá, či sa daná súradnica vyznačenia nachádza v nejakej segmentácií. Ak sa nachádza v nejakej segmentácií, tak sa zoberú kordináty ohraničujúceho boxu danej anatomickej štruktúry z 3D avatara a vypočíta sa veľkosť jedného dielika segmentácie anatomickej štruktúry v 3D reprezentácií anatomickej štruktúry a určí sa hodnota v 3D priestore pre každú os (v 3D priestore  $x, y, z$ ). Na toto určovanie sa používa v implementácií nasledujúci vzorec:

$$x = x_{3d\_at\_init\_coord} + [(x_{3d\_at\_size}/x_{arr\_at\_size}) * (|i_{arr\_marked\_coord} - x_{arr\_at\_init\_coord}|)]$$

Na začiatku  $x$  je výsledná vypočítaná súradnica. Premenná  $x_{3d\_org\_init\_coord}$  je začiatok súradnice ohraničujúceho boxu anatomickej štruktúry v 3D priestore, od ktorej už len vyššie sa bude počítať výsledná súradnica, keďže je začiatočná. V zátvorke  $(x_{3d\_at\_size}/x_{arr\_at\_size})$  figurujú dve premenné, ktorými dostane program veľkosť jedného dielika segmentácie v 3D priestore anatomickej štruktúry. Zoberie veľkosť ohraničujúceho boxu 3D anatomickej štruktúry a predelí ho veľkosťou segmentácie anatomickej štruktúry. Tento dielik sa potom násobi s absolútou hodnotou  $(i_{arr\_marked\_coord} - x_{arr\_at\_init\_coord})$ . V tejto zátvorke figuruje index vyznačenej pozície, od ktorého je odčítaný začiatočný index ohraničujúceho kvádra segmentácie, aby bol získaný reálny index v danom ohraničujucom boxe, keďže segmentácia anatomickej štruktúry je reprezentovaná veľkosťou dátovej štruktúry celého skenu v trojrozmernom poli pravdivých a záporných hodnôt. Ohraničujúci box tejto segmentácie predstavujú sa tvorí iba z pravdivých hodnôt.

## Kapitola 4. Implementácia

---

Na druhej strane, ak sa vyznačený bod nenachádza v žiadnej segmentácii, tak sa najprv skontroluje, že či je aspoň v ohraničujúcom kvádri danej segmentácie. Ak sa tam nachádza, tak sa vyberie tá segmentácia a podľa nej sa spraví to isté ako v predošom kroku.

Nakoniec, ak sa vyznačený bod nenachádza v žiadnej segmentácii ani v jej ohraničujúcom boxe, tak sa zoberú 3 najbližšie segmentácie a toto isté sa vypočíta pre každú jednu z týchto troch segmentácií. Tým boli získané 3 súradnice, nad ktorými sa spraví priemer ich súradníc a podľa toho sa approximuje poloha vyznačeného bodu v 3D atlase ľudského tela.

V aplikácií po vyznačení klinických nálezov v medicínskom zobrazení napríklad v pečeni červenou farbou to vyzerá nasledovne:



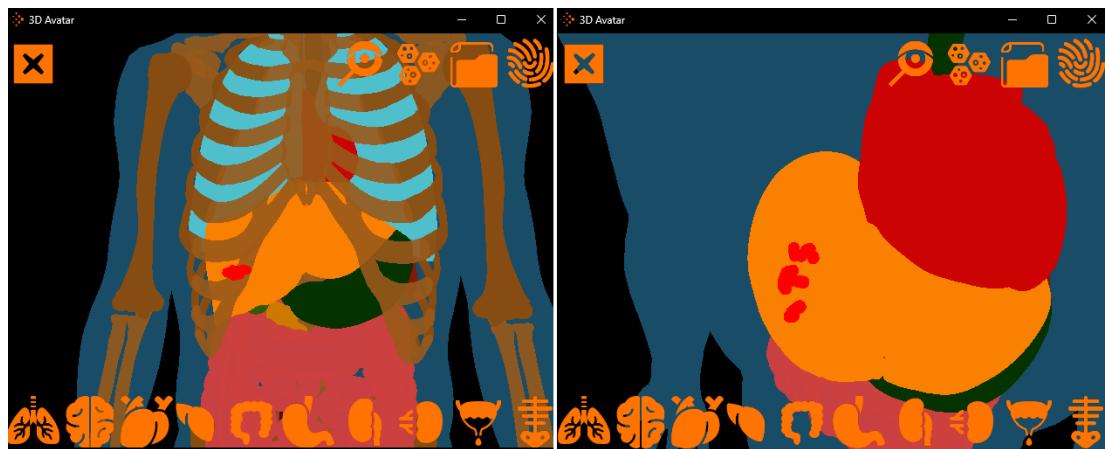
Obr. 4.5: Obrázok zobrazujúci označené klinické nálezy (ilustratívne) v pečeni

V hlavnom okne v reálnom čase kreslenia klinických nálezov do medicínskeho zobrazenia sa v 3d atlase ľudského tela (avatara) tieto vyznačené klinické nálezy

## Kapitola 4. Implementácia

---

zobrazené v obrázku 4.5 zobrazia na svoju korešpondujúcu pozíciu nasledovne:



Obr. 4.6: Obrázok na ľavej strane zobrazuje priblíženého avatara zpredu, kde nie sú odfiltrované žiadne orgány pre lepšiu viditeľnosť nálezov. Obrázok na pravej strane zobrazuje pohľad kamery zhora na avatara, kde sú odflitrované kosti a pľúca pre lepšiu viditeľnosť nálezov.

# Kapitola 5

## Zhrnutie výsledkov

V projekte je veľa háklivých častí, ktoré musia zapadnúť do seba akurát, aby mal výsledok umiestňovania bodov z medicínskeho zobrazenia do trojrozmerného ľudského atlasu zmysel. Najprv bolo ale spravené nad frontendom užívateľské testovanie, ktorého výsledky hodnotia prácu s aplikáciou. Ako posledné je zhodnotenie modelu neurónovej sieťe a kvalitatívne testovanie umiestňovania klinických nálezov z CT/MR do 3D avatara.

### 5.1 Testovanie použiteľnosti

V rámci testovania použiteľnosti boli nasledované štandardizované postupy, ktoré zahrňajú vytvorenie testovacích scenárov, vybranie vhodných účastníkov, sledovanie interakcií s produkтом a zhromažďovanie spätej väzby. Tieto metódy umožnili získať podrobné informácie o tom, ako testovaní používatelia vnímajú a interagovali s aplikáciou.

Na testovanie bolo vybraných 5 ľudí, ktorí pracovali s aplikáciou ako bolo uvedené v tabuľke 3.13. Detailnejšie informácie ohľadom používateľov sú uvedené v

## Kapitola 5. Zhrnutie výsledkov

---

nasledujúcej tabuľke:

Testovací používateľ	TP1	TP2	TP3	TP4	TP5
Alias	Ján	Pavol	Lucka	Miroslav	Michal
Dátum testovania	11/05/2024	11/05/2024	12/05/2024	13/05/2024	13/05/2024
Čas testovania	13:24	12:16	10:32	19:21	18:53
Jazyk	Slovenčina	Slovenčina	Slovenčina	Slovenčina	Slovenčina
<b>Všeobecné informácie</b>					
Pohlavie	Muž	Muž	Žena	Muž	Muž
Vek	24	19	22	25	19
<b>Zrakové postihnutie</b>					
Pomôcka na videnie	Nie	Nie	Nie	Okuliare na čítanie	Okuliare do diaľky
Farboslepost'	Nie	Nie	Nie	Nie	Nie
<b>Vzdelanie</b>					
Navštevovaná škola	STU FIIT	GAHS	PraF UK	EF UMB	SŠKBB
Najvyššia dosiahnutá úroveň vzdelania	2. stupeň vysokej školy	Základná škola	Stredná škola	Stredná škola	Stredná škola

Obr. 5.1: Prehľad používateľov, ktorí otestovali aplikáciu

Boli sledované rôzne metriky pri ich testovaní aplikácie. Najdôležitejšími z nich boli 3 hlavné metriky a tie sú: miera dokončenia úlohy, čas dokončenia úlohy a miera chybovosti.

Metriky ohľadom miery dokončenia úloh poukazuje či museli byť používatelia asistovaní pre dokončenie úlohy alebo či sa im to vôbec podarilo dokončiť.

Metrika času dokončenia úlohy poukazuje či používatelia nemali problém s nájdenním daných komponentov vyžadovaných v úlohe.

Posledná metrika, ktorá sa zameriava na mieru chybovosti používateľa pri vykonávaní úlohy a teda či si neplietol nejaké komponenty s inými alebo funkcionálitu komponentov s inými komponentami a podobne.

Tu sú tabuľky znázorňujúce výsledky týchto 3 hlavných sledovaných metrík:

**Miera dokončenia úlohy**

	Úloha 1	Úloha 2	Úloha 3	Úloha 4
<b>TP1</b>	1	1	1	1
<b>TP2</b>	1	1	1	1
<b>TP3</b>	1	1	1	1
<b>TP4</b>	1	1	1	1
<b>TP5</b>	1	1	1	1
<b>%</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>

Obr. 5.2: Miera splnenia úlohy ( 0-nesplnená, 1-splnená, 0.5-bola poskytnutá pomoc)

**Dĺžka času dokončenia úlohy**

	Úloha 1	Úloha 2	Úloha 3	Úloha 4
<b>TP1</b>	3.42	13.29	10.68	6.91
<b>TP2</b>	5.4	13.27	15.10	13.39
<b>TP3</b>	8.99	5.77	8.65	14.26
<b>TP4</b>	7.21	9.85	12.62	13.11
<b>TP5</b>	6.54	11.35	18.94	9.56
<b>Avg</b>	6.312	10.706	13.198	11.446
<b>Std</b>	1.856	2.784	3.576	2.778

Obr. 5.3: Čas dokončenia úlohy (meraný v sekundách)

**Miera chybovosti**

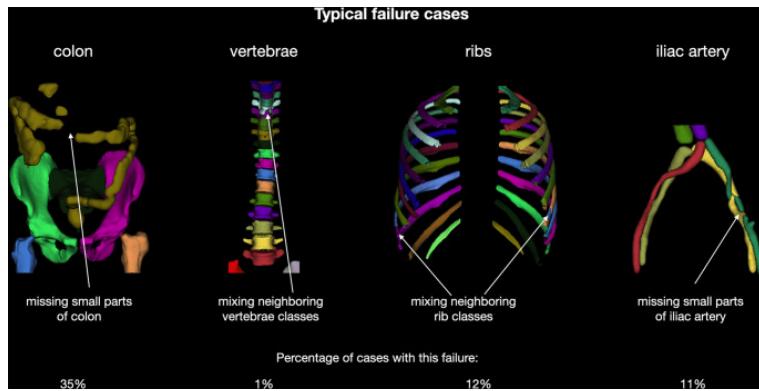
	<b>Úloha 1</b>	<b>Úloha 2</b>	<b>Úloha 3</b>	<b>Úloha 4</b>
<b>TP1</b>	0	1	0	0
<b>TP2</b>	0	0	0	1
<b>TP3</b>	0	0	0	0
<b>TP4</b>	0	0	0	0
<b>TP5</b>	0	0	0	0
<b>Avg</b>	0	0.2	0	0.2

Obr. 5.4: Počet chýb pre každú úlohu

Dáta z týchto tabuľiek (5.2, 5.3, 5.4) poukazujú na úspešnú implementáciu frontendu aplikácie. Je potrebné poukázať, že používatelia nemali najmenší problém s používaním aplikácie, čo vyplýva z výsledkov tohto testovania. Taktiež je potrebné poznamenať, že aplikácia poskytuje iba 2 obrazovky a rozpoloženie komponentov je extrémne jednoduché a ich funkcionality sú veľmi priamočiare z pohľadu používateľa.

## 5.2 Vplyv segmentácie na umiestňovanie klinických nálezov z CT/MR do 3D avatara

Pri umiestňovaní klinických nálezov zo skenu do 3D avatara najviac záleží na správne vykonanej segmentácii. Ak neurónová sieť pochybí v tomto bode, tak potom umiestnenie bodov v skene pacienta vôbec nemusí súhlasiť s umiestnením bodov v 3D avatare. Napriek vysokému koeficientu Dice a skóre NSD model [40] v niektorých prípadoch zlyháva.

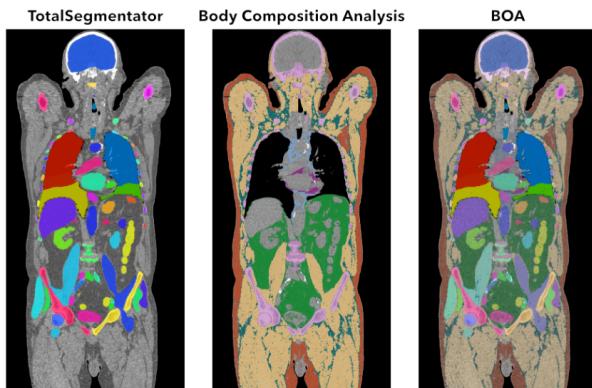


Obr. 5.5: Prehľad typických prípadov porúch modelu [40]

Na obrázku 5.5 sú znázornené najtypickejšie prípady zlyhania, napríklad chýbajúce malé časti hrubého čreva alebo bedrových tepien a zámena susedných stavcov a rebier. Tieto prípady sú aj perecentuálne obodované, že na koňkých medicínskych zobrazeniach daný problém nastal v testovacej množine dát. Je dôležité poznamenať, že čím sú dátá kvalitnejšie, tak tým tento model lepšie funguje.

Implementovaný návrh tohto projektu tiež nezahŕňa neštandardné polohy pacienta, rôzne orientácie končatín a podobne. Ak je pacient naozaj zosnímaný skenovacím zariadením takýmto spôsobom, tak aplikácia neurčuje označené body z medicínskeho zobrazenia do 3D atlasu ľudskej anatómie korektne.

Ako posledné je potrebné poznamenať, že určovanie polohy mimo ohraničujúcich boxov vysegmentovaných anatomických štruktúr si vyžaduje komplexnejšiu implementáciu. Síce zobranie troch najbližších ohraničujúcich kvádrov segmentácií je uspokojivé riešenie, nie je však optimálne. Avšak celý tento algoritmus by ani nemusel byť implementovaný, keďže čisto nová technológia bola publikovaná 3 mesiace dozadu. BOA [13] rozsegmentuje drívivú väčšinu všetkého tkiva v ľudskom tele a tým pádom by sa dalo celkovo všetko presne určovať priamo zo segmentácií.



Obr. 5.6: Porovnanie TotalSegmentator[40], BodyCompositionAnalysis[14] a BOA[13]

### 5.3 Testovanie aproximovaného umiestňovania nálezov z 3 najbližších segmentácií

Je potrebné otestovať approximáciu umiestňovania klinických bodov z medicínskeho zobrazenia do 3D atlasu ľudskej anatómie, keď sa priamo nemapuje zo segmentácie, ale keď sa approximuje pozícia z 3 najbližších segmentácií.

Aproximovanie pozície bolo otestované najprv na počítačovej tomografií. V CT zobrazení bolo vyhotovené v rôznych typoch skenov a tie sú: sken celého tela, hrudného koša, brucha a trupu. Testovacia množina skenov bola zostavená z 10 skenov, kde 3 boli celého tela, 3 hrudného koša, 2 brucha a 2 trupu. Testovalo sa na týchto skenoch 5 špecifických bodov. V priemere bolo umiestnenie týchto bodov v 3D avatare vzdialené 0.94 cm od ich pravej pozície v 3D avatare.

Aproximovanie pozície bolo potom otestované v magnetickej rezonancii. V MR zobrazení bolo vyhotovené iba v jednom type skenu a to je sken prostaty. Testovacia množina skenov bola zostavená z 10 skenov tohto typu. Testovalo sa na týchto skenoch 5 špecifických bodov. V priemere bolo umiestnenie týchto bodov v 3D avatare vzdialené 0.27 cm od ich pravej pozície v 3D avatare.

# Kapitola 6

## Záver

Práca sa zameriava na vývoj lekárskych vyšetrení zameraných na zlepšenie interpretácie lekárskych snímok rádiológmi, najmä s využitím 3D avatara. Riešenie integruje pokročilé techniky vykresľovania a interaktívne nástroje na pomoc pri analýze CT/MR snímok. 3D avatar umožňuje rádiológom vizualizovať a interagovať so skenmi v troch rozmeroch, pričom kombinuje rádiologické anotácie, segmentáciu orgánov a 3D modelovanie s cieľom zlepšiť diagnostické procesy.

Integráciou nálezov do 3D modelu systém ponúka komplexné pochopenie vzťahov medzi abnormalitami a anatomickými štruktúrami. Metodika zahŕňa použitie CT/MR skenov z internej databázy spoločnosti Siemens Healthineers, využitie rámca MONAI na predspracovanie obrazu, konvolučnej neurónovej siete U-Net modelu TotalSegmentator na segmentáciu orgánov, rámca PyQt na interakciu s rádiológom a rámca OpenGL na 3D vykresľovanie modelov ľudskej anatómie.

Dosiahnuté výsledky poukazujú na potenciál, ktorý by mal naimplementovaný prototyp na súčasný stav, v ktorom sa nachádza prehľad o klinických nálezoch vo forme štruktúrovaného textu, prípadne zoznamu vo forme hierarchických úrovní

## Kapitola 6. Záver

---

podľa častí tela a orgánov. Cieľom práce bolo preskúmať a navrhnúť prototyp riešenia automatickej transformácie pozície nálezu na CT/MR snímke konkrétneho pacienta do normalizovaného grafického zobrazenia avatara. Na základe dosiahnutých výsledkov v kapitolách 4 a 5 sa tento cieľ podarilo splniť.

Na záver by bolo vhodné poznamenať, že sa nám podarilo vytvoriť aplikáciu, ktorá je konkurenčná súčasným riešeniam. Avšak zostáva mnoho miesta pre zlepšenie, ako napr. riešenie orientácie ohraničujúcich kociek a optimálny algoritmus pre nálezy úplne mimo ohraničujúcich boxov vysegmentovaných anatomických štruktúr ľudského tela alebo na miesto tohto algoritmu implementovať model BOA.

Taktiež je možné analyzovať rýchlosť systému, využitie pamäte a možnosti automatického predspracovania obrázkov zo skenerov tak, aby rýchlosť reakcie systému už priamo pri klinickom využití systému v reálnom čase, bez oneskorení viditeľných rádiológom a bez výraznej záťaže výkonnosti systému pri paralelnom užívaní serveru množstvom užívateľov v danom medicínskom zariadení.

# Literatúra

- [1] Lisa C. Adams et al. “Prostate158 - An expert-annotated 3T MRI dataset and algorithm for prostate cancer detection”. In: *Computers in Biology and Medicine* 148 (2022), s. 105817. ISSN: 0010-4825. DOI: <https://doi.org/10.1016/j.combiomed.2022.105817>. URL: <https://www.sciencedirect.com/science/article/pii/S0010482522005789>.
- [2] Mohamed Alloghani et al. “A systematic review on supervised and unsupervised machine learning algorithms for data science”. In: *Supervised and unsupervised learning for data science* (2020), s. 3–21.
- [3] Isaac Bankman. *Handbook of medical image processing and analysis*. Elsevier, 2008.
- [4] Avijit Dasgupta a Sonam Singh. “A fully convolutional neural network based structured prediction approach towards the retinal vessel segmentation”. In: *2017 IEEE 14th international symposium on biomedical imaging (ISBI 2017)*. IEEE. 2017, s. 248–251.
- [5] Andres Diaz-Pinto et al. “Monai label: A framework for ai-assisted interactive labeling of 3d medical images”. In: *arXiv preprint arXiv:2203.12362* (2022).
- [6] *DICOM Documentation*. DICOM Manual. 2012–2024. URL: <https://dicom.innolitics.com/ciods/deformable-spatial-registration/deformable-spatial-registration/00640002>.

- [7] David J Eck. *Introduction to Computer Graphics*. 2021.
- [8] James D Foley et al. *Introduction to computer graphics*. Zv. 55. Addison-Wesley Reading, 1994.
- [9] A. Ghoneima et al. “Accuracy and reliability of landmark-based, surface-based and voxel-based 3D cone-beam computed tomography superimposition methods”. In: *Orthodontics & Craniofacial Research* 20.4 (2017), s. 227–236. DOI: <https://doi.org/10.1111/ocr.12205>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/ocr.12205>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1111/ocr.12205>.
- [10] Lee W Goldman. “Principles of CT and CT technology”. In: *Journal of nuclear medicine technology* 35.3 (2007), s. 115–128.
- [11] Yu Gordienko et al. “Deep learning with lung segmentation and bone shadow exclusion techniques for chest X-ray analysis of lung cancer”. In: *Advances in Computer Science for Engineering and Education 13*. Springer. 2019, s. 638–647.
- [12] John C. Gore. “Artificial intelligence in medical imaging”. In: *Magnetic Resonance Imaging* 68 (2020), A1–A4. ISSN: 0730-725X. DOI: <https://doi.org/10.1016/j.mri.2019.12.006>. URL: <https://www.sciencedirect.com/science/article/pii/S0730725X19307556>.
- [13] SHIP-AI group. *BOA: Body and Organ Analysis*. GitHub repository. 2023. URL: <https://github.com/UMEssen/Body-and-Organ-Analysis>.
- [14] Johannes Haubold et al. “BOA: a CT-based body and organ analysis for radiologists at the point of care”. In: *Investigative Radiology* (2023), s. 10–1097.
- [15] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature methods* 18.2 (2021), s. 203–211.

## Literatúra

---

- [16] Michael A Jacobs, Tamer S Ibrahim a Ronald Ouwerkerk. “MR imaging: brief overview and emerging applications”. In: *Radiographics* 27.4 (2007), s. 1213–1229.
- [17] R Beaulah Jeyavathana, R Balasubramanian a A Anbarasa Pandian. “A survey: analysis on pre-processing and segmentation techniques for medical images”. In: *International Journal of Research and Scientific Innovation (IJRSI)* 3.6 (2016), s. 113–120.
- [18] Hany Kasban, MAM El-Bendary a DH Salama. “A comparative study of medical imaging techniques”. In: *International Journal of Information Science and Intelligent System* 4.2 (2015), s. 37–58.
- [19] Sean Kitson. *Big Data in Medical Imaging: Pioneering Enhanced Patient Care and Diagnostic Precision*. Medical Imaging Blog. URL: <https://openmedscience.com/big-data-in-medical-imaging-pioneering-enhanced-patient-care-and-diagnostic-precision/>.
- [20] Jayanth Koushik. “Understanding convolutional neural networks”. In: *arXiv preprint arXiv:1605.09081* (2016).
- [21] Geon-hee Lee et al. “A study on the performance comparison of 3D file formats on the web”. In: *International journal of advanced smart convergence* 8.1 (2019), s. 65–74.
- [22] Le Lu et al. “Deep learning and convolutional neural networks for medical image computing”. In: *Advances in computer vision and pattern recognition* 10 (2017), s. 978–3.
- [23] Arsalan Mousavian et al. “3d bounding box estimation using deep learning and geometry”. In: *Proceedings of the IEEE conference on Computer Vision and Pattern Recognition*. 2017, s. 7074–7082.

- [24] Andreas S Panayides et al. “AI in medical imaging informatics: current challenges and future directions”. In: *IEEE journal of biomedical and health informatics* 24.7 (2020), s. 1837–1857.
- [25] Norbert J Pelc. “Recent and future directions in CT imaging”. In: *Annals of biomedical engineering* 42 (2014), s. 260–268.
- [26] S Perumal a Thambusamy Velmurugan. “Preprocessing by contrast enhancement techniques for medical images”. In: *International Journal of Pure and Applied Mathematics* 118.18 (2018), s. 3681–3688.
- [27] Guilherme Polo. *Pygtk, pyqt, tkinter and wxpython comparison*. 2017.
- [28] Luke Polson. *Python Metaphysics Series*. GitHub repository. 2023. URL: [https://github.com/lukepolson/youtube\\_channel/blob/main/Python%20Metaphysics%20Series/vid40.ipynb](https://github.com/lukepolson/youtube_channel/blob/main/Python%20Metaphysics%20Series/vid40.ipynb).
- [29] Peter Reimer et al. *Clinical MR imaging*. Springer, 2010.
- [30] DR Sarvamangala a Raghavendra V Kulkarni. “Convolutional neural networks in medical image understanding: a survey”. In: *Evolutionary intelligence* 15.1 (2022), s. 1–22.
- [31] Peter Savadjiev et al. “Demystification of AI-driven medical image interpretation: past, present and future”. In: *European radiology* 29 (2019), s. 1616–1624.
- [32] *SciPy Documentation*. SciPy Manual. 2008–2024. URL: <https://docs.scipy.org/doc/scipy/>.
- [33] Joseph A Shiraef. “An exploratory study of high performance graphics application programming interfaces”. In: (2016).
- [34] K Kirk Shung, Michael Smith a Benjamin MW Tsui. *Principles of medical imaging*. Academic Press, 2012.
- [35] K. Subburaj, B. Ravi a Manish Agarwal. “Automated identification of anatomical landmarks on 3D bone models reconstructed from CT scan images”.

- In: *Computerized Medical Imaging and Graphics* 33.5 (2009), s. 359–368.  
ISSN: 0895-6111. DOI: <https://doi.org/10.1016/j.compmedimag.2009.03.001>. URL: <https://www.sciencedirect.com/science/article/pii/S089561110900024X>.
- [36] Paul Suetens. *Fundamentals of medical imaging*. Cambridge university press, 2017.
- [37] P Vasuki, J Kanimozhi a M Balkis Devi. “A survey on image preprocessing techniques for diverse fields of medical imagery”. In: *2017 IEEE International Conference on Electrical, Instrumentation and Communication Engineering (ICEICE)*. IEEE. 2017, s. 1–6.
- [38] Jakob Wasserthal. *Dataset with segmentations of 117 important anatomical structures in 1228 CT images*. Ver. 2.0.1. Okt. 2023. DOI: 10.5281/zenodo.10047292. URL: <https://doi.org/10.5281/zenodo.10047292>.
- [39] Jakob Wasserthal et al. *Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images*. GitHub repository. 2023. URL: <https://www.github.com/wasserth/TotalSegmentator>.
- [40] Jakob Wasserthal et al. “Totalsegmentator: Robust segmentation of 104 anatomic structures in ct images”. In: *Radiology: Artificial Intelligence* 5.5 (2023).
- [41] Jun Xu et al. “A deep convolutional neural network for segmenting and classifying epithelial and stromal regions in histopathological images”. In: *Neurocomputing* 191 (2016), s. 214–223.
- [42] Hye Sun Yun et al. “Learning-based local-to-global landmark annotation for automatic 3D cephalometry”. In: *Physics in Medicine & Biology* 65.8 (2020), s. 085018.

## Literatúra

---

- [43] Liya Zhao, Kebin Jia et al. “Multiscale CNNs for brain tumor segmentation and diagnosis”. In: *Computational and mathematical methods in medicine* 2016 (2016).