

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-16768-116143

Peter Bartoš

Aplikácia vizuálnych dotazov v doméne spracovania medicínskych obrazov

Priebežná správa o riešení projektu

Vedúci práce: Ing. Igor Jánoš, PhD.

Január 2026

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-16768-116143

Peter Bartoš

Aplikácia vizuálnych dotazov v doméne spracovania medicínskych obrazov

Priebežná správa o riešení projektu

Študijný program: Inteligentné softvérové systémy

Študijný odbor: Informatika

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky,
FIIT STU, Bratislava

Vedúci práce: Ing. Igor Jánoš, PhD.

Január 2026

Tu bude vložené zadanie

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Modrom Kameni, Január 2026

Peter Bartoš

Annotation

Slovak University of Technology Bratislava

Faculty of Informatics and Information Technologies

Degree Course: Inteligentné softvérové systémy

Author: Peter Bartoš

Diploma Thesis: Application of visual prompts in the domain of medical image processing

Supervisor: Ing. Igor Jánoš, PhD.

Január 2026

This thesis focuses on the application of Vision Transformer (ViT) architectures in the domain of medical image processing, specifically for brain tumor segmentation using the BraTS dataset. While convolutional neural networks (CNNs) have dominated the field of computer vision over the past decade, transformers—originally designed for natural language processing—have demonstrated great potential in image analysis tasks as well. The work addresses the challenge of limited training data, which is a common issue in medical applications, and investigates methods that enable efficient finetuning of pre-trained large transformer-based models with a small number of samples. An essential part of the thesis is the integration of the concept of visual prompting, which allows interactive guidance of the model through visual inputs, such as user-annotated regions of interest. The proposed solutions implemented in PyTorch framework are experimentally evaluated on the publicly available BraTS dataset, and their performance is compared with state of the art methods. The results highlight the benefits of combining transformers with visual prompting for medical image segmentation tasks, especially in scenarios with limited annotated data.

Anotácia

Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Študijný program: Inteligentné softvérové systémy

Autor: Peter Bartoš

Diplomová práca: Aplikácia vizuálnych dotazov v doméne spracovania medicínskych obrazov

Vedúci projektu: Ing. Igor Jánoš, PhD.

Január 2026

Táto diplomová práca sa zameriava na aplikáciu architektúr vision transformero-
rov (ViT) v oblasti spracovania medicínskych obrazov, konkrétne na segmentáciu
nádorov mozgu s využitím dátovej množiny BraTS. Kým konvolučné neurónové
siete (CNN) dominovali oblasti počítačového videnia počas posledného desaťročia,
transformery - pôvodne navrhnuté pre spracovanie prirodzeného jazyka - preukázali
veľký potenciál aj pri úlohách obrazovej analýzy. Práca sa zameriava na problema-
tiku obmedzenej dostupnosti tréningových dát v medicíne a skúma metódy umož-
ňujúce efektívne dotréningovanie veľkých, predtrénovaných transformer modelov na
malom množstve dát. Kľúčovou súčasťou práce je integrácia konceptu vizuálnych
dotazov, ktorý umožňuje interaktívne usmerňovanie modelu pomocou vizuálnych
vstupov, ako sú napríklad používateľom označené oblasti záujmu. Navrhnuté rieše-
nia implementované knižnicou PyTorch sú experimentálne vyhodnotené na verejne
dostupnom datasete BraTS a ich výkonnosť je porovnaná s najmodernejšími me-
tódami. Výsledky poukazujú na výhody kombinácie ViT modelov a vizuálnych
dotazov pri úlohách segmentácie medicínskych obrazov, najmä v situáciách s ob-
medzeným množstvom anotovaných dát.

Pod'akovanie

Moje pod'akovanie patrí vedúcemu mojej práce Ing. Igorovi Jánošovi, PhD. za jeho ochotu a užitočné rady, ktoré mi poskytol pri písaní diplomovej práce.

Obsah

1	Úvod	1
1.1	Úvod do problémovej oblasti	1
1.2	Zámer projektu	3
2	Analýza problému	5
2.1	Medicínske zobrazenia	5
2.1.1	Magnetická rezonancia	6
2.2	Umelá inteligencia	7
2.2.1	Zaužívané architektúry segmentačných modelov	8
2.2.2	Konvolučná neurónová sieť	9
2.2.3	Vizuálny transformer	12
2.2.4	Vizuálne dotazy	15
2.3	Existujúce riešenia	17
2.3.1	SAM-Med2D	17
2.3.1.1	Architektúra siete a tréning	17
2.3.1.2	Vyhodnotenie	19
2.3.2	SAM-BraTS	20
2.3.2.1	Architektúra siete a tréning	21
2.3.2.2	Vyhodnotenie	22

2.3.3	PRISM	24
2.3.3.1	Architektúra siete a tréning	24
2.3.3.2	Vyhodnotenie	27
3	Návrh vlastného riešenia	29
3.1	Prístup k problému	30
3.2	Dátová množina	32
3.2.1	Štruktúra dát	32
3.2.2	Predspracovanie dát	33
3.3	Metriky	33
3.4	Kritériá segmentačného modelu	34
3.5	Požiadavky na vizuálny dotaz	35
3.6	Kritériá finálnej segmentácie	36
3.7	Riziká a výzvy	36
4	Implementácia	37
4.1	Použité rámce	37
4.2	Architektúra segmentačných modelov	40
4.2.1	SAM model	40
4.2.1.1	Obrazový enkóder	42
4.2.1.2	Dotazový enkóder	42
4.2.1.3	Maskový dekóder	43
4.2.2	MiT model	43
4.2.2.1	Hierarchický enkóder	44
4.2.2.2	All-MLP dekóder	45
4.2.3	Generovanie vizuálneho dotazu	46
4.2.3.1	Detekcia regiónov tumoru	46
4.2.3.2	Výpočet bodového dotazu	47

4.3	Tréning	47
4.3.1	Stratová funkcia	48
4.3.2	Tréning SAM modelu	50
4.3.3	Tréning MiT modelu	51
	Literatúra	51

Kapitola 1

Úvod

1.1 Úvod do problémovej oblasti

Gliómy patria medzi najagresívnejšie a život ohrozujúce formy rakoviny a predstavujú významnú časť primárnych nádorov mozgu u dospelých. Podľa Centrálneho registra mozgových nádorov v Spojených štátoch tvoria gliómy približne 25% všetkých primárnych nádorov mozgu a 80% zhubných primárnych nádorov mozgu a centrálneho nervového systému. Difúzne gliómy, ktoré zahŕňajú podtypy ako astrocytóm, oligodendroglióm a glioblastóm, sú obzvlášť náročné pre ich infiltratívny charakter a genetickú rozmanitosť. [30, 47] Tieto nádory, ktoré Svetová zdravotnícka organizácia (WHO) zaraďuje do stupňov 2 až 4, vykazujú značnú variabilitu v biologickom správaní, prognóze a odpovedi na liečbu. Glioblastóm, zaradený do 4. stupňa WHO, je obzvlášť agresívny, s mediánom prežitia len 8 až 14 mesiacov napriek štandardnej liečbe, zatiaľ čo oligodendrogliómy majú podstatne dlhší medián prežitia, až 17 rokov. [23, 47]

Zobrazovanie magnetickou rezonanciou (MRI) zohráva kľúčovú úlohu pri diagnostike, plánovaní liečby a sledovaní gliómov. MRI poskytuje dôležité informácie o

veľkosti, lokalizácii a morfológických zmenách nádoru, vďaka čomu je zlatým štandardom na monitorovanie progresie difúzných gliómov. Manažment gliómov však zostáva zložitý vzhľadom na ich heterogénnu povahu, ktorá predstavuje značné výzvy pri presnom vymedzení hraníc nádoru, najmä po liečbe. Hoci sa v oblasti predoperačnej segmentácie gliómov dosiahol významný pokrok, pričom väčšina výskumov využíva údaje z iniciatív, ako sú Archív onkologických snímok (The Cancer Imaging Archive - TCIA) a výzvy v oblasti segmentácie mozgových nádorov (Brain Tumor Segmentation Challenge - BraTS), existuje stále priestor na ďalšie skúmanie a využitie nových technológií na zlepšovanie už zaužívaných metód. [47, 33]

V posledných rokoch techniky hlbokého učenia, najmä konvolučné neurónové siete (ďalej ako CNN), spôsobili revolúciu v oblasti analýzy medicínskych obrazov a preukázali pozoruhodné schopnosti pri detekcii a klasifikácii vzorov v medicíne. Ako výkonná alternatíva sa však objavila novšia architektúra s názvom vizuálne transformery (angl. vision transformer, ďalej ako ViT), ktorá dosahuje špičkové výsledky vo viacerých úlohách počítačového videnia, v ktorých tradične dominujú CNN. Transformery, ktoré boli pôvodne navrhnuté na spracovanie prirodzeného jazyka, sa ukázali ako veľmi sľubné vo vizuálnych doménach tým, že využívajú mechanizmy vlastnej pozornosti (angl. self-attention) na zachytenie závislostí na dlhé vzdialenosti a priestorových hierarchií v obrazoch. To vyvolalo záujem o ich použitie v lekárskom zobrazovaní, kde je potreba presnej a efektívnej analýzy prvoradá. [47, 33]

Napriek ich potenciálu zostáva využitie ViT v lekárskom zobrazovaní, najmä pri segmentácii gliómov, aktívnou oblasťou výskumu. Jednou z kritických výziev pri aplikácii modelov hlbokého učenia na súbory lekárskeho údajov je obmedzená dostupnosť anotovaných tréningových údajov. Tento problém je obzvlášť výrazný v

oblasti lekárskeho zobrazovania, kde je získavanie anotovaných súborov údajov časovo aj zdrojovo náročné. Preto je skúmanie techník, ktoré dokážu maximalizovať výkon na malých súboroch údajov, nevyhnutné pre pokrok v aplikáciách lekárskeho zobrazovania. [47, 33]

Okrem architektúr ako CNN a ViT sa v poslednom období začína v oblasti segmentácie obrazov presadzovať aj prístup známy ako vizuálne dotazy (angl. visual prompting). Tento prístup umožňuje interaktívne usmerňovanie modelu pomocou vizuálnych vstupov od používateľa, ako sú napríklad označenia oblastí záujmu pomocou bodov, kriviek alebo masiek. Princíp vizuálnych dotazov sa ukázal ako veľmi sľubný najmä v prípadoch, kde sú k dispozícii len obmedzené množstvá anotovaných dát alebo keď je potrebné prispôbiť výstup modelu konkrétnemu prípadu na základe spätnej väzby používateľa. [49]

V doméne medicínskeho zobrazovania, konkrétne pri segmentácii gliómov na dátovej množine BraTS, môžu vizuálne dopyty výrazne zlepšiť presnosť a použiteľnosť segmentačných nástrojov v klinickej praxi. Umožňuje špecialistom interaktívne korigovať alebo upresňovať predikcie modelu, čím sa znižuje riziko nesprávneho určenia hraníc nádoru. Navyše, kombináciou veľkých predtrénovaných ViT modelov s mechanizmami vizuálnych dotazov možno dosiahnuť vyššiu generalizáciu aj pri menšom počte trénovacích príkladov. [49, 48]

1.2 Zámer projektu

Cieľom tejto práce je navrhnúť, implementovať a experimentálne overiť prístup k segmentácii mozgových nádorov, ktorý kombinuje pokročilé architektúry ViT modelov s technikami vizuálneho dotazovania na 2D MRI snímkach. Hlavný dôraz je kladený na využitie týchto technológií v kontexte obmedzeného množstva anotovaných trénovacích dát, čo je bežná výzva v oblasti medicínskeho zobrazovania.

V rámci práce sa budú analyzovať súčasné metódy segmentácie nádorov, s osobitným zameraním na transformery, ktoré sa v posledných rokoch ukazujú ako sľubná alternatíva ku klasickým konvolučným neurónovým sieťam. Následne sa navrhne prístup využívajúci veľký predtrénovaný model ViT architektúry, ktorý bude adaptovaný na segmentačnú úlohu pomocou techniky vizuálnych dotazov - konkrétne formou označenia oblastí záujmu používateľom.

Cieľom je overiť, do akej miery môže takýto prístup zvýšiť presnosť a flexibilitu segmentácie v porovnaní s tradičnými metódami, najmä v prípadoch, keď nie je k dispozícii veľký objem anotovaných dát. Experimenty budú realizované na referenčnom datasete BraTS, pričom sa vyhodnotí vplyv vizuálneho dotazovania na kvalitu segmentácie a použiteľnosť systému v klinickej praxi.

Výsledkom projektu by mala byť demonštrácia toho, že kombinácia vizuálnych transformerov a interaktívneho vizuálneho dotazovania predstavuje efektívny a prakticky využiteľný prístup k segmentácii mozgových nádorov.

Kapitola 2

Analýza problému

2.1 Medicínske zobrazenia


Lekárske zobrazovanie predstavuje zásadnú súčasť modernej zdravotnej starostlivosti, keďže využíva rôzne technológie na vytváranie obrazov vnútorných štruktúr ľudského tela. Tieto vizualizácie pomáhajú lekárom pri stanovovaní diagnóz, plánovaní a sledovaní priebehu liečby. Zohrávajú významnú úlohu aj pri včasnom odhalení ochorení, tvorbe individuálnych liečebných plánov, populačných skrínin-
goch, ako aj pri hodnotení efektivity liečby a predikcii jej výsledkov. Uplatňujú sa tiež v medicíne založenej na dôkazoch a vo výskume - predklinickom aj klinickom. Vďaka schopnosti poskytovať detailné a neinvazívne pohľady na anatomické a fyziologické procesy má lekárske zobrazovanie neodmysliteľné miesto v súčasnej medicíne. [34, 38]

V oblasti medicínskeho zobrazovania existuje viacero metód, pričom každá z nich má svoje špecifické výhody a je vhodná pre určité diagnostické účely. Medzi najbežnejšie techniky patria röntgenové snímkovanie (X-ray), počítačová tomografia (CT), magnetická rezonancia (MRI) a ultrazvuk. Táto práca sa bude venovať vý-

hradne magnetickej rezonancii a jej využitiu v zdravotníctve. [17, 38]

2.1.1 Magnetická rezonancia

Magnetická rezonancia (ďalej ako MRI) predstavuje neinvazívnu zobrazovaciu metódu, ktorá využíva silné magnetické pole a rádiové frekvencie vlny na vytváranie vysoko detailných obrazov vnútorných orgánov a tkanív. Na rozdiel od röntgenového snímokovania či počítačovej tomografie, MRI nepracuje s ionizujúcim žiarením, vďaka čomu je považovaná za bezpečnejšiu a flexibilnejšiu možnosť zobrazovania v medicíne. [16]



Obr. 2.1: Príklad MRI skenu prierezu mozgu. [16]


MRI si získala pevné miesto v diagnostike aj výskume vďaka svojej schopnosti precízne zobrazovať mäkké tkanivá v rôznych častiach tela. Okrem bežne používaných T1- a T2-vážených snímok vzniklo množstvo pokročilých MRI techník, ktoré umožňujú získať aj metabolické a biofyzikálne informácie o skúmaných oblastiach. Napríklad difúzne vážené zobrazovanie umožňuje sledovať pohyb molekúl vody v tkanivách, pričom difúzny tenzor dokáže zobrazovať orientáciu nervových vlákien v bielej hmote mozgu. Metabolické údaje možno získať aj pomocou protónovej spektroskopie alebo zobrazovaním jadier ako je sodík. V oblasti onkológie sa čoraz častejšie využíva dynamické zobrazovanie s kontrastnými látkami a pokročilé formy

spektroskopie. Kombináciou týchto metód môžu lekári presnejšie určiť diagnózu alebo sledovať účinnosť liečby. Veľkou výhodou MRI je možnosť prispôbiť kontrast obrazu pomocou rôznych parametrov, čo umožňuje optimalizovať výsledky podľa konkrétneho diagnostického cieľa. Na tvorbu MRI snímok vplýva viacero technických aspektov, ako je hardvér zariadenia, lokalizácia signálu, gradienty, usporiadanie k-priestoru a pulzné sekvencie. [16, 32]

2.2 Umelá inteligencia

Umelá inteligencia (angl. Artificial Intelligence, ďalej ako AI) predstavuje súbor algoritmických metód a techník, ktoré umožňujú strojom simulovať niektoré aspekty ľudskej inteligencie, ako je učenie, rozhodovanie, rozpoznávanie obrazcov alebo porozumenie jazyku. V posledných rokoch zaznamenalo AI významný pokrok predovšetkým vďaka hlbokému učeniu (angl. deep learning), ktoré umožňuje trénovať komplexné modely na veľkých dátových množinách pomocou umelých neurónových sietí a to najmä v oblastiach ako je spracovanie prirodzeného jazyka, počítačové videnie a medicínska diagnostika. [22, 11]

V medicíne nachádza AI čoraz širšie uplatnenie, najmä pri automatizácii úloh, ktoré sú inak časovo náročné alebo podliehajú subjektívnemu hodnoteniu odborníkov. Typickým príkladom je segmentácia medicínskych obrazových dát, kde AI umožňuje presnejšie a rýchlejšie identifikovať anatomické štruktúry či patologické oblasti, napríklad nádory mozgu alebo iné abnormality. Vzhľadom na vysokú variabilitu pacientov, zobrazovacích metód, anatomických rozdielov a typov patológií je robustnosť a generalizovateľnosť modelov AI v tejto oblasti mimoriadne dôležitá pre klinickú prax aj výskumné využitie. Dobre vytrénované modely môžu pomôcť znížiť chybovosť, potenciálne urýchliť diagnostiku a zlepšiť výsledky liečby pacientov. [40, 11]



Obr. 2.2: Zobrazenie príkladov, že hlboké učenie sa môže vyznačovať široko rôznymi typmi údajov a učiť sa z nich. [11]

2.2.1 Zaužívané architektúry segmentačných modelov

Segmentácia obrazu patrí medzi kľúčové úlohy počítačového videnia v medicíne, kde zohráva zásadnú rolu pri diagnostike a plánovaní liečby. Úlohou segmentačného modelu je priradiť každej obrazovej jednotke (pixelu alebo voxelu) triedu, ktorá reprezentuje určitú štruktúru, ako napríklad nádor, zdravé tkanivo, cievy, orgány alebo iné anatomicke oblasti. Modely pre segmentáciu musia byť schopné zachytiť detailné lokálne informácie, ako aj globálny kontext celého obrazu, čo si vyžaduje mimoriadne sofistikovanú a starostlivo navrhnutú architektúru schopnú generalizovať na rôzne typy medicínskych dát. [6]

Z hľadiska architektúr sa modely segmentácie v súčasnosti zvyčajne delia do dvoch hlavných skupín:

- **Konvolučné neurónové siete** (angl. Convolutional neural networks, ďalej ako CNN) sú dlhodobu dominantné pri spracovaní obrazových dát. Využívajú konvolučné filtre, ktoré umožňujú efektívne extrahovať lokálne rysy. Typicky používané architektúry sú napríklad UNet[15] a Resnet[39]. CNN modely sa osvedčili aj pri trojrozmerných dátach, ako sú MRI skeny, kde sa často používajú 3D konvolúcie. [29]
- **Vizuálne transformery** (angl. Visual transformers, ďalej ako ViT) predstavujú novší prístup, ktorý využíva mechanizmus sebaopozornosti (angl. self-attention) na modelovanie globálnych závislostí v obraze. Namiesto konvulučných operácií pracujú s vektorovými reprezentáciami rozdelených obrazových oblastí/výrezov (angl. patch). Hoci boli pôvodne navrhnuté pre klasifikáciu, dnes sa ViT architektúry úspešne aplikujú aj v oblasti segmentácie ako napríklad UNETR[13], TransUNet[4] a SAM[5] modely. [9]

CNN sú stále populárne pri spracovaní lokalizovaných detailov, zatiaľ čo ViT sa čoraz viac uplatňujú pri spracovaní globálnych závislostí v obraze. Ďalšie podrobnosti o týchto modeloch budú rozobrané v nasledujúcich sekciách. [29, 9]

2.2.2 Konvulučná neurónová sieť

CNN modely sú jednou z najúspešnejších architektúr používaných v oblasti počítačového videnia, najmä pri úlohách, ako je segmentácia obrazu, klasifikácia a detekcia objektov. CNN modely sa od tradičných plne prepojených neurónových sietí líšia tým, že využívajú konvulčné operácie, ktoré umožňujú extrakciu lokálnych vzorov a črt z obrazových dát. [29, 3]

Základnou zložkou CNN je konvolučná vrstva, ktorá aplikuje konvolúciu na vstupný obraz alebo predchádzajúci výstup. Konvolúcia je matematická operácia, pri ktorej sa malý filter pohybuje po obrázku a na každý jeho bod aplikuje skalárny súčin s príslušnou časťou vstupného obrazu. Na základe tréningu sa sieť naučí rozpoznávať, ktoré jadrá sa aktivujú, keď zaznamenajú špecifický prvok na určitej priestorovej pozícii vstupného obrazu. Konvolučné vrstvy zároveň umožňujú výrazne znížiť zložitosť modelu tým, že efektívne spracúvajú a optimalizujú svoj výstup. Na reguláciu veľkosti výsledného výstupu sa využívajú hyperparametre ako hĺbka (angl. depth), krok (angl. stride) a nulové doplnenie (angl. zero-padding). Hĺbka určuje počet filtrov použitých v danej vrstve, čím sa zvyšuje schopnosť modelu zachytávať rôznorodé črty. Krok definuje, že o koľko pixelov sa filter posúva pri aplikácii na obraz - väčší krok vedie k zmenšeniu výstupného rozmeru. Nakoniec, nulová výplň slúži na pridanie nulových hodnôt okolo okrajov vstupného obrazu, čo umožňuje zachovať jeho pôvodné rozmery aj po aplikácii konvolučnej operácie a zároveň zlepšuje spracovanie okrajových oblastí. [29, 10]

Tento proces možno vyjadriť nasledovným vzorcom:


$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) \cdot K(i - m, j - n) \quad (2.1)$$

kde:

- I je vstupný obraz (input),
- K je konvolučné jadro (filter/kernel),
- $S(i, j)$ je výstupná hodnota po konvolúcii na pozícii (i, j) ,
- m, n sú indexy prechádzajúce cez rozmery jadra.

Výsledok $S(i, j)$ je teda súčet súčinov medzi hodnotami z výrezu obrazu a jadrom

filtra, ktorý sa posúva po celej obrazovej ploche. Tento proces umožňuje zachytiť rôzne obrazové vzory, ako sú okraje, textúry a tvary. Filter sa následne upravuje počas tréningu siete, aby sa optimalizoval na extrakciu relevantných črt z obrazov. [29, 10]



Obr. 2.3: Bežne zaužívaný typ architektúry CNN, v ktorej sú konvolučné vrstvy kontinuálne naskladané medzi aktivačnými vrstvami predtým, ako prejdú cez združovaciu vrstvu, pred prechodom medzi jednou alebo viacerou plne pripojených vrstiev s aktivačnou funkciou. [29]

Konvolučné siete majú niekoľko dôležitých vlastností:

- **Efektivita extrakcie vzorov:** konvolučné operácie sú veľmi efektívne pri extrakcii lokálnych rysov z obrazov, ako sú hrany alebo textúry, bez potreby spracovávaní celého obrazu naraz. Tento prístup významne znižuje počet parametrov v sieti, čím sa znižuje jej výpočtová náročnosť. [19]
- **Hierarchia vzorov:** CNN umožňuje hierarchické učenie vzorov, kde nižšie vrstvy extrahujú jednoduché vzory (ako okraje), zatiaľ čo vyššie vrstvy kombinujú tieto vzory do komplexnejších reprezentácií, ako sú objekty alebo tvary. [19]
- **Zdieľanie parametrov:** parametre (váhy) konvolučného filtra sú zdieľané vo všetkých miestach obrazu, čo znamená, že model sa môže naučiť rovnaké vzory na rôznych častiach obrazu. Tento prístup zvyšuje efektivitu učenia a znižuje počet potrebných parametrov. [12]

- **Združovanie:** po každej konvolučnej vrstve sa zvyčajne aplikuje združovacia (angl. pooling) vrstva, ktorá znižuje rozlíšenie obrazu a zachováva iba najdôležitejšie informácie. Združovanie znižuje počet parametrov a zabraňuje pretrénovaniu, pričom zvyšuje robustnosť modelu voči variáciám v obraze. [3]

Jedným z najznámejších a najúčinnějších modelov založených na konvolučných neurónových sieťach je architektúra UNet[15], ktorá bola navrhnutá špeciálne pre úlohy segmentácie medicínskych obrazov. UNet sa skladá z dvoch hlavných častí: klesajúca časť, ktorá extrahuje vzory z obrazu pomocou konvolučných a združovacích vrstiev, a rastúca časť, ktorá rekonštruje segmentovaný obraz pomocou transponovaných konvolúcií. Tento prístup umožňuje modelu uchovávať dostatok detailov a zároveň získať globálne kontextové informácie. [6, 15]

V oblasti segmentácie trojrozmerných obrazov, ako sú MRI skeny mozgu, sa často používajú 3D konvolučné siete, ktoré aplikujú konvolúciu na trojrozmerné dáta. Tieto modely sa ukázali ako veľmi účinné pri zachytávaní štruktúr v trojdimenziónoch obrazových dátach, kde je potrebné zachytiť vzory nielen v jednotlivých 2D rovinách, ale aj v treťom rozmere. [6]

CNN sú teda kľúčovým nástrojom v mnohých oblastiach medicíny, kde umožňujú presnú a rýchlu analýzu obrazových dát, ako je napríklad segmentácia nádorov v MRI snímkach. [6]

2.2.3 Vizuálny transformer

ViT modely predstavujú novší prístup k spracovaniu obrazových dát, ktorý čerpá inšpiráciu z úspechu transformerových architektúr v oblasti spracovania prírodného jazyka (angl. natural language processing). Na rozdiel od tradičných konvolučných sietí, ktoré využívajú lokálne konvolúcie, ViT modely aplikujú mechanizmus sebaopozornosti (angl. self-attention) na reprezentácie obrazu, čím umožňujú

modelovať globálne závislosti medzi jednotlivými časťami obrazu. [9]

Mechanizmus sebaopozornosti je možné vyjadriť nasledovne:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V, \quad (2.2)$$


kde:

- Q sú dotazy (angl. queries), ktoré reprezentujú požiadavky na získanie informácie,
- K sú kľúče (angl. keys), ktoré popisujú vlastnosti uložených vstupov,
- V sú hodnoty (angl. values), ktoré predstavujú samotné informácie alebo reprezentácie uložené v pamäti,
- d_k je rozmer priestoru kľúčov (angl. dimension of key vectors), ktorý sa používa na škálovanie skalárnej hodnoty v skalárnom súčine.

V tomto procese sa najprv vypočíta skalárny súčin medzi dotazom (Q) a kľúčmi (K), ktorý vyjadruje mieru podobnosti. Výsledok sa následne škáluje delením druhou odmocninou z rozmeru priestoru kľúčov (d_k), čo pomáha stabilizovať gradienty počas tréningu. Na tieto hodnoty sa potom aplikuje softmax funkcia, aby sa vytvorila distribúcia pravdepodobností, ktorá určuje váhy jednotlivých hodnôt (V). Nakoniec sa tieto váhy použijú na váženú kombináciu hodnôt, čím sa získa výstup mechanizmu pozornosti. Tento prístup umožňuje modelu dynamicky sa sústrediť na relevantné časti vstupu. [46]

Ďalší základný princíp fungovania ViT spočíva v rozdelení vstupného obrazu na malé výrezy alebo oblasti (angl. patches), ktoré sú následne linearizované a prevedené na vektorové reprezentácie. Každý výrez je doplnený o pozičné informácie (angl. positional encoding), ktoré zabezpečujú, že model má informáciu o priesto-

rovom usporiadaní daných oblastí a vie ich správne interpretovať vzhľadom na ich polohu. Tieto vektory sú následne spracované transformerovými vrstvami, ktoré pozostávajú z mechanizmov sebaopozornosti a plne prepojených vrstiev, čo umožňuje modelu zachytiť komplexné vzťahy medzi jednotlivými časťami obrazu. [46]



Obr. 2.4: Všeobecné zobrazenie architektúry ViT pozostávajúcej z transformer enkóderu, ktorý priamo využíva výrezy medicínskeho zobrazenia a je pripojený ku dekóderu, ktorý častokrát predstavuje enkóder založený na CNN architektúre. [13]

Jednou z výhod ViT modelov je schopnosť zachytiť ďaleké závislosti v obraze bez potreby hierarchického zhlukovania črt, ako je to v prípade CNN. Hoci ViT modely počas tréningu spravidla vyžadujú veľké množstvo dát a výpočtových zdrojov, ale po dôkladnom natrénovaní na rozsiahlych datasetoch dokážu efektívne generalizovať aj pri menších množstvách nových dát, čím môžu prekonávať tradičné

CNN architektúry z hľadiska efektivity tréovania. [9]


V oblasti segmentácie medicínskych obrazov sa ViT architektúry adaptovali napríklad vo forme modelov ako UNETR[13] alebo TransUNet[4], ktoré kombinujú výhody ViT v modelovaní globálnych vzťahov s dekodovacími architektúrami podobajúcimi sa UNet[15] architektúre. Okrem toho bol v roku 2023 predstavený model SAM[5] (Segment Anything Model), ktorý je navrhnutý ako univerzálny model segmentácie založený na transformer architektúre a je schopný generalizovať naprieč rôznymi typmi obrazových úloh bez potreby špecifického doladenia pre konkrétnu úlohu. Tento prístup otvára nové možnosti v oblasti automatizovanej medicínskej analýzy. [18]

2.2.4 Vizuálne dotazy

Vizuálne dotazy (angl. visual prompts) predstavujú moderný spôsob interakcie s modelmi počítačového videnia, pri ktorom používateľ poskytuje vstup vo forme vizuálnej nápovedy, ako je bod, krivka alebo maska, a model na základe tohto vstupu predikuje výstup, typicky v podobe segmentácie. Tento prístup umožňuje flexibilnú, intuitívnu a často aj vysoko presnú manipuláciu s modelom bez potreby klasického tréovania na konkrétne úlohy. [2, 20]

Jeden z najznámejších modelov využívajúcich vizuálne dotazy je SAM[5], ktorý bol navrhnutý s cieľom fungovať ako univerzálny segmentačný nástroj. SAM je schopný na základe jednoduchého vstupu - napríklad kliknutia na objekt alebo výberu oblasti - vytvoriť kvalitnú segmentačnú masku. Na rozdiel od tradičných segmentačných modelov, ktoré sú tréované na konkrétnu triedu objektov, SAM generalizuje na nové objekty bez potreby ďalšieho doladenia (angl. fine-tuning), čím demonštruje silu a flexibilitu prístupu vizuálnych dotazov. [5, 20]

Vizuálne dotazy fungujú tak, že vizuálny dotaz je prevedený na vektorovú repre-



Obr. 2.5: Všeobecné zobrazenie architektúry ViT modelu prispôbeného na vizuálne dotazy pozostávajúci z obrazového enkóderu, inštrukčného enkóderu a maskového dekóderu. [18]

zentáciu (angl. embedding), ktorý sa následne spojí s obrazovými výrezami snímky vo forme vektorových reprezentácií. Tento kombinovaný vstup sa spracováva transformer architektúrou, ktorá generuje odpoveď v podobe segmentačnej masky. Architektúra je častokrát rozdelená na tri hlavné časti: enkóder obrazu (spracuje celý obraz), enkóder inštrukcie (ktorý zakóduje vizuálny dotaz) a dekóder masky (kombinuje tieto informácie a vygeneruje výstup). [18]

Tento prístup si získava čoraz väčšiu popularitu aj v oblasti medicíny, kde umožňuje interaktívnu segmentáciu na základe označenia určitej oblasti odborníkom, pričom model dokáže zvyšok segmentovať automaticky. Takýto systém môže slúžiť ako asistent odborníka, ktorý potenciálne môže zrýchliť diagnostický proces a znížiť mieru chýb. [2, 18, 20]

2.3 Existujúce riešenia

2.3.1 SAM-Med2D

Autori článku [5] predstavujú komplexné riešenie na prispôsobenie modelu SAM (Segment Anything Model) pre segmentáciu 2D medicínskych obrazov. Pôvodný SAM, vyvinutý spoločnosťou Meta AI, dosahuje vynikajúce výsledky pri segmentácii prirodzených obrazov, avšak jeho aplikácia na medicínske snímky je obmedzená kvôli výraznému rozdielu medzi doménami prirodzených a medicínskych obrazov. Na prekonanie tohto rozdielu autori zhromaždili a spracovali rozsiahly súbor dát, nazvaný SA-Med2D-20M, ktorý obsahuje približne 4,6 milióna 2D medicínskych snímok a 19,7 milióna zodpovedajúcich segmentačných masiek. Tieto dáta pokrývajú rôzne modalities, ako sú CT, MRI, ultrazvuk, röntgen, endoskopia a ďalšie, ktoré zahŕňajú viac ako 100 kategórií anatomických štruktúr a orgánov.

2.3.1.1 Architektúra siete a tréning

SAM-Med2D vychádza z pôvodného SAM modelu, ktorý kombinuje ViT ako enkóder obrazu a špeciálny enkóder na dotazy (angl. prompts) na spracovanie užívateľských vstupov (body, krivky, masky). Autori si uvedomili, že priamy prenos SAM modelu na medicínske zobrazenia má zhoršenú presnosť. Preto model viacej špecializovali tak, že použili ľahkú adaptáciu pôvodného ViT enkódera pomocou adaptačných vrstiev. Použili ich tak, že zamrazili parametre pôvodného enkódera a pridali adaptívne vrstvy na každý transformer blok. Adaptéry sa používajú na zníženie nákladov a umožňujú flexibilné prispôsobenie modelu. Autori použili GELU aktivačnú funkciu vnútri týchto blokov. GELU aktivačná funkcia v adaptéroch pomáha zachovať plynulé prechody a jemné nelineárnosti, ktoré sú dôležité pri

segmentácii komplexných štruktúr, ako sú napríklad nádory v mozgu. Tvar tejto aktivačnej funkcie vyzerá nasledovne:


$$\text{GELU}(x) \approx 0.5x \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right) \right), \quad (2.3)$$

kde x je vstupná hodnota do aktivačnej funkcie, $\tanh(\cdot)$ je hyperbolická tangens funkcia, ktorá transformuje hodnoty do intervalu $(-1, 1)$, $\sqrt{\frac{2}{\pi}}$ je normalizačný faktor vychádzajúci z aproximácie normálneho rozdelenia, 0.044715 je konštanta, ktorá zlepšuje presnosť aproximácie tým, že zohľadňuje vyšší stupeň polynomu (x^3) a x^3 zavádza jemnú nelinearitu, ktorá lepšie zachytáva nelineárne vlastnosti vstupného signálu pri extrémnych hodnotách. Pre kanálovú dimenziu sa komprimuje vstupný mapovaný obraz do menšieho rozmeru pomocou globálneho združovania (angl. global average pooling), následne sa použije lineárna vrstva na zníženie počtu kanálov a opäť sa tieto kanály obnovia na pôvodnú hodnotu. Tento proces pomáha modelu učiť sa dôležité rysy zo vstupu bez potreby pretrénovania celého enkódera. [5]

SAM-Med2D vylepšuje funkcionality dotazov oproti predchádzajúcim metódam SAM modelov, ktoré zvyčajne používali iba jeden typ dotazu. SAM-Med2D využíva kombináciu zriedkavé (angl. sparse) a husté (angl. dense) dotazy, aby zlepšil schopnosť modelu pracovať s rôznymi druhmi dát, najmä v medicínskych snímkach. V SAM-Med2D sa tiež zachováva maskový dekodér z pôvodného modelu, pričom sa jeho parametre aktualizujú počas tréningu. Aby sa zlepšila presnosť segmentácie, model predikuje viacero masiek súčasne (štandardne tri). Pri spätnom šírení chyby sa vyberie maska s najvyšším IoU (Intersection over Union) skóre v porovnaní so skutočnými maskami, aby sa spoľahlivo aktualizovali gradienty. [5]

V tréningu SAM-Med2D modelu používali optimalizátor Adam s počiatočnou rýchlosťou učenia $1e-4$ a zmiešanú fokálnu a Dice stratovú funkciu, pričom obrázky

boli zmenšené na veľkosť $256 * 256$ rozlíšenie. Tréning prebiehal pomocou simulovanej interaktívnej segmentácie, kde sa model trénuje v 10 iteráciách na každú dávku dát. V prvej iterácii sa náhodne vyberie buď bod, alebo ohraničujúci box ako dotaz. Pri ďalších iteráciách sa používajú rôzne množstvá bodov zo zóny chyby medzi predikovanými maskami a skutočnými hodnotami. Týmto spôsobom model dokáže dynamicky zlepšovať svoje predikcie a naučiť sa lepšie reagovať na vstupy. Tento prístup umožňuje, aby model flexibilne reagoval na interaktívne zmeny v dotazoch, čím sa zlepší presnosť segmentácie aj pri použití menej detailných údajov. Počas tréningu sa model opiera o kombinované použitie hustých a zriedkavých dotazov, čo umožňuje optimalizovať výkon modelu aj pri nižšej kvalite inicializačných údajov. [5]



Obr. 2.6: Reťazec procesov SAM-Med2D modelu, kde autori zmrazujú obrazový enkóder a do každého transformer bloku začleňujú učiace sa vrstvy adaptéra na získanie doménovo špecifických znalostí v oblasti medicíny. Dotazový enkóder doľadujú bodami a ohraničujúcimi boxami, pričom aktualizujú parametre dekodera masky prostredníctvom interaktívneho učenia [5]

2.3.1.2 Vyhodnotenie

SAM-Med2D dosiahol výrazné zlepšenie v Dice skóre v porovnaní s pôvodným SAM a FT-SAM (ktorý zahŕňal doladenie dekóderv na základe masiek). Model

dosiahol zvýšenie o 17,67% v režime ohraničujúcich boxov (79,30%) a konzistentné zlepšenia v režimoch bodových dotazov. SAM-Med2D prekonal základné modely vo všetkých anatomických oblastiach, pričom najväčšie zlepšenia boli pozorované v hrudníkových a panvových oblastiach. Avšak segmentácia oblastí hlavy a krku zostávala stále pre model náročná. Model tiež vykázal silnú generalizáciu naprieč rôznymi zobrazovacími modalitami, dosahujúc najvyššie Dice skóre pri CT a PET obrazoch. [5]

Datasets	Bbox prompt (%)			1 point prompt (%)		
	SAM [8]	SAM-Med2D	SAM-Med2D*	SAM [8]	SAM-Med2D	SAM-Med2D*
CrossMoDA23[33]	78.98	70.51	84.62	18.49	46.08	73.98
KiTS23 [34]	84.80	76.32	87.93	38.93	48.81	79.87
FLARE23 [35]	86.11	83.51	90.95	51.05	62.86	85.10
ATLAS2023 [36]	82.98	73.70	86.56	46.89	34.72	70.42
SEG [37]	75.98	68.02	84.31	11.75	48.05	69.85
LNQ2023 [38]	72.31	63.84	81.33	3.81	44.81	59.84
CAS2023 [39]	52.34	46.11	60.38	0.45	28.79	15.19
TDSC-ABUS2023 [40]	71.66	64.65	76.65	12.11	35.99	61.84
ToothFairy2023 [41]	65.86	57.45	75.29	1.01	32.12	47.32
Weighted average	85.35	81.93	90.12	48.08	60.31	83.41

Obr. 2.7: Zovšeobecnenie validácie na 9 dátových súboroch MICCAI2023, kde „*“ označuje SAM-Med2D model bez parametrov vrstvy adaptéra. Zobrazené hodnoty predstavujú Dice skóre. [5]

Tieto výsledky potvrdili, že doladenie SAM modelu na veľkých medicínskych datasetoch významne zlepšilo výkon segmentácie a prenosnosť domény, najmä v interaktívnych nastaveniach s bodovými vizuálnymi dotazmi. [5]

2.3.2 SAM-BraTS

Autori článku [51] predstavujú riešenie na prispôsobenie znova modelu SAM pre segmentáciu 2D medicínskych obrazov, keďže SAM patrí v tejto dobe medzi základové modely (angl. foundation model) pre segmentáciu. Na overenie schopností tohto modelu v medicínskom zobrazovaní autori použili dataset BraTS2019, ktorý

obsahuje 259 prípadov vysokostupňových gliómov (HGG) a 76 prípadov nízko-
stupňových gliómov (LGG). Každý sken obsahuje 4 modalities: T1 (anatomická
štruktúra), T1ce (T1 s kontrastnou látkou - zvýrazňuje aktívnu oblasť nádoru),
T2 (zvýrazňuje opuch), FLAIR (zvýrazňuje edém). Každý prípad obsahuje anotá-
cie od odborníkov, ktoré rozlišujú tri podregióny nádoru: zvýraznený nádor (angl.
enhancing tumor, ďalej ako ET), jadro nádoru (angl. tumor core, ďalej ako TC) a
celý nádor (angl. whole tumor, ďalej ako WT). Keďže verzia SAM modelu, ktorý
autori použili, akceptuje iba 2D obrázky, 3D MRI snímky autori rozrezali na 2D
rezy v axiálnej rovine a boli ponechané len tie rezy, ktoré obsahovali tumor. Tak-
tiež neposkytovali modelu všetky 4 modalities v 4 kanáloch, ale každú modalitu ako
iný obrázok.

2.3.2.1 Architektúra siete a tréning

Model SAM pozostáva z troch hlavných častí: obrazový enkóder, dotazový enkóder
a dekóder masky. Autori uvádzajú, že v najskorších experimentoch bol použitý
predtrénovaný SAM bez žiadneho dotrénovania. Model bol evaluovaný s rôznymi
typmi vizuálnych dotazov:

- bodové prompty (2, 10, 20 a 30 bodov - rovnomerne rozložené pozitívne a
negatívne body),
- jeden ohraničujúci box,
- kombinácia ohraničujúceho boxu a jedného pozitívneho bodu.

Výber dotazov bol odvodzovaný z polohy na základe masky s cieľom zabezpečiť
objektívnosť testovania. Následne bol model aj doladený, pričom boli zamrazené
parametre obrazového a dotazového enkódera a aktualizované boli len parametre
dekódera masky. Dolaďovanie prebiehalo, ako už bolo spomínané, na 2D dátach z
BraTS2019 datasetu rozdelených na tréningovú a testovaciu množinu. [51]

2.3.2.2 Vyhodnotenie

Segmentačná presnosť modelu hodnotili pomocou troch metrík: Dice koeficient, Hausdorffova vzdialenosť (angl. distance) a Priemerná symetrická povrchová vzdialenosť (angl. average symmetric surface distance). Dice koeficient je štandardne používaná metrika na meranie podobnosti medzi dvoma množinami. V prípade segmentácie vyjadruje mieru prekrytia medzi predikovanou maskou P a anotovanou maskou G . Je definovaný nasledovne:

$$\text{Dice}(P, G) = \frac{2|P \cap G|}{|P| + |G|}, \quad (2.4)$$

kde $|P|$ a $|G|$ sú veľkosti predikcie a anotovanej masky, a $|P \cap G|$ predstavuje počet spoločných pixelov. Hodnota tohto koeficientu sa pohybuje v intervale $[0; 1]$, pričom hodnota 1 značí dokonalé prekrytie. Hausdorffova vzdialenosť meria maximálnu vzdialenosť od bodu v jednej množine ku najbližšiemu bodu v druhej množine. V kontexte segmentácie hodnotí najhoršiu (najväčšiu) chybu v zarovnaní hraníc segmentácie. Formálne je definovaná ako:

$$\text{HD}(P, G) = \max \left\{ \sup_{p \in P} \inf_{g \in G} d(p, g), \sup_{g \in G} \inf_{p \in P} d(g, p) \right\}, \quad (2.5)$$

kde $d(p, g)$ označuje euklidovskú vzdialenosť medzi bodmi p a g . Nižšia hodnota vzdialenosti indikuje lepšiu zhodu medzi predikovanou a skutočnou hranicou. Priemerná symetrická povrchová vzdialenosť je metrika, ktorá meria priemernú vzdialenosť medzi hranicami predikcie a ground truth masky symetricky, teda v oboch smeroch. Výpočet metriky je daný:

$$\text{ASSD}(P, G) = \frac{1}{|P| + |G|} \left(\sum_{p \in P} \min_{g \in G} d(p, g) + \sum_{g \in G} \min_{p \in P} d(g, p) \right), \quad (2.6)$$

kde $d(p, g)$ je euklidovská vzdialenosť medzi bodmi. Metrika poskytuje robustnejšiu mieru celkovej chyby hraníc než Hausdorffova, keďže penalizuje priemerné odchýlky, nie len maximálne. [51]

Najlepšie výsledky riešenia autorov je možno vidieť na nasledujúcej tabuľke:

Region	Method	Prompts	T1			T1ce			T2			FLAIR		
			Dice $\uparrow$	HD $\downarrow$	ASSD $\downarrow$	Dice $\uparrow$	HD $\downarrow$	ASSD $\downarrow$	Dice $\uparrow$	HD $\downarrow$	ASSD $\downarrow$	Dice $\uparrow$	HD $\downarrow$	ASSD $\downarrow$
Whole Tumor	SAM	1 box	0.8005	17.9673	0.6028	0.7989	17.6185	0.6142	0.8240	17.4714	0.5129	0.7989	17.6185	0.6142
Tumor Core	SAM	1 box	0.8211	14.6222	0.4693	0.8442	14.1880	0.3853	0.8334	14.4117	0.4224	0.8442	14.1839	0.3840
Enhancing Tumor	SAM	1 box	0.6999	14.1850	0.7629	0.7625	12.3332	0.5768	0.7142	13.9397	0.7057	0.7625	12.3332	0.5768

Obr. 2.8: Výsledky SAM modelu po doladení, kde zobrazené metriky sú vyhodnotené iba pre vizuálne dotazy jedného ohraničujúceho boxu, keďže mali najlepšie výsledky. [51]

Hlavné výsledky štúdie poukázali na to, že ohraničujúce boxy mali najlepšie výsledky oproti ostatným vyskúšaným možnostiam. Zvyšovanie počtu bodových dotazov (z 1 na 10) výrazne zlepšilo segmentačný výkon. Naopak pri 20 a 30 bodoch však začal výkon klesať v dôsledku preplnenia a nárastu falošných pozitívnych oblastí. Výkon sa tiež líšil medzi rôznymi MRI modalitami: najlepšie výsledky boli na dátach T2 a FLAIR, pričom modalita T1 vykazovali horšiu presnosť kvôli rozmazaným hraniciam tumorov. Najpresnejšia bola segmentácia pre región jadra tumoru, nasledovaná segmentáciou regiónom celého tumoru, pričom segmentácia zvýrazneného tumoru bola najslabšia. Ďalej, zavedenie náhodného šumu do dotazov (napr. náhodný posun bodov alebo zmena veľkosti boxu) spôsobilo pokles výkonu, čo reflektuje reálnejšie interaktívne scenáre. Doladenie modelu SAM viedlo k výraznému zlepšeniu, kde Dice skóre pri segmentácii celého tumoru v T1 modalite stúplo z 0,6989 na 0,8005. Autori tiež diskutovali o perspektívach budúceho výskumu, najmä o rozšírení SAM pre prácu s 3D dátami a o možnostiach lepšieho využívania multimodálnych informácií z rôznych zobrazovacích modalít. [51]

2.3.3 PRISM

Autori článku [21] predstavujú model PRISM (Promptable and Robust Interactive Segmentation Model), ktorý je určený na presnú segmentáciu 3D medicínskych obrazov pomocou rôznych typov vizuálnych dotazov, ako sú body, boxy, čiary (angl. scribbles) a masky. Cieľom práce bolo dosiahnuť robustnú interaktívnu segmentáciu, pričom riešenie kladie dôraz na iteratívne učenie, korekcie na základe chýb v predchádzajúcich iteráciách a zohľadnenie dôveryhodnosti predikcií. Na vyhodnotenie modelu PRISM boli použité štyri verejné datasety pre segmentáciu tumorov, ktoré sa sústreďujú na tumory hrubého čreva, pankreasu, pečene a obličiek. Tieto dáta predstavujú výzvy v podobe anatomických variácií, rôznorodých tvarov tumorov a nejasných hraníc. Zo súborov dát sa zameriavali iba na podmnožiny nádorových másk, teda robili binárnu segmentáciu. Datasety si rozdelili na tréningové, validačné a testovacie rozdelené v tomto poradí v pomere 70, 10 a 20.

2.3.3.1 Architektúra siete a tréning

PRISM využíva všeobecnú enkóder-dekóder architektúru s hybridným enkóderom, ktorý kombinuje CNN a ViT architektúry, čím zachytáva lokálne aj globálne vlastnosti obrazu. [21]

Model PRISM využíva iteratívne učenie na postupné zlepšovanie segmentačných výsledkov. Po každej iterácii segmentácie používateľ poskytuje nové vizuálne dotazy založené na chybových oblastiach predchádzajúcej predikcie. Tento prístup umožňuje modelu reagovať na chyby a v ďalších iteráciách ich opravovať, čím sa segmentácia postupne približuje optimálnemu výsledku. Každá iterácia i generuje predikciu segmentácie y'_i a je asociovaná s vlastnou stratovou funkciou L_i . Celková tréningová stratová funkcia je definovaná ako priemerná hodnota strát naprieč

všetkými iteráciami:

$$L_{\text{total}} = \frac{1}{N} \sum_{i=1}^N L_i, \quad (2.7)$$

kde N je celkový počet iterácií a L_i je stratová funkcia pre i -tu iteráciu, zahŕňajúca stratové funkcie Dice, hraničnú a regresnú. Po každej iterácii sú nové vizuálne dotazy (body alebo čiary) generované na základe oblastí s falošne pozitívnymi a falošne negatívnymi predikciami z y'_{i-1} . V prvej iterácii sa ako vizuálny dotaz používa 3D ohraničujúci box odvodený z anotovanej masky, ktorý zostáva nemenný počas celého procesu. [21]

Autori tiež na zvýšenie robustnosti segmentácie využívajú mechanizmus učenia, ktorý nazvali učenie s istotou (angl. confidence learning), ktorý namiesto produkovania jednej segmentačnej masky generuje viacero masiek spolu s hodnotami istoty (angl. confidence scores). Týmto prístupom je možné vybrať najspoľahlivejšiu predikciu na základe hodnotenia istoty modelu. Konkrétne, posledná mapa znakov dekódera, označená ako $f_d = \text{Decoder}(Z_x)$, interaguje s vizuálnymi vstupnými zobrazeniami Z_v na generovanie viacerých výstupov, kde m_j je kontinuálna segmentačná mapa pre j -tý výstup a s_j je hodnota istoty pre j -tý výstup. Výpočty pre jednotlivé výstupy sú definované nasledovne:

$$m_j = f_d \times \text{MLP}_m^j(Z_v) \quad (2.8)$$

$$s_j = \text{MLP}_s^j(Z_v), \quad (2.9)$$

kde MLP_m^j a MLP_s^j predstavujú malé viacvrstvové perceptróny (ďalej ako MLP) aplikované na vizuálne vstupné zobrazenia pre masku a skóre istoty. Stratová funkcia pre učenie s istotou na jednej iterácii je definovaná ako:

$$L_{\text{con}} = \sum_{j=1}^M (\lambda_s L_s(m_j, y) + \lambda_b L_b(m_j, y) + \lambda_r L_r(s_j, 1 - L_{\text{Dice}}(m_j, y))), \quad (2.10)$$

kde:

- L_s je štruktúrálna stratová funkcia, ktorá kombinuje Dice a cross-entropy:
$$L_s = L_{\text{Dice}} + L_{\text{CE}},$$
- L_b je hranová stratová funkcia založená na priemernej kvadratickej chybe (angl. mean squared error, ďalej ako MSE) medzi hranicami predikcie a anotovanej masky,
- L_r je regresná stratová funkcia medzi skóre istoty a chybou segmentácie (1 - Dice skóre),
- λ_s , λ_b a λ_r sú váhy jednotlivých strátových funkcií.

Význam učenia s istotou spočíva v tom, že model sa učí nielen produkovať presné segmentácie, ale zároveň odhaduje svoju istotu voči generovaným maskám. Tento prístup umožňuje robustnejší výber výstupu pri inferencií a podporuje efektívnejšiu iteratívnu korekciu chýb. [21]

Autori ďalej implementovali špeciálnu korekčnú sieť, ktorá slúži na doladenie predikovaných masiek. Po každej iterácii je z kandidátskych masiek vybraná tá s najvyššou hodnotou istoty, ktorá je následne spracovaná korekčnou sieťou. Táto korekčná sieť je navrhnutá ako výpočtovo nenáročná a efektívna architektúra pozostávajúca z dvoch reziduálnych blokov a dvoch konvolučných vetiev. Jej vstupom je spojený vektor (angl. concatenated tensor) x_c , ktorý obsahuje vstupný obraz x , binárnu masku predikcie $\hat{b}$, kumulatívnu mapu pozitívnych dotazov a kumulatívnu mapu negatívnych dotazov. Pre efektívnosť je vstupný vektor x_c najskôr zredukovaný (angl. downsample) a následne opätovne prevedený späť na pôvodné rozlíšenie pred výpočtom finálnej segmentácie y'_t . Stratovú funkciu pre korekčné

učenie definovali nasledovne:

$$L_{\text{cor}} = \lambda_s L_s(y'_i, y) + \lambda_b L_b(y'_i, y), \quad (2.11)$$

kde L_s je štruktúrna stratová funkcia (kombinácia Dice a cross-entropy), L_b je hranová stratová funkcia, založená na MSE medzi hranami predikcie a anotovanej masky. λ_s a λ_b sú váhy pre jednotlivé komponenty straty. Výstup y'_i slúži ako vstup pre nasledujúcu iteráciu segmentácie, kde nové vizuálne dotazy (body alebo čiary) sú generované na základe chýb v predchádzajúcom výstupe. Dôležité je, že korekčná sieť neovplyvňuje spätnú propagáciu váh hlavného modelu (dekódera masky), ale pôsobí len na doladenie finálneho výstupu v rámci každej iterácie. [21]


Tréning prebiehal s veľkosťou dávky (angl. batch size) 2, rýchlosť učenia si nastavili na 4×10^{-5} , kde ju znižovali o 2×10^{-6} po každej epoche, použili optimalizátor AdamW, nastavili si maximálny počet epôch na 200 a počet dotazov počas tréningu bol náhodne vybraný z 1 až do 50 bodov na iteráciu. Cieľovú stratovú funkciu počas tréningu definovali ako súčet stratových funkcií z jednotlivých iterácií:

$$L_{\text{total}} = \frac{1}{N} \sum_{i=1}^N (L_{\text{con},i} + L_{\text{cor},i}), \quad (2.12)$$

kde $L_{\text{con},i}$ je strata spojená s učením s istotou v i -tej iterácii a $L_{\text{cor},i}$ je strata spojená s korekčným učením v i -tej iterácii. [21]

2.3.3.2 Vyhodnotenie

Výkonnosť PRISM bola primárne hodnotená pomocou metriky Dice. Model bol porovnávaný s viacerými najmodernejšími automatickými aj interaktívnymi segmentačnými riešeniami, kde uviedli dva modely: PRISM-plain a PRISM-ultra.



Obr. 2.9: Detailne vykreslená PRISM architektúra. Zelený blok značí korekčnú sieť. [21]

PRISM-plain (podporuje iba bodové dotazy) dosiahol vyššie metriky než väčšina interaktívnych modelov trébovaných od nuly a to v priemere 74.5% Dice. PRISM-ultra (kombinácia bodov, boxov a čiar) dosiahol takmer ľudskú presnosť segmentácie na všetkých štyroch datasetoch, výrazne prekonávajúc existujúce metódy s priemerným Dice 94.75%. PRISM-ultra taktiež dosahuje rastúcu presnosť cez iterácie. [21]

Methods	Public datasets (Dice %/NSD %)			
	Colon tumor	Pancreas tumor	Liver tumor	Kidney tumor
nnU-Net [12]	43.91/52.52	41.65/62.54	60.10/75.41	73.07/77.47
3D UX-Net [15]	28.50/32.73	34.83/52.56	45.54/60.67	57.59/58.55
Swin-UNETR [28]	35.21/42.94	40.57/60.05	50.26/64.32	65.54/72.04
SAM [14]	28.83/33.63	24.01/26.74	8.56/5.97	36.30/29.86
3DSAM-adapter [9]	57.32/73.65	54.41/77.88	56.61/69.52	73.78/83.86
ProMISe [18]	66.81/81.24	57.46/79.76	58.78/71.52	75.70/80.08
SAM-Med3D [31]	54.34/78.58	65.61/92.40	23.64/26.97	76.50/88.41
SAM-Med3D-organ	70.75/91.03	76.40/97.75	66.52/77.97	88.20/97.80
SAM-Med3D-turbo	73.77/94.95	74.87/96.43	69.36/81.70	89.26/98.40
PRISM-plain	67.18/85.28	65.73/89.51	79.70/91.60	85.29/93.55
PRISM-ultra	93.79/99.96	94.48/99.99	94.18/99.99	96.58/99.80

Obr. 2.10: Kvantitatívne výsledky spomedzi porovnávaných modelov, kde PRISM-plain predstavuje zjednodušený PRISM model na spravodlivé porovnanie s metódami, ktoré neumožňujú dotazy s ohraničujúcimi boxami a ktoré používajú iba 1 bodový podnet na vstupe. PRISM-ultra model umožňuje dotazy aj s ohraničujúcimi boxami a čiarami. [21]

Kapitola 3

Návrh vlastného riešenia


Ako už bolo spomenuté, cieľom práce je analyzovať súčasné metódy segmentácie nádorov v BraTS doméne, s osobitným zameraním na implementáciu riešenia architektúrou transformer s vizuálnymi dotazmi, ktoré sa v posledných rokoch ukazujú ako sľubná alternatíva ku klasickým konvolučným neurónovým sieťam.

Koncept práce bude teda zahŕňať kombináciu architektúry ViT s bodovými vizuálnymi dotazmi. Tieto modely budú starostlivo vybrané také, ktoré už videli veľké množstvo dát a budú dotrénované na BraTS doménu. Dátová množina, na ktorej budú modely dotrénované a vyhodnotené, bude zabezpečená verejne dostupným zdrojom. Architektúra modelov bude prispôbená dátovej množine, kde problém bude predstavovať binárnu segmentáciu, kde jednotlivé pixely medicínskeho zobrazenia budú klasifikované do dvoch tried: tumorové alebo netumorové tkanivo.

Výstupom práce bude softvérové riešenie, do ktorého bude možné vložiť vyextrahovaný 2D snímok prierezu 3D MRI skenu mozgu a následne získať vysegmentovanú oblasť nádorového tkaniva anatomickej štruktúry.

3.1 Prístup k problému

Navrhovaný tok riešenia vychádza z dvojfázovej segmentačnej postupnosti, ktorý využíva veľký predtrénovaný ViT model (ktorý bol aj dotrénovaný na doménový problém) na generovanie vizuálneho dotazu a následne ďalší veľký dotrénovaný ViT model na vytvorenie presnej finálnej masky. Cieľom je zvýšiť interaktívnu kontrolu nad modelom a zároveň dosiahnuť vysokú kvalitu binárnej segmentácie tumorového tkaniva v MRI snímkach.




Obr. 3.1: Zobrazenie postupnosti krokov návrhu riešenia práce.

V prvom kroku je do systému vložený 2D prierez 3D MRI objemu, ktorý je následne spracovaný predtrénovaným základovým ViT modelom (angl. foundation ViT model) pre generovanie počiatočnej segmentačnej predikcie. Tento model poskytuje hrubú, ale priestorovo konzistentnú tumorovú masku, ktorá slúži ako vizuálny odhad lokalizácie patologickej oblasti. Počiatočná maska nie je použitá ako konečný výsledok, ale ako základ pre vytvorenie vizuálneho dotazu, ktorý má model v ďalšej fáze explicitne usmerniť.

Vizuálny dotaz je v podobe bodu odvodený priamo z výstupu prvého modelu. Tento dotaz obsahuje informáciu o polohe tumoru a funguje ako dodatočný vstupný signál pre druhý model bez toho, aby bol viazaný na manuálne kreslenú anotáciu. Jeho úlohou je preniesť znalosť počiatočnej detekcie do presnejšej transformerovej segmentačnej siete.

V druhej fáze je originálny MRI prierez spolu s odvodeným vizuálnym dotazom z

predošlého kroku vložený do dotrénovaného presnejšieho ViT modelu, ktorý už tiež prešiel doménovo špecifickým dotrénovaním. Tento model je navrhnutý tak, aby dokázal prepájať informáciu z dotazu s globálnym kontextom obrazu a realizovať detailnú pixelovú binárnu klasifikáciu. Zachytáva tak jemné okrajové štruktúry aj širšie priestorové vzťahy, ktoré sú pre MRI obrazy typické.



Obr. 3.2: Vizualizované zobrazenie postupnosti krokov návrhu riešenia práce. Žltý kruh umiestnený vpravo v skene na lište zobrazuje pozíciu priereku 3D skenu. Zelená farba vykresľuje anotáciu tumorového regiónu, oranžová zobrazuje predikovanú masku prvého modelu, modrá predstavuje vizuálny dotaz a červená zobrazuje finálnu predikovanú masku druhého modelu.

Výsledkom riešenia je teda finálna segmentačná maska, ktorá reflektuje lokalizáciu navrhnutú prvým modelom, avšak s vyššou presnosťou a schopnosťou adaptácie na usmernenie riadené dotazmi. Takýto koncept podporuje využitie veľkých predtrénovaných transformerov v medicíne aj v podmienkach limitovaných dát, keďže ťažisko učenia je prenesené na silný základový (angl. foundation) model a transformer špecializovaný na doménu sa sústreďí len na precízne rozhodovanie. Celý tok je navrhnutý modulárne, aby bolo možné jednotlivé fázy analyzovať a vyhodnotiť oddelene v ďalších kapitolách práce.

3.2 Dátová množina


Pre účely trénovania a vyhodnocovania bude použitá verejne dostupná dátová množina Brain Tumor Segmentation Challenge 2021 (ďalej ako BraTS). Táto dátová množina je komplexný a verejne dostupný zdroj dát navrhnutý na porovnávanie algoritmov na segmentáciu nádorov mozgu a rádiogenomickú klasifikáciu. Bola predstavená v rámci výzvy BraTS 2021, ktorá zároveň predstavovala 10. výročie iniciatívy BraTS. Táto množina obsahuje predoperačné multiparametrické magnetické rezonancie od 2040 pacientov diagnostikovaných s gliómami, čo sú najčastejšie primárne zhubné nádory centrálneho nervového systému. [1]

V riešení práce bude využitá táto dátová množina na dotrénovanie existujúcich ViT modelov a evaluáciu segmentácie nádorov mozgu.

3.2.1 Štruktúra dát

Každý 3D sken v BraTS množine má k dispozícii štyri typy MRI modalít: T1 (anatomická štruktúra), T1ce (T1 s kontrastnou látkou), T2 (zvýrazňuje opuch), FLAIR (zvýrazňuje edém). T1 modalita predstavuje klasickú MRI snímku mozgu bez kontrastných látok. T1ce zobrazuje MRI snímku mozgu s kontrastnou látkou, ktorá zvýrazňuje aktívnu oblasť nádoru. T2 modalita zvýrazňuje opuch nádoru, pri ktorej sa zvýrazňuje obsah vody v štruktúre mozgu. FLAIR modalita zvýrazňuje edém nádoru a to tým, že sa inverzne zvýrazňuje obsah vody v anatomickej štruktúre. [26]

Každý prípad obsahuje anotácie od odborníkov, ktoré rozlišujú tri podregióny nádoru: zvýraznený nádor (angl. enhancing tumor, ďalej ako ET), jadro nádoru (angl. tumor core, ďalej ako TC) a celý nádor (angl. whole tumor, ďalej ako WT). MRI snímky sú uložené vo formáte NIfTI a každá modalita je trojrozmerný objem (3D) zobrazujúci pacientov mozog. [1, 26]



Obr. 3.3: Príklady prierezu 3D MRI skenu mozgu z BraTS 2021 datasetu už s vyznačenými maskami reprezentujúcimi anotované triedy. [1]

3.2.2 Predspracovanie dát

Všetky snímky sú predspracované na zabezpečenie konzistencie, vrátane koregistrácie na spoločnú anatomickú šablónu, prevzorkovania na jednotnú veľkosť voxelov $1 * 1 * 1 \text{ mm}^3$ a odstránenia lebky z obrazu (angl. skull stripping). Rozmery jednotlivých snímok sú štandardizované na $240 * 240 * 155$ voxelov. Táto štandardizovaná množina podporuje vývoj a hodnotenie pokročilých modelov strojového učenia s cieľom zlepšiť presnosť diagnostiky a personalizované plánovanie liečby pacientov s gliómom. [1]

3.3 Metriky

Pri hodnotení segmentačných modelov v medicínskych zobrazeniach je kľúčové presne určiť, do akej miery sa predikovaná maska zhoduje so skutočnou anotáciou. V tejto práci budú preto využité dve najčastejšie používané metriky na posúdenie presnosti priestorového prekrytia: *Dice Coefficient* a *Intersection over Union* (ďalej ako IoU). Väčšinou ale bude v práci referencovaná metrika Dice. Obe metriky poskytujú robustnú informáciu o tom, ako dobre model identifikuje hranice nádorového tkaniva, pričom sú obzvlášť vhodné pre nevyvážené datasety, ktoré sú v medicínskych úlohách bežné.

Dice koeficient meria podobnosť medzi predikovanou maskou P a anotovanou maskou G na základe ich prekrytia a hodnota nadobúda interval od 0 do 1, kde 1 predstavuje úplnú zhodu ako je uvedené vo vzorci (2.4). Táto metrika je veľmi citlivá na nepresnosti v hraniciach lézií, ktoré môžu predstavovať len malú časť obrazu, čo je typické pri nádorových štruktúrach.

Metrika IoU hodnotí pomer prieniku predikovanej masky P a skutočnej anotovanej masky G k ich zjednoteniu. Rovnako ako Dice nadobúda hodnoty od 0 do 1, pričom vyššia hodnota reprezentuje lepší súlad.

$$\text{IoU}(P, G) = \frac{|G \cap P|}{|G \cup P|}, \quad (3.1)$$

IoU poskytuje prísnejšie hodnotenie ako Dice, pretože penalizuje nielen nesprávne segmentované oblasti, ale aj objekty mimo regiónu prekrytia.

Použitie oboch metriky súčasne prináša komplexnejší pohľad na kvalitu segmentácie — Dice zdôrazňuje kvalitu prekrytia objektu a IoU dopĺňa informáciu o celkovom presnom priestorovom súlade. Tento prístup umožní detailnejšie porovnať jednotlivé modely aj ich varianty s vizuálnym promptingom a bez neho.

3.4 Kritériá segmentačného modelu

Navrhované riešenie využíva transformačné neurónové siete pre segmentáciu medicínskych obrazov, preto musí model spĺňať viacero kritérií, ktoré zabezpečia jeho účinnosť aj v podmienkach s obmedzeným množstvom anotovaných dát. Hlavnou požiadavkou na model je schopnosť pracovať s globálnym aj lokálnym kontextom, aby vedel presne identifikovať hranice nádorového tkaniva, ale zároveň pochopil jeho vzťah k okolitej anatomickej štruktúre. Model by mal byť vopred predtrénovaný na rozsiahlych vizuálnych datasetoch, aby už disponoval základnou znalosťou

vizuálnych rysov/črt a bolo ho možné následne efektívne dotrénovať pre BraTS doménu. Tréningová stratégia bude využívať zamrazenie/odmrazenie (angl. freeze/unfreeze) niektorých častí siete pre stabilnejšie učenie, pričom nižšie vrstvy môžu byť fixované a vyššie vrstvy doladené na špecifické MRI charakteristiky. Návrh zároveň kladie dôraz aj na pamäťovú efektívnosť a veľkosť vstupu, keďže ViT modely sú založené na rozdelených obrazových oblastiach/výrezoch (angl. patch-based ViT), tak môžu strácať detaily pri príliš hrubom delení vstupnej mapy. Model musí byť tiež kompatibilný so spracovaním pridaného kanála štvrtej modality BraTS dátovej množiny a aj kanála pre vizuálny dotaz, ktorý bude slúžiť na interaktívne usmerňovanie segmentácie.

3.5 Požiadavky na vizuálny dotaz

Veľmi dôležitou súčasťou návrhu je definovať, akú informáciu má vizuálny dotaz (angl. prompt) modelu prenášať a ako má ovplyvniť jeho rozhodovací proces. Dotaz musí byť generovaný tak, aby jednoznačne lokalizoval oblasť záujmu (teda oblasť nádoru), ktorá sa následne spracuje v ďalšom kroku. Dotaz by mal modelu poskytovať informáciu o jeho pozícii primárne k okolitému nádorovému jadru, ale nie ho predefinovať natoľko, aby spôsoboval chybné ignorovanie reálneho vstupného obrazu. V kontexte BraTS segmentácie sa ako dotaz najčastejšie používajú bodové dotazy alebo ohraničujúce kvádre, ktoré zvýrazňujú tumorové oblasti a sú vložené ako dodatočný vstup do modelu. Ďalšou požiadavkou je dotazová reprezentácia bez farebnej informácie, keďže modely v BraTS doméne spravidla pracujú s intenzitami a binárnymi maskami, a hodnoty dotazu by mali byť dobre normovateľné a jednoznačne rozlíšiteľné.

3.6 Kritériá finálnej segmentácie

Finálny model v riešení má poskytovať binárnu segmentačnú masku, ktorá rozlišuje medzi tumorovým a netumorovým tkanivom. Po podrobnom predtrénovaní musí byť model schopný generalizovať na menšie množstvo dát efektívnejšie ako CNN modely, keďže transformerové reprezentácie dokážu po dostatočnom naučení zachovať robustnú presnosť aj pri nízkom počte anotovaných MRI snímok. Segmentácia musí byť presná na úrovni pixelu, zachytávať aj malé tumorové štruktúry a byť stabilná voči artefaktom a rozdielom v intenzitách. Dôležitou požiadavkou je aj to, aby výsledná maska neobsahovala anatomicky neplatné fragmentácie a bola topologicky konzistentná, čo umožní následnú vizualizáciu alebo export pre klinickú validáciu. Model má podávať masku v bežnom medicínskom formáte, ktorý možno spracovať alebo transformovať aj pre spätnú 3D vizualizáciu v práci.

3.7 Riziká a výzvy

Pri návrhu transformer segmentačnej pipeline s vizuálnymi dotazmi existuje niekoľko zásadných výziev a rizík, ktoré môžu ovplyvniť úspešnosť riešenia.

Jedným z najdôležitejších problémov je zaujatosť voči dotazom (angl. prompt-bias), teda situácia, keď model dotaz ignoruje alebo naopak príliš preberie dotaz a samotné anatomické štruktúry MRI obrazu ignoruje. [36]

Problém môže predstavovať aj generovanie dotazu z výstupných masiek prvotného modelu, keďže jeho maska môže obsahovať nepresnosti, ktoré následne dotazu priradia chybné priestorové informácie.

V práci musí byť tiež riešený rozsah modelovej komplexity oproti množstvu dát, keďže malé medicínske datasety môžu viesť k pretrénovaniu transformeru, ak nie je zvolená vhodná stratégia učenia. [44]

Kapitola 4

Implementácia

Implementácia je realizovaná v programovacom jazyku *Python 3*, ktorý predstavuje jeden z najpoužívanějších nástrojov pre oblasť spracovania medicínskych dát a strojového učenia. Tento jazyk v kombinácii s rozsiahlym ekosystémom knižníc ponúka flexibilitu pri návrhu modelov, rýchlu experimentáciu, jednoduché škálovanie a podporu moderných rámcov a knižníc pre hlboké učenie (angl. deep learning). Implementácia zahŕňa spracovanie dát, prípravu trénovacích postupov, konštrukciu modelovej architektúry, vyhodnocovanie výsledkov a automatizované sledovanie experimentov. Celý vývojový proces je tak orientovaný na prehľadnosť, reprodukovateľnosť a možnosť ďalšieho rozširovania v budúcnosti.

4.1 Použité rámce

V tejto práci boli použité viaceré knižnice a rámce, ktoré zabezpečujú spracovanie obrazu, načítavanie datasetov, architektúru segmentačných modelov, implementáciu stratových funkcií, tréningu a inferencie, implementácia a vyhodnocovanie metrík, vizualizáciu, ako aj sledovanie experimentov a výkonu modelov.

Rámec *PyTorch* je špecializovaná knižnica pre hlboké učenie, ktorá slúži na definovanie neurónových sietí, automatické diferenciovanie, tréning modelov a manipuláciu s tenzormi. V tejto práci bol PyTorch použitý na definíciu architektúry modelov, ich trénovanie, tvorbu načítavačov dát (angl. dataloaders) pre efektívne čítanie skenov počas učenia a pre inferenciu. PyTorch poskytuje flexibilitu pri navrhovaní vlastných modelov, stratových funkcií (angl. loss functions), optimalizátorov (angl. optimizers) a mnoho ďalších. [31]

Rámec *TorchMetrics* poskytuje štandardizované implementácie metrík pre PyTorch modely, vrátane segmentačných metrík ako Dice a IoU. Použitím tejto knižnice sa v práci zabezpečilo spoľahlivé a reprodukovateľné vyhodnocovanie kvality segmentácie modelov počas tréningu, ako aj testovania. [41]

TorchVision je oficiálny balík rozšírení pre PyTorch poskytujúci nástroje pre transformácie obrázkov a predtrénované modely pre počítačové videnie. V práci bol použitý pri načítavaní dát pre transformovanie datasetu a spracovanie vstupných obrázkov pred ich použitím v neurónových sieťach. [42]

Knižnica *SegmentationModelsPyTorch* (ďalej ako SMP) poskytuje implementácie populárnych architektúr segmentačných modelov, ako sú UNet alebo SegFormer, s rôznymi predtrénovanými enkódermi. SMP bol využitý v práci pre konfiguráciu a architektúru segmentačných sietí použitých v experimentoch. [35]

Rámec *Ultralytics* obsahuje implementácie pokročilých modelov pre detekciu a segmentáciu objektov, vrátane SAM modelu, ktorý umožňuje segmentáciu obrazu a segmentovanie vizuálnymi dotazmi. V práci bol tento rámec využitý pre použitie modelu SAM na segmentáciu. [45]

NumPy je základná knižnica pre numerické výpočty a prácu s poľami. Umožňuje efektívne spracovanie multidimenzionálnych polí (napr. obrázkov ako matíc), arit-

metických operácií nad nimi a integruje sa s inými knižnicami, ako sú Pandas a Matplotlib. V práci je používaný pri narábaní s dátovými štruktúrami, manipulácii vstupných obrazových dát, výpočtoch a transformáciách pred tréningom alebo vizualizáciou. [27]

Knižnica *OpenCV* je jedno z najrozšírenejších riešení pre počítačové videnie a spracovanie obrazov. Používa sa na načítavanie a manipuláciu s obrazmi, transformácie a klasické algoritmy spracovania obrázkov. V tejto práci bola táto knižnica použitá pri generovaní vizuálnych dotazov, konkrétne na lokálnu detekciu ostrovov (angl. island detection) v binárnej maske a následné vyhodnotenie pomocou transformácie vzdialenosti (angl. distance transform, určenie najvzdialenejšieho bodu od hraníc daného ostrova). [28]


Knižnica *Matplotlib* je používaná pre vizualizáciu dát a dátových štruktúr, ktorá umožňuje vytvárať rôzne typy grafov, obrázkov a vizualizácií výsledkov. V tejto práci bola použitá na vizualizáciu predikcií modelov, zobrazovanie segmentačných masiek, historické priebehy metrík a ďalšie grafické výstupy dôležité pre analýzu výsledkov. [24]

Knižnica *Tqdm* sa používa pre vypisovanie/vizualizovanie indikátora priebehu pri rôznych skriptoch a procesoch. V práci bol rámec použitý na vizualizáciu priebehu tréningu a inferencie v reálnom čase, čo zlepšuje prehľadnosť behu experimentov a uľahčuje monitorovanie dlhšie trvajúcich procesov. [43]

Rámec *ClearML* je nástroj na sledovanie experimentov, hyperparametrov, metrík a správy kontrolných bodov modelov. V práci bol použitý na monitorovanie tréningových úloh, ukladanie výsledkov, sledovanie konfigurácií a porovnávanie výkonu jednotlivých experimentov v jednotnom rozhraní. [7]

4.2 Architektúra segmentačných modelov

Navrhovaný segmentačný tok riešenia pozostáva z dvoch hlavných modelových komponentov, ktoré spolu vytvárajú viacstupňový segmentačný systém. Prvým krokom je extrakcia jednotlivých 2D rezov z 3D MRI objemu. Tento rez je následne spracovaný modelom SAM [18], ktorý poskytne prvotnú segmentáciu nádorovej oblasti. Táto maska sa ďalej transformuje na vizuálny dotaz (tento proces bude vysvetlený v ďalšej sekcii), ktorý slúži ako dodatočná priestorová informácia pre druhý model, postavený na architektúre MixVision Transformer [50] (ďalej ako MiT). Ten už následne vykonáva finálnu segmentáciu zohľadňujúcu pôvodný MRI obraz aj priestorovú znalosť vizuálneho dotazu.



Obr. 4.1: Zobrazenie toku navrhnutého riešenia.


Tento dvojstupňový prístup kombinuje robustné všeobecné segmentačné schopnosti modelu SAM [18] s vysokou presnosťou rozšírenej architektúry vizuálnych transformerov modelu MiT [50], ktorá sa špecializuje na medicínske dáta.

4.2.1 SAM model

Segment Anything Model (SAM) je pokročilý bazálny model (angl. foundation model) pre obrazovú segmentáciu vyvinutý výskumníkmi z Meta AI Research. Jeho

hlavným cieľom je umožniť dotazovú segmentáciu obrazu, teda generovanie vysoko kvalitných maskových segmentácií pre ľubovoľný objekt alebo oblasť obrazu na základe rôznych typov vstupných dotazov, ako sú body, ohraničovacie polia alebo dokonca masky samotné. SAM bol navrhnutý tak, aby dokázal generalizovať na nové domény a úlohy bez potreby špecifického doladenia pre každú z nich — teda vykazoval silný výkon pri testovaní bez príkladov (angl. zero-shot) na ľubovoľných vizuálnych scénach (v tomto mu dopomáha jeho predtrénovanie na datasete SA-1B pozostávajúci z vyše jednej miliardy másk). [18]

Architektúra SAM pozostáva z troch kľúčových modulov. Sú to obrazový enkóder, dotazový enkóder a maskový dekóder. Tieto spolupracujú pri generovaní výsledných segmentačných masiek. [18]



Obr. 4.2: Vizualizovaná architektúra SAM modelu. Na ľavej strane zobrazené rôzne typy vstupných dotazov ku obrázku. Vpravo je zobrazená samotná architektúra SAM modelu. [18]

Kvôli tejto výkonnosti pri využívaní modelu bez príkladov bol model vybraný do tejto práce pre prvotnú segmentáciu nádorovej oblasti z prierezu 3D MRI objemu mozgu.

4.2.1.1 Obrazový enkóder

Obrazový enkóder je výkonná neurónová sieť určená na spracovanie vstupného obrazu a extrakciu bohatých vektorových reprezentácií (angl. embeddings), ktoré zachytávajú vizuálne informácie obsahu obrazu na rôznych úrovniach. V SAM je obrazový enkóder postavený na ViT [9] architektúre, ktorý bol predtrénovaný pomocou prístupu maskovaného autoenkódera [14] (angl. masked autoencoder, ďalej ako MAE). ViT je vhodný pre spracovanie obrazov vo forme dlhých sekvencií výrezov obrazu (angl. patches) a umožňuje zachytiť ako lokálne, tak globálne závislosti medzi obrazovými oblasťami. Enkóder spracuje vstupný obraz jednorázovo a vytvorí jeho hustú vektorovú reprezentáciu, ktorá je dekóderom spätne použitá pre rôzne dotazy. Využíva maskované autoenkódovanie pre silné predtrénovacie vlastnosti. Produkuje vektorové reprezentácie obrazu, ktoré môžu byť znova použité pri rôznych dotazoch bez opätovného spracovania celého obrazu. [18]

4.2.1.2 Dotazový enkóder

Dotazový enkóder je flexibilný komponent, ktorý spracúva vstupné dotazy - teda informácie o tom, čo sa má segmentovať. SAM podporuje 2 typy vizuálnych dotazov: diskkrétne (angl. sparse prompt) a súvislé (angl. dense prompt). [18]

Diskkrétne dotazy sú tvorené jednotlivými bodami (popredie/pozadie) alebo ohraničujúcimi poliami (angl. bounding boxes). Súvislé dotazy sú kombináciou diskkrétnych dotazov s pomocnými maskami (napr. zakreslené machuľe, oblasti, alebo segmentácie predchádzajúceho kroku). [18]

Diskkrétne dotazy, ako body a ohraničujúce polia, sú zakódované pomocou pozíčných enkódovaní a naučených vektorových reprezentácií, zatiaľ čo masky sú zvyčajne spracované pomocou jednoduchých konvolučných vrstiev predtým, než sa spoja s vektorovými reprezentáciami obrazu. Takto vytvorené dotazové vektorové

reprezentácie poskytujú modelu kontextové vodítka o tom, ktorá časť obrazu je relevantná pre segmentáciu. [18]

Tento modul je navrhnutý tak, aby premenil ľubovoľné vstupné pokyny užívateľa na vektorovú reprezentáciu, ktorú môže maskový dekodér ľahko kombinovať s vektorovými reprezentáciami obrazu. [18]


4.2.1.3 Maskový dekodér

Maskový dekodér je ľahký, ale efektívny dekodovací modul, ktorý kombinuje vektorové reprezentácie obrazu z obrazového enkóderu a vektorové reprezentácie vizuálnych dotazov z dotazového enkóderu, aby vygeneroval výslednú segmentačnú masku. Architektúra maskového dekódera vychádza z princípov transformerového dekódera doplneného o mechanizmy sebaopozornosti (angl. self-attention) a krížovej pozornosti (angl. cross-attention), ktoré umožňujú interakciu medzi obrazovými a dotazovými vektorovými reprezentáciami. [18]

Priamo sa takto integrujú dve hlavné informácie: bohatá vizuálna reprezentácia vstupného obrazu a zmysluplné kontextové vodítka z vizuálneho dotazu. Maskový dekodér následne produkuje binárnu masku, ktorá reprezentuje požadovanú segmentáciu objektu alebo oblasti obrazu podľa dotazu. [18]

4.2.2 MiT model

MiT je hierarchická transformerová architektúra špeciálne navrhnutá pre segmentačné úlohy, ktorá kombinuje výhody globálnej pozornosti (angl. global-attention) transformerov s viacúrovňovou (angl. multi-scale) reprezentáciou typickou pre moderné konvolučné siete. Model MiT produkuje viaceré úrovne črtových reprezentácií obrazu pri rôznych priestorových rozlíšeniach, čo je kľúčové pre presnú segmentáciu. [50]



Obr. 4.3: Vizualizácia architektúry MiT s jeho hlavnými komponentami ako hierarchický enkóder a špeciálny dekóder, ktorý agreguje viacúrovňové vstupy z enkóderu. [50]

Presne kvôli tejto viacúrovňovej hierarchickej architektúre bol MiT vybraný v tejto práci ako finálny segmentačný model, keďže sa kvôli jeho detailnému vnímaniu lokálnych aj globálnych črt hodí do tejto medicínskej domény. Predikuje finálnu segmentáciu nádorovej oblasti z prierezu 3D MRI objemu mozgu.

4.2.2.1 Hierarchický enkóder

Na rozdiel od pôvodnej ViT [9] architektúry, ktorá spracováva obraz ako jednorozmerný prvok (angl. token) sekvencie, MiT rozdeľuje vstupný obraz na menšie prekryvné výrezy oblastí (napr. 4×4) a spracúva ich postupne cez niekoľko štádií. Každé štádium obsahuje transformerové bloky, ktoré zachytávajú vnútorné vzťahy v rámci výrezov obrazu, čím vznikajú viacúrovňové črty. [50]

Enkóder postupne generuje výstupy (viaceré úrovne mapy príznakov) s rôznymi priestorovými rozlíšeniami (napr. $1/4$, $1/8$, $1/16$, $1/32$ vstupnej veľkosti), pričom

každý stupeň obsahuje širšie a hlbšie črty, ktoré reprezentujú rôznu mieru detailov obrazu. [50]

Namiesto neprekrývajúcich sa výrezov obrazu ako u základných ViT [9], MiT používa prekrývajúce sa vektorové reprezentácie výrezov, ktoré pomáhajú lepšie zachovať lokálny kontext a spojitosť pixelov pri prechode medzi úrovňami. [50]

Ďalej nepoužíva explicitné pozičné zakódovania. MiT sa vyhýba tradičným pozičným vektorovým reprezentáciám, ktoré sú bežné pri klasických transformer modeloch. Namiesto toho sa priestorová informácia prirodzene zakóduje prekrývajúcimi sa výrezmi obrazu a tzv. Mix-FFN (mixed feed-forward network) blokmi. Tým sa zlepšuje generalizácia, napr. ak sa rozlíšenie líši v testovacej množine od tréningových podmienok. [50]

MiT nahrádza tradičné FFN bloky (feed-forward network) v transformerových vrstvách takzvanými Mix-FFN modulmi. Tie obsahujú 3x3 hlbkové konvolúcie, ktoré vnášajú priestorové informácie priamo do transformerových blokov, čím kompenzujú absenciu explicitných pozičných kódov. Tento krok umožňuje modelu naučiť sa lokálne aj globálne vzťahy bez špeciálneho pozičného kódovania. [50]

4.2.2.2 All-MLP dekodér

Na rozdiel od komplexných dekodérov používaných v iných transformerových segmentačných modeloch, MiT využíva jednoduchý MLP (multilayer perceptron) dekodér, ktorý agreguje viacúrovňové vstupy z enkóderu. Výstupy z viacerých úrovní enkódera sa spoja a spracujú pomocou ľahkých MLP vrstiev, ktoré integrujú informácie z lokálnych aj globálnych pozorností, čím vzniká silná reprezentácia pre masku bez ťažkého dekodovacieho modulu. Takýto jednoduchý dekodér výrazne znižuje výpočtovú náročnosť výsledného modelu a zároveň zachováva vysokú presnosť segmentácie. [50]

4.2.3 Generovanie vizuálneho dotazu

Po získaní predikcie masky z SAM modelu je potrebné extrahovať bodový dotaz, ktorý bude slúžiť ako vstup pre finálny MiT model. Proces zahŕňa identifikáciu hlavného tumoru a výber reprezentatívneho bodu v jeho centre najďalej od jeho hraníc. Tento prístup umožňuje automatickú lokalizáciu reprezentatívneho bodu bez manuálneho označovania, minimalizuje vplyv artefaktov a šumu a umožňuje MiT modelu zamerať sa na hlavnú tumornú oblasť pri finálnej segmentácii.

4.2.3.1 Detekcia regiónov tumoru

Získanie samostatných regiónov z masky získanej od SAM modelu sa spracuje pomocou implementovanej funkcie na získanie spojených komponentov v obraze so všetkými možnými 8 smermi (vľavo, vpravo, hore, dole a diagonálnymi smermi). Funkcia identifikuje všetky spojené komponenty v binárnej maske a pre každý komponent vracia počet pixelov, súradnice ohraničujúceho rámca (angl. bounding box), centroid komponentu a ďalšie štatistiky. Vyberie sa najväčší región, ktorý zodpovedá hlavnej oblasti tumoru, čím minimalizuje vplyv menších artefaktov.




Obr. 4.4: Detekcie regiónov tumoru z masky na príklade dátovej štruktúry dvojrozmerného poľa.

4.2.3.2 Výpočet bodového dotazu

Pre vybraný región je aplikovaná funkcia transformácie vzdialenosti. Pre každý pixel komponentu sa vypočíta vzdialenosť od najbližšieho okrajového pixelu regiónu:

$$D(x, y) = \min_{(i,j) \in \partial R} \sqrt{(x-i)^2 + (y-j)^2}, \quad (4.1)$$

kde ∂R predstavuje hranice regiónu. Pixel s najvyššou hodnotou v mape vzdialeností sa použije ako bodový dotaz pre MiT model.



Obr. 4.5: Vizualizácia transformácie vzdialenosti od hraníc regiónu na príklade dátovej štruktúry dvojrozmerného poľa.

4.3 Tréning

Tréning navrhovaného riešenia prebiehal v dvoch samostatných fázach, ktoré zodpovedajú jednotlivým komponentom architektúry: SAM [18] modelu pre prvotnú segmentáciu oblasti nádorového regiónu a MiT [50] modelu pre finálnu segmentáciu s využitím vizuálneho dotazu. Oba modely boli trénované oddelene, pričom výstupy SAM modelu neslúžili ako vstupné informácie pre generovanie vizuálnych dotazov počas tréningu MiT modelu, ale boli odvodené zo samotnej anotácie.

Tréning bol realizovaný na grafickej karte *NVIDIA RTX 6000 Ada Generation* s kapacitou 48 GB GPU pamäte. Z dôvodu citlivosti medicínskych dát a zachova-

nia anatomickej konzistencie MRI snímok nebola počas tréningu aplikovaná dátová augmentácia. Dataset bol rozdelený na *trénovaciu*, *validačnú* a *testovaciu* množinu, pričom validačná množina slúžila na monitorovanie generalizačných vlastností modelu a na výber optimálneho kontrolného bodu (angl. checkpoint) modelu.

Optimalizácia bola realizovaná pomocou algoritmu *AdamW* [8] s váhovým rozpadom (angl. weight decay), ktorý je vhodný pre transformerové architektúry. Na stabilizáciu učenia bol použitý *krokový plánovač* (angl. learning rate scheduler) s lineárnym nárastom učenia počas prvých piatich epochách (angl. warm-up) a následným kosínusovým poklesom hodnoty učenia.

Z dôvodu pamäťových obmedzení a zároveň snahy zachovať numerickú stabilitu bol tréning realizovaný v režime miešanej presnosti výpočtov (angl. mixed precision) s využitím automatického pretypovania (angl. autocast) na dátový typ *bfloat16*. Tento formát si zachováva rovnaký rozsah exponentu ako *float32*, čím minimalizuje riziko numerickej nestability, pričom znižuje pamäťové nároky v porovnaní s 32 bitami a poskytuje vyššiu stabilitu než *float16*.

4.3.1 Stratová funkcia

Na optimalizáciu oboch segmentačných modelov bola použitá kombinovaná stratová funkcia pozostávajúca z *binárnej krížovej entropie* (angl. Binary Cross-Entropy, ďalej ako BCE) a *Dice koeficientu*. Táto kombinácia je často používaná pre medicínsku segmentáciu, kde často dochádza k výraznej nevyváženosti tried medzi pozadím a nádorovou oblasťou. [37, 25]

Celková stratová funkcia je definovaná ako:

$$\mathcal{L}_{total} = \lambda_{BCE} \cdot \mathcal{L}_{BCE} + \lambda_{Dice} \cdot \mathcal{L}_{Dice}, \quad (4.2)$$

kde λ_{BCE} a λ_{Dice} predstavujú váhy jednotlivých zložiek stratovej funkcie.


BCE penalizuje nesprávne klasifikované pixely na úrovni jednotlivých pixelov:

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]. \quad (4.3)$$

Dice koeficient zas vyhodnocuje mieru prekrytia medzi predikovanou maskou a referenčnou maskou (anotáciou):

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_i \hat{y}_i y_i}{\sum_i \hat{y}_i + \sum_i y_i}. \quad (4.4)$$

Vizualizácia dvoch príkladov pre vytýčenie rozdielov medzi týmito stratovými funkciami:



Obr. 4.6: Zelená farba predstavuje korektne predikované pixely. Modrá farba predstavuje anotačné pixely, ktoré boli vyhodnotené ako pozadie. Červená farba predstavuje nekorektne predikované pixely.

Na obidvoch príkladoch nadobúda BCE hodnotu 0.83, keďže iba jeden pixel je nesprávne predikovaný. Pre Dice ale ľavý nadobúda hodnotu 0.96 a pravý 0.66, keďže táto metrika hodnotí prekrytie a to dodáva hlbšiu perspektívu pri tréňovaní modelu.

Použitie Dice koeficientu je obzvlášť výhodné pri malých nádorových oblastiach, keďže optimalizuje priamo mieru prekrytia a nie je citlivé na veľkosť triedy. Kom-

binácia s BCE zabezpečuje stabilné gradienty a rýchlejšiu konvergenciu počas tréningu. [37, 25]

4.3.2 Tréning SAM modelu

SAM bol vybraný na túto úlohu kvôli jeho dobrým výsledkom bez doplňujúcich príkladov (angl. zero-shot). Avšak po zistení, že SAM mal problém s medicínskymi dátami (špecificky BraTS) bolo rozhodnuté ho dotrénovať na tento domový problém.

SAM model bol dotrénovaný na 2D rezoch MRI skenov s rozlíšením 256×256 pixelov, ktoré pri doprednom šírení cez sieť boli na začiatku preškálované na 1024×1024 pixelov kvôli jeho natvrdo nastaveným PE. Vstup tvorili štyri obrazové kanály zodpovedajúce jednotlivým MRI modalitám a výstupom bola binárna segmentačná maska. Keďže SAM má iba tri vstupné kanály, tak bol vytvorený ďalší vstupný kanál, kde boli váhy prekopírované a spriemerované z pôvodných troch vstupných kanálov. Model bol inicializovaný s predtrénovanými váhami a trénovaný počas maximálne 50 epoch s veľkosťou dávky (angl. batch size) 128 a kvantite (angl. number of workers) 8. Rýchlosť učenia bola nastavená na hodnotu 1×10^{-5} a prahová hodnota rozhodovania (angl. prediction threshold) bola nastavená na 0.7.

Hlavným cieľom tréningu SAM modelu bolo dosiahnuť robustnú prvotnú segmentáciu tumoru, ktorá následne slúžila na generovanie vizuálnych dotazov pre MiT model. Počas tréningu bola monitorovaná hodnota stratovej funkcie a segmentačné metriky na validačnej množine a podľa nich bola vybratá najlepšia verzia modelu.

4.3.3 Tréning MiT modelu

MiT bol dotrénovaný s piatimi vstupnými kanálmi, ktoré pozostávali zo štyroch MRI modalít a jedného kanála reprezentujúceho vizuálny dotaz (základný model mal tiež iba tri vstupné kanály a postup bol rovnaký ako pre dotrénovanie SAM modelu). Rozlíšenie vstupu bolo 256×256 pixelov a výstupom bola binárna segmentačná maska.

Počas tréningu bol vizuálny dotaz generovaný náhodným výberom bodu v rámci regiónu tumoru tak, aby vždy ležal vo vnútri niektorého tumorového regiónu. Tento prístup zabezpečuje, že model je dotrénovaný na rôznych pozíciách vizuálneho dotazu a zvyšuje jeho robustnosť voči posunu dotazu v inferenčnej fáze, najmä pri viac-regiónových nádoroch.

Model bol dotrénovaný maximálne 50 epoch s veľkosťou dávky (angl. batch size) 256 a kvantite (angl. number of workers) 8. Rýchlosť učenia bola nastavená na hodnotu 1×10^{-5} a prahová hodnota rozhodovania (angl. prediction threshold) bola nastavená na 0.7. Validačná množina bola využitá na sledovanie priebehu učenia, detekciu pretrénovania a výber najlepšieho modelu na základe segmentačných metrík.

Literatúra

- [1] Ujjwal Baid et al. “The rsna-asnr-miccai brats 2021 benchmark on brain tumor segmentation and radiogenomic classification”. In: *arXiv preprint arXiv:2107.02314* (2021).
- [2] Amir Bar et al. “Visual prompting via image inpainting”. In: *Advances in Neural Information Processing Systems* 35 (2022), s. 25005–25017.
- [3] Yoshua Bengio, Ian Goodfellow, Aaron Courville et al. *Deep learning*. Zv. 1. MIT press Cambridge, MA, USA, 2017.
- [4] Jieneng Chen et al. “Transunet: Transformers make strong encoders for medical image segmentation”. In: *arXiv preprint arXiv:2102.04306* (2021).
- [5] Junlong Cheng et al. “Sam-med2d”. In: *arXiv preprint arXiv:2308.16184* (2023).
- [6] Özgün Çiçek et al. “3D U-Net: learning dense volumetric segmentation from sparse annotation”. In: *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2016: 19th International Conference, Athens, Greece, October 17–21, 2016, Proceedings, Part II* 19. Springer. 2016, s. 424–432.
- [7] *ClearML: Machine learning experiment manager*. <https://clear.ml/>. 2025.
- [8] Kuangyu Ding, Nachuan Xiao a Kim-Chuan Toh. “Adam-family methods with decoupled weight decay in deep learning”. In: *arXiv preprint arXiv:2310.08858* (2023).

- [9] Alexey Dosovitskiy et al. “An image is worth 16x16 words: Transformers for image recognition at scale”. In: *arXiv preprint arXiv:2010.11929* (2020).
- [10] Vincent Dumoulin a Francesco Visin. *A guide to convolution arithmetic for deep learning*. 2016. arXiv: 1603.07285 [cs.LG].
- [11] Andre Esteva et al. “A guide to deep learning in healthcare”. In: *Nature medicine* 25.1 (2019), s. 24–29.
- [12] Ian Goodfellow et al. *Deep learning*. Zv. 1. 2. MIT press Cambridge, 2016.
- [13] Ali Hatamizadeh et al. “Unetr: Transformers for 3d medical image segmentation”. In: *Proceedings of the IEEE/CVF winter conference on applications of computer vision*. 2022, s. 574–584.
- [14] Kaiming He et al. “Masked autoencoders are scalable vision learners”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022, s. 16000–16009.
- [15] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature methods* 18.2 (2021), s. 203–211.
- [16] Michael A Jacobs, Tamer S Ibrahim a Ronald Ouwerkerk. “MR imaging: brief overview and emerging applications”. In: *Radiographics* 27.4 (2007), s. 1213–1229.
- [17] Hany Kasban, MAM El-Bendary, DH Salama et al. “A comparative study of medical imaging techniques”. In: *International Journal of Information Science and Intelligent System* 4.2 (2015), s. 37–58.
- [18] Alexander Kirillov et al. “Segment anything”. In: *Proceedings of the IEEE/CVF international conference on computer vision*. 2023, s. 4015–4026.
- [19] Alex Krizhevsky, Ilya Sutskever a Geoffrey E Hinton. “Imagenet classification with deep convolutional neural networks”. In: *Advances in neural information processing systems* 25 (2012).

- [20] Feng Li et al. “Visual in-context prompting”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, s. 12861–12871.
- [21] Hao Li et al. “Prism: A promptable and robust interactive segmentation model with visual prompts”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer. 2024, s. 389–399.
- [22] Geert Litjens et al. “A survey on deep learning in medical image analysis”. In: *Medical image analysis* 42 (2017), s. 60–88.
- [23] David N Louis et al. “The 2021 WHO classification of tumors of the central nervous system: a summary”. In: *Neuro-oncology* 23.8 (2021), s. 1231–1251.
- [24] *Matplotlib: Visualization library*. <https://matplotlib.org/>. 2025.
- [25] Fausto Milletari, Nassir Navab a Seyed-Ahmad Ahmadi. “V-net: Fully convolutional neural networks for volumetric medical image segmentation”. In: *2016 fourth international conference on 3D vision (3DV)*. Ieee. 2016, s. 565–571.
- [26] Amr Mohamed et al. “Brain tumor radiogenomic classification”. In: *arXiv preprint arXiv:2401.09471* (2024).
- [27] *NumPy: Fundamental package for scientific computing*. <https://numpy.org/>. 2025.
- [28] *OpenCV: Open Source Computer Vision Library*. <https://opencv.org/>. 2025.
- [29] Keiron O’shea a Ryan Nash. “An introduction to convolutional neural networks”. In: *arXiv preprint arXiv:1511.08458* (2015).
- [30] Quinn T Ostrom et al. “CBTRUS statistical report: primary brain and other central nervous system tumors diagnosed in the United States in 2015–2019”. In: *Neuro-oncology* 24.Supplement_5 (2022), s. v1–v95.

- [31] *PyTorch: Tensors and Dynamic neural networks*. <https://pytorch.org/>. 2025.
- [32] Peter Reimer et al. *Clinical MR imaging*. Springer, 2010.
- [33] Fahad Shamshad et al. “Transformers in medical imaging: A survey”. In: *Medical Image Analysis* 88 (2023), s. 102802.
- [34] K Kirk Shung, Michael Smith a Benjamin MW Tsui. *Principles of medical imaging*. Academic Press, 2012.
- [35] *SMP: Segmentation Models in PyTorch*. <https://segmentation-models.pytorch.readthedocs.io/en/latest/>. 2025.
- [36] Fei Song et al. “Doubly Debaised Test-Time Prompt Tuning for Vision-Language Models”. In: *arXiv preprint arXiv:2511.11690* (2025).
- [37] Carole H Sudre et al. “Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations”. In: *International Workshop on Deep Learning in Medical Image Analysis*. Springer. 2017, s. 240–248.
- [38] Paul Suetens. *Fundamentals of Medical Imaging*. Cambridge University Press, 2017.
- [39] Sasha Targ, Diogo Almeida a Kevin Lyman. “Resnet in resnet: Generalizing residual architectures”. In: *arXiv preprint arXiv:1603.08029* (2016).
- [40] Eric J Topol. “High-performance medicine: the convergence of human and artificial intelligence”. In: *Nature medicine* 25.1 (2019), s. 44–56.
- [41] *TorchMetrics: Standardized metrics for PyTorch*. <https://lightning.ai/docs/torchmetrics/stable/>. 2025.
- [42] *Torchvision: Vision utilities for PyTorch*. <https://docs.pytorch.org/vision/>. 2025.
- [43] *Tqdm: Fast, extensible progress bars*. <https://pypi.org/project/tqdm/>. 2024.

- [44] Anh T Tran, Tal Zeevi a Seyedmehdi Payabvash. “Strategies to improve the robustness and generalizability of deep learning segmentation and classification in neuroimaging”. In: *BioMedInformatics* 5.2 (2025), s. 20.
- [45] *Ultralytics: real-time detection, segmentation and classification*. <https://docs.ultralytics.com/>. Framework with SAM model and others. 2025.
- [46] Ashish Vaswani et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017).
- [47] Maria Correia de Verdier et al. “The 2024 Brain Tumor Segmentation (BraTS) Challenge: Glioma Segmentation on Post-treatment MRI”. In: *arXiv preprint arXiv:2405.18368* (2024).
- [48] Xinlong Wang et al. “Seggpt: Segmenting everything in context”. In: *arXiv preprint arXiv:2304.03284* (2023).
- [49] Xinlong Wang et al. “Seggpt: Towards segmenting everything in context”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, s. 1130–1140.
- [50] Enze Xie et al. “SegFormer: Simple and efficient design for semantic segmentation with transformers”. In: *Advances in neural information processing systems* 34 (2022), s. 12077–12090.
- [51] Peng Zhang a Yaping Wang. “Segment anything model for brain tumor segmentation”. In: *arXiv preprint arXiv:2309.08434* (2023).