

FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLOGIÍ

SLOVENSKÁ TECHNICKÁ UNIVERZITA

Ilkovičova 2, 842 16 Bratislava 4

2024/2025

Neurónové siete

Projekt č.2

Cvičiaci: Ing. Tibor Sloboda

Vypracovali: Šimon Freivald, Peter Bartoš

Čas cvičení: Štvrtok 18:00-19:50

Zadanie projektu

Naším cieľom bolo vytvoriť vhodný model, ktorý bude vykonávať segmentáciu obrazu. Podmienkou bolo použiť a otestovať Swish aktivačnú funkciu a využiť dataset TIGER.

Dáta

TIGER - je verejný dataset obsahujúci dáta zamerané na digitálnu patológiu rakoviny prsníka s manuálnymi anotáciami. Dataset je rozdelený do troch subsetov:

WSIROIS - Whole-slide images with manual annotations in regions of interest

- 195 celoplošných patologických snímok rakoviny prsníka s vybranými a manuálne označenými ROI
- V každom ROI sú anotované tieto oblasti:
 - invasive tumor - label: 1
 - tumor-associated stroma - label: 2
 - in-situ tumor - label: 3
 - healthy glands - label: 4
 - necrosis not in-situ - label: 5
 - inflamed stroma - label: 6
 - rest - label: 7
- Multi-class segmentation

WSIBULK - Whole-slide images with coarse manual annotation of the tumor bulk

- Sada 93 patologických snímok rakoviny prsníka
- Obsahuje anotácie jednej alebo viacerých oblastí, ktoré obsahujú invazívne nádorové bunky
- Single-class segmentation

WSITILS - Whole-slide images with visual estimation of the TILs at slide level

- V tomto subsele nie sú uvedené žiadne segmentačné anotácie, ale zoznam hodnôt TIL (Tumor-infiltrating lymphocytes)

V našom projekte sme si vybrali subset **WSIROIS**, kde sme ale podľa vypísaného tiger challengeu tento subset poňali ako binárnu segmentáciu kde je cieľom vysegmentovať invasive tumor (label 1) + tumor-associated stroma (label 2). Zvyšné classy sú poňaté ako "rest".

Keďže originálny dataset bol príliš veľký na stiahnutie tak, sme si stiahli len nami vybraný subset [WSIROIS](#), kde už rovno boli vyrezané ROI z pôvodných whole-slide imageov, spolu s ich

segmentačnými maskami. Tieto dáta sme následne upravili do vhodnej file štruktúry na tréovanie. Pri tréovaní sme následne segmentačné masky premenili na nami zvolenú úlohu a to tak, že pre label 1 a 2 sme vo výstupnej maske nastavili maximálnu hodnotu pixelu 255 a zvyšok bol vyplnený hodnotu 0. Vstupné obrázky a aj nové masky boli následne resizeované na jednotnú veľkosť 128x128 a prešli augmentáciou, kedy sa náhodne tvorili flipy - horizontálne a vertikálne, rotácie do 22 stupňov a náhodné gaussove rozmazanie. Takto pretransformované obrázky a masky boli nakoniec preškálované na hodnoty [0, 1] a vyskúšali sme aj hodnoty [-1, 1], práve kvôli využitému paperu Swish aktivačnej funkcie.

Implementácia modelu

Po predspracovaní bol model natréovaný na segmentáciu obrazu pomocou U-Net architektúry. Kľúčové kroky zahŕňali:

- Konvolučná neurónová sieť U-Net s enkóderom a dekóderom
 - Vstupná vrstva → obrázky s 3 kanálmi (rgb).
- Zostupná (enkóderová) časť (každý blok obsahuje dve 3x3 konvolúcie, normalizáciu a aktiváciu, nasledované 2x2 max poolingom)
 - Prvý blok → 64 filtrov, aktivácia
 - Druhý blok → 128 filtrov, aktivácia
 - Tretí blok → 256 filtrov, aktivácia
 - Štvrtý blok → 512 filtrov, aktivácia
- Bottleneck → 1024 filtrov, dve konvolúcie s aktiváciou
- Vzostupná (dekóderová) časť (každý dekóderový blok kombinuje zväčšený výstup z predchádzajúcej vrstvy s príslušným výstupom enkódera pomocou skip connections a následne aplikuje dve konvolúcie)
 - Prvý blok → transponovaná konvolúcia, skip connection s enkóderom, 512 filtrov
 - Druhý blok → 256 filtrov a to isté
 - Tretí blok → 128 filtrov a to isté
 - Štvrtý blok → 64 filtrov a to isté
- Výstupná vrstva → 1 filter (1 kanál), konvolúcia 1x1 na mapovanie na binárny výstup

Parametre modelu:

- Aktivačná funkcia → Swish, Learnable Swish a SwiGLU
- Optimalizátor → Adam
- Stratová funkcia → Binary Cross Entropy with logits
- Prah klasifikácie výstupu → 0.5

Priebeh tréningu

Model sa trénoval 50 epôch s batch size 64 (najviac koľko sa nám zmestilo do pamäte s rozumným časom). Použili sme štandardné metriky pre segmentáciu a to IoU a Dice skóre. Pre prah klasifikácie výstupu sme vyskúšali aj väčší ako 0.5, keďže masky sú pomerne malé oproti obrázku, ale nespravilo to žiadny významný rozdiel vo výsledných metrikách.

V každej epoche:

- Pre každý tréningový batch sa vykonal forward pass, výpočet straty a spätná propagácia
- Predikcie boli binarizované pomocou sigmoid a porovnávané s maskou (ground truth)
- Metriky IoU, Dice a strata boli zaznamenávané

Validácia:

Po každej epoche nasledovala evaluačná fáza na validačných dátach bez učenia, s rovnakým výpočtom metrík.

Logovanie:

Po každej epoche sa metriky posielali do nástroja wandb pre vizualizáciu.

Evaluácia



Obrázok č. 1 – Porovnanie výsledkov na validačnej množine s použitím a nepoužitím skip connections.

Toto porovnanie vyšlo v našom zadaní ako najviac zaujímavé, pretože pri rovnakých podmienkach len pridaním skip connections do architektúry Unet sme dostali diametrálne odlišné a lepšie výsledky.

Unet - Skip Connections, Swish - Dice: 88.63%, IoU: 79.80%

Unet, Swish - Dice: 73%, IoU: 57.80%




Obrázok č. 2 – Porovnanie medzi Swish, LearnableSwish a SwiGLU.

Tento výsledok je taktiež zaujímavý, pretože sme nepredpokladali, že SwiGLU bude pomerne veľkým rozdielom za Swish a LearnableSwish. Čo sa týka týchto dvoch obdôb Swish funkcií tak, môžeme vidieť len malý rozdiel no aj napriek tomu LearnableSwish dosiahla o čosi najlepšiu výsledok v našej práci.

LearnableSwish - Dice: 90%, IoU: 81.92%

Swish - Dice: 88.63%, IoU: 79.80%

SwiGLU - Dice: 86%, IoU: 75.69%



Obrázok č. 3 – Porovnanie výsledkov na validačnej množine s rôznymi škálovaniami.

Pri rovnakých podmienkach len so zmenou škálovania vstupu z $[0,1]$ na $[-1,1]$ sme dostali totožné výsledky, pretože rozdiel bol len veľmi zanedbateľný v prospech škálovania $[-1,1]$.

Škálovanie $[-1, 1]$, Swish - Dice: 88.63%, IoU: 79.80%

Škálovanie $[0, 1]$, Swish - Dice: 88.38%, IoU: 79.39%

Zhrnutie

Najlepšie výsledky boli dosiahnuté kombináciou:

- Pridanie skip connections do Unet architektúry
- Použitie LearnableSwish aktivácie
- Škálovanie vstupu na $[-1, 1]$

Projekt ukázal, že správna normalizácia vstupu a hlavne voľba aktivačnej funkcie majú významný vplyv na presnosť segmentácie. Ďalej, že skip connections výkonnosť architektúry Unet posúvajú na vyšší level. Prekvapivo pri pomerne malých maskách voči celej veľkosti obrazu nemal prah klasifikácie výstupu nejaký extra značný vplyv. Tiež napodiv SwiGLU sa preukázala ako najhoršou alternatívou spomedzi ostatných vyskúšaných aktivačných funkcií a najlepšia bola Learnable Swish.