

FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLOGIÍ

SLOVENSKÁ TECHNICKÁ UNIVERZITA

Ilkovičova 2, 842 16 Bratislava 4

2024/2025

Neurónové siete

Projekt č.3

Cvičiaci: Ing. Tibor Sloboda

Vypracovali: Šimon Freivald, Peter Bartoš

Čas cvičení: Štvrtok 18:00-19:50

Zadanie projektu

Cieľom projektu bolo vytvoriť model na detekciu a lokalizáciu kľbových bodov človeka na základe vstupného RGB obrázka. Použitý bol LSP (Leeds Sports Pose) dataset, ktorý obsahuje anotované súradnice 14 kľúčových bodov ľudského tela. Model predikuje heatmapy pre každý kľb a hodnotí sa pomocou metriky PCKh (Percentage of Correct Keypoints) s normalizáciou na 0.5 násobok veľkosti hlavy.

Dáta

LSP – Leeds Sports Pose Dataset obsahuje 10 000 obrázkov športovcov v rôznych pózach. Každý obrázok má anotovaných 14 kľbov: hlava, ramená, lakty, zápästia, boky, kolena a členky. Dataset bol rozdelený na tréningovú množinu (9000 vzoriek) a testovaciu množinu (1000 vzoriek). Keďže obrázky boli rôznych veľkostí tak, sme ich najprv orezali okolo anotovaného človeka o veľkosti 256x256. Anotácie sme uložili ako .npy súbor, kde každé dve hodnoty zodpovedajú súradniciam jedného kľbu x a y. Pre každý kľb sa vytvára 2D gaussovská heatmapa. Heatmapy sa vytvárajú v mierke 1/64 pôvodnej veľkosti obrázku - podobne ako pri metóde UniPose. Použili sme dynamickú augmentáciu počas tréningu. Spravili sme horizontálny flip s pravdepodobnosťou 0.5 a vertikálny flip s pravdepodobnosťou 0.5. Augmentácia sa aplikuje naraz na obrázok aj všetky heatmapy.

Implementácia modelu

Po predspracovaní bol model natrénovaný na odhad pózy človeka v obrázku pomocou U-Net architektúry. Architektúra vyzerala nasledovne:

Encoder (Backbone):

- EfficientNet-B0 (import z timm)
 - Predtrénovaný na ImageNet
 - Zmrazené váhy – neaktualizujú sa počas tréningu (experimentovali sme aj s nezmrazenými váhami)
 - Takto malý backbone model bol použitý na základe nami vybraného paperu (skúšali sme aj U-Net bez predtrénovaného backbone-u -> príliš pomalý tréning)
- Decoder (UpBlocks):
 - 3 upsampling bloky, kde každý blok pozostával:
 - Bilineárna interpolácia
 - Concatenácia skip connection z backbone
 - DoubleConv blok (Conv2D → BatchNorm → ReLU) - experimentovali sme aj so SingleConv blokom, čo neprinieslo žiadne zlepšenie alebo zhoršenie

- Head:
 - Posledné vrstvy:
 - Conv2D → BatchNorm → ReLU → Dropout(0.3) → Conv2D
 - Výstup má tvar [batch_size, 14, H, W] – heatmapy pre každý klb

Parametre modelu:

- Aktivačná funkcia → ReLU
- Optimalizátor → Adam
- Stratová funkcia → MSE a z paperu HeatmapWeightingMSE
- Dropout → 0.3
- Regularizácia (weight decay) → 0.0001

Priebeh tréningu

Model sa trénoval 50 epôch (neskôr 100) s batch size 256 (najviac koľko sa nám zmestilo do pamäte s rozumným časom). Použili sme metriku PCKh@0.5, kde predikovaný klb je považovaný za správny, ak je jeho euklidovská vzdialenosť od anotácie menšia ako 50% veľkosti hlavy. Z heatmapy sa extrahujú číselné súradnice x a y pomocou argmax a porovnávajú sa anotovanými súradnicami. Mieru učenia (learning rate) sme nastavili na 0.0001. V každej epoche:

- Pre každý tréningový batch sa vykonal forward pass, výpočet straty a spätná propagácia
- Predikcie boli porovnávané s maskou (ground truth)
- Metrika Pckh a strata boli zaznamenávané

Validácia:

Po každej epoche nasledovala evaluačná fáza na validačných dátach bez učenia, s rovnakým výpočtom metrík.

Logovanie:

Po každej epoche sa metriky posielali do nástroja wandb pre vizualizáciu.

Evaluácia




Obrázok č. 1 – Porovnanie výsledkov pri tréningu s malým zmrazeným predtrénovaným backbone-om s použitím loss funkcie z papery a MSE s dynamickou augmentáciou.

Z porovnania je zrejmé, že loss navrhnutý v papery vedie k rýchlejšej konvergencii počas tréningu, čo sa však prejavuje aj výraznejším pretrénovaním. Hoci MSE loss taktiež trpí určitým pretrénovaním, jeho rozsah je v porovnaní s lossom z papery podstatne menší. Napriek tomu dosahuje MSE loss na validačnej množine veľmi podobné výsledky.

Paper Loss - Train PCKh: 60.24%, Test PCKh: 44.35%

MSE Loss - Train PCKh: 50.79%, Test PCKh: 43.50%




Obrázok č. 2 – Porovnanie výsledkov pri trénoch s malým ne-zmrazeným predtrénovaným backbone-om s použitím lossu s paperu a MSE s dynamickou augmentáciou.

Na základe predchádzajúceho grafu sme vyhodnotili model so zmrazeným backbone-om ako nedostatočne skonvergovaný, pretože vykazoval slabé výsledky na trénoch aj validačných dátach. Preto sme pristúpili k ďalšiemu experimentu, v ktorom sme backbone odmrázili, s cieľom získať robustnejší model. Z výsledkov však možno pozorovať podobné správanie ako predtým – v druhej polovici trénoch dochádza k výraznému overfittingu. Možno dodať, že v prvej polovici trénoch sa dostane na 50% na validačnej množine a 60% trénoch množine a po tomto bode, ako už bolo spomínané, začína overfitovať. Opäť platí, že model tréňovaný pomocou MSE lossu vykazuje menší stupeň pretrénovania a zároveň dosahuje lepšie výsledky na validačnej množine v porovnaní s lossom z paperu.

Paper Loss - Train PCKh: 86.92%, Test PCKh: 44.98%

MSE Loss - Train PCKh: 81.04%, Test PCKh: 46.94%



Obrázok č. 3 – Porovnanie výsledkov pri trénoch s malým zmrazeným predtrénovaným backbone-om s použitím paper lossu **s** a **bez** využitia dynamickej augmentácie dát.

Napriek nepekným výsledkom je z daného grafu vidieť evidentný veľmi veľký prínos augmentácie dát na trénoch modelu. Bez augmentácie dochádzalo k veľmi rýchlemu veľkému overfitu zatiaľ čo pri použití augmentácie sa model dokázal stabilnejšie učiť generalizovať čo sa však tiež v neskoršej fáze trénoch pokazilo ale v oveľa menšom merítku. Domnievame sa, že dataset LSP sám o sebe nieje dostatočne obsiahly na trénoch nakoľko prichádza k veľkému overfitu a aj len malé zvýšenie obsahu pridanou augmentáciou dokáže spraviť veľký rozdiel vo výsledku.

Bez Augmentácie (epocha 50) - Train PCKh: 79.20%, Test PCKh: 41.93%

S Augmentáciou (epocha 50) - Train PCKh: 49.88%, Test PCKh: 44.19%



Obrázok Č. 4 – Porovnanie výsledkov pri trénoch s väčším zmrazeným predtrénovaným backbone-om s použitím loss funkcie z paperu a MSE s dynamickou augmentáciou.

Aj pri zväčšení backbone modelu vidíme úplne rovnaký trend. Loss funkcia z paperu sa na začiatku tréningu omnoho lepšie zorientuje no v dlhodobom horizonte opäť trpí väčším pretrénovaním a horším validačným výsledkom ako MSE loss.

Paper Loss- Train PCKh: 71.60%, Test PCKh: 43.50%


MSE Loss - Train PCKh: 64.10%, Test PCKh: 45.30%

Zhrnutie

Najlepšie výsledky boli dosiahnuté kombináciou:

- Odmrazený predtrénovaný EfficientNet B0 backbone
- Predčasné ukončenie tréningu - kvôli rýchlej konvergencii k overfitu
- Použitie dynamickej augmentácie
- Použitie paper loss-u

(Epocha 20) Train PCKh: 51.52%, Test PCKh: 49.34%



Model	Train PCKh	Test PCKh
paper-unfreezed-b0-aug	51.51487	49.33626
mse-unfreezed-b0-aug	48.2693	46.72369

Hlavným poznatkom z tohto zadania je predpoklad, že dataset LSP o veľkosti 10 000 obrázkov, nie je dostatočne rozsiahly na úspešné natrénovanie modelu pre danú úlohu. Túto skutočnosť ešte zhoršuje fakt, že obrázky v datasete zachytávajú ľudí v neštandardných a často veľmi náročných pózach, čo výrazne sťažuje generalizáciu modelu. Z experimentov navyše vyplýva, že aj jednoduchá augmentácia dát dokáže výrazne zlepšiť výsledky, čo poukazuje na obmedzenosť pôvodného datasetu. Obohatenie trénovacej množiny o ďalší väčší a diverzifikovanejší dataset by s veľkou pravdepodobnosťou viedlo k výraznému zlepšeniu výkonnosti modelu.